


1주차: 강의 소개와 회귀분석의 첫 지도

회귀분석의 이해

2026년 2학기 · 동덕여자대학교 데이터사이언스전공

데이터에서 관계를 발견하고,
불확실성을 인정하며, 예측을 설명하는 법

$$Y = f(X_1, X_2, \dots, X_p) + \epsilon$$



수업일: 2026년 9월 2일

수업 주제: 강의 소개 · 평가 및 운영 · 회귀분석의 개요

수업 방법: 오리엔테이션 + 개념 강의 (실습은 다음 수업부터)

오늘의 학습목표

수업을 마치면 다음을 설명하거나 수행할 수 있어야 합니다.

1. 이 과목의 학습 목표, 평가 방식과 출결 규정을 설명한다.
2. 데이터 기반 질문에서 반응변수 Y와 설명변수 X를 구분한다.
3. 회귀분석을 “변수 사이의 함수적 관계를 탐색하는 데이터 분석 방법”으로 설명한다.
4. 회귀분석이 문제 진술부터 모형 평가까지 이어지는 반복 과정임을 이해한다.
5. 관심 있는 사례를 반응변수와 설명변수로 표현한다.

75분 수업 흐름

시간	내용	학생 활동
0-8분	환영, 과목의 질문, 첫 사례	“무엇을 예측하고 싶은가?” 한 문장 작성
8-20분	강의 목표, 운영, 평가, 출결	핵심 규정 체크
20-42분	회귀분석의 개념과 용어	사례별 Y와 X 찾기
42-55분	회귀분석의 단계와 반복성	단계 순서 맞추기
55-68분	응용 사례 비교와 질문	사례의 Y와 X, 분석 목적 정리
68-75분	핵심 개념 정리	Exit ticket 제출

1. 이 과목은 어떤 문제를 다루는가

데이터를 분석할 때 자주 묻는 질문은 다음과 같습니다.

- 수리할 부품 수가 늘면 수리 시간은 얼마나 늘어나는가?
- 광고비가 매출과 어떤 관계를 갖는가?
- 집의 위치, 연식, 면적과 가격은 어떻게 연결되는가?
- 발사 시 기온이 우주왕복선 부품의 손상과 관련되는가?
- 어떤 설명변수가 결과에 중요한가?


이 질문들은 서로 달라 보이지만 공통 구조를 갖습니다.

1. 설명하거나 예측하고 싶은 결과가 있다.
2. 그 결과와 관련될 수 있는 하나 이상의 변수가 있다.
3. 데이터로 관계를 요약하고, 설명하고, 예측하고 싶다.

2. 강의 운영과 평가

평가 구성

시험 70% · 과제 10% · 출석 20%




지각 2회 = 결석 1회 · 총 수업시수의 1/5 초과 결석 시 F

- 중간고사 30%, 기말고사 40%, 과제 10%, 출석 20%입니다.
- 지각 2회는 결석 1회로 산정합니다.
- 결석시수가 총 수업시수의 1/5을 초과하면 학칙에 따라 F학점이 부여됩니다.
- 개인 노트북을 준비합니다.
- 기본적인 R 문법과 프로그래밍 경험을 권장하지만, 실습 자료에서 필요한 개념을 다시 확인합니다.
- 이론을 먼저 이해한 뒤, 같은 개념을 R 코드와 시각화로 확인합니다.

3. 회귀분석이란 무엇인가

회귀모형의 해부도

관측된 Y 를 설명하는 체계적인 부분과, 설명되지 않은 오차 ϵ 를 분리한다.



회귀분석은 변수들 사이의 함수적 관계를 탐색하는 개념적으로 단순하면서도 널리 활용되는 방법입니다. 일반적인 관계는 다음처럼 적을 수 있습니다.

$$Y = f(X_1, X_2, \dots, X_p) + \epsilon$$

- Y : 반응변수(response), 종속변수(dependent), 목표변수(target), 출력(output)
- $X_1, \dots, X_p$: 설명변수(explanatory), 예측변수(predictor), 공변량(covariate), 회귀변수(regressor)
- $f(\cdot)$: 설명변수와 반응변수 사이의 체계적인 관계
- ϵ : 모형이 정확히 설명하지 못하는 근사의 불일치, 즉 확률오차

선형회귀모형의 대표적인 형태는 다음과 같습니다.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon$$

여기서 $\beta_0, \beta_1, \dots, \beta_p$ 는 데이터로부터 추정할 미지의 회귀계수입니다.

주의: “독립변수”라는 용어는 널리 쓰이지만, 실제 데이터의 예측변수들이 서로 통계적으로 독립이라는 뜻은 아닙니다. 이 강의에서는 주로 **설명변수** 또는 **예측변수**라는 표현을 사용합니다.

4. 회귀분석의 세 가지 핵심 목적

회귀방정식은 단순히 선 하나를 그리는 도구가 아닙니다.

1. **관계 요약과 설명:** 반응변수와 설명변수들의 관계를 간결하게 표현합니다.
2. **효과와 중요성 평가:** 개별 설명변수가 결과와 어떻게 관련되는지 평가합니다.
3. **예측:** 주어진 설명변수 값에서 반응변수 값을 예측합니다.

상황에 따라 예측변수 값을 바꾸는 정책이나 의사결정의 효과를 분석하는 데에도 활용할 수 있습니다. 그러나 관측 데이터의 회귀관계를 곧바로 인과효과로 해석해서는 안 됩니다. 인과적 결론에는 연구 설계와 추가 가정이 필요합니다.

5. 응용 사례에서 Y와 X 찾기

회귀분석은 어디에 쓰일까?

서로 다른 분야라도 질문의 구조는 같다: “어떤 X들이 Y와 어떻게 연결되는가?”

농학	Y 현재 우유 생산량 X 이전 생산량 · 지방/단백질 · 수유일수	노동·경제	Y 생활비 X 인구밀도 · 소득 · 세금 · 노동권 법안
정치학	Y 국내 인구이동 X 실업률 · 임금 · 범죄율 · 교육수준	역사학	Y 유물의 연대 X 두개골의 너비 · 높이 · 길이
환경	Y 수질 오염 농도 X 농업 · 산림 · 주거 · 산업 토지 비율	산업 생산	Y 광택 작업시간 X 제품 지름 · 제품 종류 · 가격
우주안전	Y 손상된 O-ring 수 X 발사 시 기온	의료서비스	Y 의료기관 수익 X 병상 수 · 입원일수 · 비용 구조

분야	가능한 반응변수 Y	가능한 설명변수 X
농학	현재 월의 우유 생산량	이전 월 생산량, 지방/단백질 함량, 수유일수
노동·경제	생활비	인구밀도, 노조가입 비율, 인구, 세금, 소득
정치학	국내 인구이동률	실업률, 임금, 범죄율, 소득, 교육수준
역사학	두개골의 대략적 연대	최대 너비, 높이, 길이, 코 높이
환경	강 유역의 평균 질소 농도	농업·산림·주거·상업/산업 용지 비율
산업	제품 광택시간	제품 지름, 제품 종류, 가격
우주안전	손상된 O-ring 수	발사 시 기온
의료서비스	시설의 순이익	병상 수, 입원일수, 환자치료 수익, 비용

작 활동: 질문을 회귀문제로 바꾸기

아래에서 하나를 골라 2분 동안 작성합니다.

- 관심 있는 결과 Y는 무엇인가?
- 결과와 관련될 수 있는 설명변수 X를 두 개 이상 적어보자.
- 각 변수는 양적 변수인가, 질적 변수인가?
- 이 관계를 설명하려는가, 예측하려는가, 둘 다인가?

5. 적합방법의 선택
6. 모형 적합
7. 모형 평가 및 비판
8. 선택된 모형을 문제 해결에 사용

중요한 점은 이 순서가 일방통행이 아니라는 것입니다. 잔차나 특이값에서 문제가 발견되면 변수, 모형, 데이터와 가정을 다시 검토합니다. 만족할 만한 설명과 예측이 얻어질 때까지 **적합 → 진단 → 비판 → 수정**을 반복합니다.

8. 학기 동안 만들 웹 애플리케이션



다음 실습 수업부터 제공된 코드를 실행해 입력값이 예측과 그림을 어떻게 바꾸는지 확인합니다. 이후 학습한 내용을 추가합니다.

- 단순회귀의 계수와 예측
- 다중회귀와 여러 설명변수
- 신뢰구간과 예측구간
- 잔차와 영향점 진단
- 질적 변수와 변수변환
- 공선성과 변수선택
- 최종 분석 보고와 앱 설명

수리 시간 예측 앱 — 1주차 프로토타입

입력


수리할 부품 수



예상 수리 시간

112.7분

오늘은 앱 구조와
입력-출력의 연결을 확인합니다.



다음 단계: 계수 해석 · 구간추정 · 진단 · 변수선택

운영 안내: 첫 수업에서는 환경설정을 진행하지 않습니다. 아래 내용은 다음 실습 수업을 위한 참고입니다.

9. 다음 수업 예고: R, RStudio, Quarto의 역할

R 실습 환경: 네 가지 역할을 구분하자

도구의 이름이 비슷해 보여도 역할은 다르다.



권장 설치 순서: R → RStudio → Quarto 확인 → 필요한 패키지 설치

- R은 통계 계산과 프로그래밍을 수행하는 엔진입니다.
- RStudio는 R 코드를 작성하고 실행하며 파일, 그래프, 도움말을 관리하는 통합 개발 환경입니다.
- Quarto는 설명, 코드, 표, 그림을 한 문서에 묶어 재현 가능한 결과물로 만드는 출판 시스템입니다.
- R 패키지는 R의 기능을 확장합니다. 이번 수업의 첫 앱에서는 shiny를 사용합니다.

.qmd 문서는 어떻게 결과가 되는가?

설명과 코드를 함께 저장하면, 같은 분석을 다시 실행하고 검증할 수 있다.



핵심: 결과만 저장하는 것이 아니라, 결과를 만든 코드와 설명까지 함께 남긴다.

다음 실습 수업에서 사용할 확인 명령

```
R.version.string
2 + 3
getwd()
Sys.which("quarto")
```

```
required <- c("knitr", "rmarkdown", "shiny")
required %in% rownames(installed.packages())
```

첫날 환경 점검 체크리스트

모든 항목에 체크되면 .qmd 렌더링과 Shiny 앱 실행을 시작할 수 있다.



R 설치

R.version.string이 출력된다



RStudio 실행

Console에 2 + 3을 입력하면 5가 나온다



Quarto 확인

Sys.which("quarto")가 빈 문자열이 아니다



필수 패키지

knitr · rmarkdown · shiny가 설치되어 있다



프로젝트 열기

week01_regression.Rproj를 열었다



데이터 경로

data/Computer.Repair.txt가 존재한다



문서 렌더링

week01_lab_student.qmd가 HTML로 렌더링된다



앱 실행

shiny::runApp("app")이 브라우저를 연다

자세한 설치와 오류 해결은 [R/RStudio/Quarto 설치와 문제 해결](#)을 참고합니다.

10. 오늘의 Exit ticket

수업이 끝나기 전에 다음 세 문장을 완성합니다.

1. 회귀분석에서 Y 는 _____ 이다.
2. 회귀분석에서 ϵ 는 _____ 을 나타낸다.
3. 내가 회귀분석으로 살펴보고 싶은 질문은 _____ 이다.

Take-home message

- 회귀분석은 Y 와 X 의 관계를 모형으로 요약하고 설명하며 예측하는 방법이다.
- 모형은 현실의 완전한 복사본이 아니라 근사이므로 오차 ϵ 와 가정을 함께 고려해야 한다.
- 회귀분석은 한 번의 계산이 아니라 문제 진술, 적합, 진단, 비판과 수정이 반복되는 과정이다.
- R 코드는 결과를 만드는 계산이며, .qmd 문서는 그 계산의 이유와 결과까지 함께 기록한다.
- 이번 학기의 앱은 매주 배운 개념을 추가하며 성장한다.

다음 수업 준비

- 다음 수업에는 실습용 노트북을 준비합니다.
- R/RStudio/Quarto 환경설정과 기본 실행은 다음 실습 수업에서 함께 진행합니다.
- 다음 수업에서는 산점도, 공분산, 상관계수와 회귀분석의 기본 아이디어를 다룬다.

참고

- Ali S. Hadi, Samprit Chatterjee, *Chatterjee 예제를 통한 회귀분석 제6판: R 활용*, Chapter 1.
- 강현철, *예제를 통한 회귀분석 제6판 제1장 서론* 강의자료.
- 수업용 R 코드: 주교재 Chapter 2 예제 중 R 객체, 데이터 구조, 데이터 읽기 관련 부분.

점검 퀴즈

이전 과정에서 원 강의의 핵심 개념을 바탕으로 보충한 복습 문항입니다.

1. 회귀분석에서 반응변수와 설명변수는 각각 무엇인가요?
2. 회귀모형에서 오차 ϵ 를 포함하는 이유는 무엇인가요?
3. 회귀분석을 반복적인 과정이라고 부르는 이유는 무엇인가요?
4. 관측 데이터의 회귀관계를 인과관계로 바로 해석할 수 있나요?
5. 데이터 표에서 행과 열은 각각 무엇을 나타내나요?