

산점도에서 회귀분석으로

회귀분석의 이해 · 2026년 9월 14일 월요일 · 3주차 1차시

주교재 3.2 공분산과 상관계수, 3.3 컴퓨터 수리시간 사례

1. 오늘의 질문: 수리 예약에 몇 분을 배정할까?

컴퓨터 수리점에서 고객이 “부품 4개를 고쳐야 합니다”라고 말한다. 직원에게 필요한 것은 “부품 수와 수리시간은 관련이 있다”라는 설명만이 아니다. 예약표에 **몇 분을 배정할지**도 판단해야 한다.

오늘은 이 질문을 세 단계로 나누어 생각한다.

1. **그림으로 보기**: 부품 수가 많을수록 수리시간도 긴가?
2. **숫자로 요약하기**: 함께 증가하는 경향은 얼마나 뚜렷한가?
3. **예측으로 나아가기**: 부품 수를 알면 수리시간을 더 잘 예상할 수 있는가?

공분산과 상관계수는 두 번째 질문에 답하는 도구다. 회귀분석은 세 번째 질문으로 나아갈 수 있게 한다. 오늘은 모형의 추정·검정을 배우기 전에 그 필요성과 기본 아이디어를 이해한다.

학습목표: 산점도 읽기, 편차의 곱 설명하기, 공분산·상관계수 손계산하기, 상관의 한계 구분하기, 관계 요약과 예측의 차이 설명하기.

2. 한 점은 한 건의 관측이다

수리 기록에서 X 는 수리할 부품 수(개), Y 는 수리시간(분)이다. 가로축에 X , 세로축에 Y 를 놓는다. **같은 수리 건의 두 값**이 하나의 점이 된다. **(4, 64)**는 “4번째 수리”가 아니라 “부품 4개, 수리시간 64분인 한 건”이다.

수리 건	부품 수 x_i	수리시간 y_i	산점도에 찍을 점
A	2	29	(2, 29)
B	4	64	(4, 64)
C	4	74	(4, 74)
D	8	119	(8, 119)

위 네 건은 교재 사례의 일부다. B와 C는 부품 수가 같지만 수리시간은 다르다. 따라서 “부품 수만 알면 시간이 완벽하게 정해진다”고 생각하면 안 된다. 부품 종류·고장 정도·작업 조건 등 기록되지 않은 요인이 있을 수 있다. 이것은 가능한 해석이지, 이 자료에서 해당 요인을 실제로 측정했다는 뜻은 아니다.

산점도는 방향과 형태를 함께 보여준다

합성 자료 · 축과 단위 → 방향 → 형태 → 흩어짐 → 특이점



그림 1. 각 패널은 개념 설명을 위한 합성 자료다. 점의 높이가 아니라 왼쪽에서 오른쪽으로 갈 때의 패턴을 비교한다. 점을 선으로 연결하지 않아도 관계를 읽을 수 있다.

산점도를 읽는 다섯 가지 순서

읽을 것	확인할 내용	말로 설명하는 예
축·단위	무엇을 어떤 단위로 측정했는가?	"가로는 부품 수, 세로는 분이다."
방향	함께 증가하는가, 반대로 움직이는가?	"부품 수가 많을수록 시간이 긴 편이다."
형태	직선 주변인가, 곡선인가?	"직선으로 대략 요약할 수 있어 보인다."
흩어짐	같은 X에서 Y는 얼마나 다양한가?	"부품 수가 같아도 시간이 다르다."
특이점	전체 패턴에서 벗어난 점이 있는가?	"몇 점이 전체 인상을 좌우하는지 살핀다."

직접 확인 E1. (4, 64)와 (4, 74)는 어느 방향으로 나란히 놓이는가? 두 점 사이의 거리는 무엇을 뜻하는가? 힌트: 가로좌표가 같다.

3. 평균에서 얼마나 벗어났는가?

"함께 크다"를 판단하려면 비교 기준이 필요하다. 각 변수의 **표본평균**을 기준으로 삼는다.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

기호	뜻	읽는 방법
n	관측한 쌍의 개수	데이터가 네 쌍이면 $n = 4$
i	관측을 구별하는 번호	x_i, y_i 는 같은 관측의 두 값
$\sum$	지정한 항을 모두 더하라는 기호	$\sum x_i = x_1 + \cdots + x_n$
$\bar{x}, \bar{y}$	각 변수의 표본평균	합계를 관측 수로 나눈 값
$x_i - \bar{x}$	X 의 편차	평균보다 크면 양수, 작으면 음수

풀이 예제 1: 평균과 편차를 먼저 계산한다

손계산을 위해 만든 작은 합성 자료를 사용하자. 교재의 실제 수리시간 데이터와는 다른 **계산 연습용 자료**다.

$$X = (1, 2, 3, 4), \quad Y = (2, 4, 4, 6).$$

1단계. 평균: $\bar{x} = (1 + 2 + 3 + 4)/4 = 2.5$, $\bar{y} = (2 + 4 + 4 + 6)/4 = 4$.

2단계. 관측마다 평균을 뺀다.

i	x_i	y_i	$x_i - 2.5$	$y_i - 4$
1	1	2	-1.5	-2
2	2	4	-0.5	0
3	3	4	0.5	0
4	4	6	1.5	2

첫 관측은 두 평균보다 모두 작고, 마지막 관측은 두 평균보다 모두 크다. 평균을 뺀 값들의 합은 각 열에서 0 이다. 따라서 편차를 그냥 더해서는 함께 움직이는 정도를 알아낼 수 없다.

평균선은 “평균보다 크다 / 작다”의 기준

점 (1, 2): 두 편차 모두 음수 → 편차 굵은 양수




그림 2. 가로축·세로축의 원점이 아니라 **두 평균선의 교점**을 기준으로 영역을 나눈다. 평균선 위의 점은 편차 하나가 0이므로 편차의 곱도 0이다. 교재 그림 3.1의 개념을 작은 계산 자료로 새로 구성했다.

4. 왜 편차 두 개를 곱할까?

한 관측의 두 편차를 곱하면 “두 변수가 평균을 기준으로 같은 방향에 있는가?”를 부호로 표시할 수 있다.

X의 위치	Y의 위치	편차의 곱	관계에 대한 기여
평균보다 큼	평균보다 큼	$(+) \times (+) = +$	함께 큰 관측
평균보다 작음	평균보다 작음	$(-) \times (-) = +$	함께 작은 관측
평균보다 큼	평균보다 작음	$(+) \times (-) = -$	반대쪽에 있는 관측
평균보다 작음	평균보다 큼	$(-) \times (+) = -$	반대쪽에 있는 관측

편차의 곱 = 부호가 있는 사각형의 넓이

같은 방향은 +, 반대 방향은 - · 넓이는 절댓값, 색은 부호





그림 3. 사각형의 넓이는 편차 곱의 **절댓값**이다. 색은 부호를 나타낸다. 넓이는 음수가 될 수 없지만, 대수적으로 합산하는 편차의 곱은 음수일 수 있다. 넓은 사각형을 만드는 점은 합에 크게 기여한다.

여기서 “양의 영역에 점이 더 많으면 반드시 양의 공분산”이라고 단정하면 안 된다. **점의 개수뿐 아니라 편차 곱의 크기**도 중요하다. 평균에서 멀리 떨어진 한 점이 작은 여러 점보다 더 크게 작용할 수 있다.

풀이 예제 2: 공분산을 표 한 장으로 계산한다

앞의 네 쌍을 계속 사용한다. 마지막 열은 같은 행의 두 편차를 곱한 값이다.

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$
1	-1.5	-2	3
2	-0.5	0	0
3	0.5	0	0

4	1.5	2	3
합	0	0	6

표본 공분산은 편차 곱의 합을 $n - 1$ 로 나눈 값이다.

$$s_{xy} = \text{cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1} = \frac{6}{4 - 1} = 2.$$

결과가 양수라는 것은 두 변수가 표본에서 함께 증가하는 선형 경향을 가진다는 뜻이다. 여기서 2는 "2배 증가한다"거나 "2만큼의 기울기"라는 뜻이 아니다.

왜 $n - 1$ 인가? 이 수업에서는 모집단 전체가 아니라 표본으로 공분산을 계산한다. 표본평균을 데이터에서 구하면 편차들의 합이 0이라는 제약이 생긴다. 표준적인 표본 분산·공분산은 이를 반영해 $n - 1$ 을 사용한다. 엄밀한 불편성 증명은 오늘 범위 밖이다. R의 `cov()`도 같은 분모를 사용한다.

직접 확인 E2. 위 자료에서 Y 를 $(6, 4, 4, 2)$ 로 바꾸면 공분산의 부호와 값은 어떻게 될까? 먼저 그림을 예상한 뒤 편차의 곱을 계산하라.

5. 공분산에는 단위가 남아 있다

X 가 부품 수(개), Y 가 시간(분)이면 s_{xy} 의 단위는 개·분이다. 시간 단위를 분에서 초로 바꾸면 모든 Y 의 숫자는 60배가 된다. 실제 수리 사건은 그대로인데 공분산도 60배가 된다.

같은 관측, 다른 단위

시간을 60배 → 공분산도 60배 · 상관계수는 그대로





그림 4. 두 그림은 같은 합성 관측이다. 오른쪽 세로축은 왼쪽의 60배다. 축 단위를 읽지 않고 공분산 숫자만 비교하면 관계가 더 강해졌다고 오해할 수 있다.

단위를 양의 상수배로 바꿀 때는 다음이 성립한다.

$$\text{cov}(X, 60Y) = 60 \text{cov}(X, Y).$$

상수를 더하면 평균도 같은 만큼 이동하므로 편차는 변하지 않는다. 예를 들어 모든 시간에 10분을 더해도 공분산은 그대로다. 일반적으로는

$$\text{cov}(aX + b, cY + d) = ac \text{cov}(X, Y).$$

이 식은 새 관측을 만드는 공식이 아니라 **척도 변환의 효과**를 정리한 것이다. 서로 단위가 다른 두 연구의 공분산을 보고 “숫자가 더 큰 연구에서 관계가 더 강하다”고 바로 비교할 수 없다.

6. 표준편차로 나누면 단위가 없어진다

공분산에서 단위와 산포 크기의 영향을 제거하려면 각 변수의 표준편차로 나눈다. 표본 표준편차는 평균 주변의 퍼짐을 원래 단위로 나타내는 값이다.

$$s_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}, \quad s_y = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}}.$$

편차를 제공하면 음수와 양수가 상쇄되지 않는다. 평균적인 제곱 크기를 구한 뒤 제곱근을 취해 원래 단위로 돌아온다. 여기서는 **표본 표준편차**를 쓰므로 분모가 $n-1$ 이다.

표준화 값 $z_{xi} = (x_i - \bar{x})/s_x$ 는 “평균에서 표준편차 몇 개만큼 떨어져 있는가?”를 나타낸다. $z = 1$ 이면 평균보다 표준편차 하나만큼 크다. 단위가 같아야 한다는 제약 없이 두 변수의 위치를 비교할 수 있다.

표준화: 평균에서 표준편차 몇 개만큼 떨어졌는가?

각 변수에서 평균을 빼고 표본 표준편차로 나눈다




그림 5. 점의 상대적인 선형 패턴은 유지된다. 표준화 후 각 축의 평균은 0, 표본 표준편차는 1이다. 표준화한다고 분포가 정규분포로 바뀌는 것은 아니다.

풀이 예제 3: 상관계수를 끝까지 계산한다

앞의 작은 자료에서 필요한 합은 다음과 같다.

$$\begin{aligned} S_{xx} &= (-1.5)^2 + (-0.5)^2 + (0.5)^2 + (1.5)^2 = 5, \\ S_{yy} &= (-2)^2 + 0^2 + 0^2 + 2^2 = 8, \\ S_{xy} &= 3 + 0 + 0 + 3 = 6. \end{aligned}$$

S_{xx} , S_{yy} , S_{xy} 는 계산을 간단히 적기 위해 이름 붙인 **합계**다. 아직 $n - 1$ 로 나누지 않았다.

$$s_x = \sqrt{5/3} \approx 1.2910, \quad s_y = \sqrt{8/3} \approx 1.6330.$$

표본 Pearson 상관계수 r 는 다음과 같다.

$$r = \frac{s_{xy}}{s_x s_y} = \frac{2}{\sqrt{5/3}\sqrt{8/3}} = \frac{6}{\sqrt{5 \times 8}} \approx 0.9487.$$

해석: 이 네 쌍에서는 강한 양의 선형관계가 나타난다. $r = 0.9487$ 은 "94.87%의 관측이 맞는다", "94.87%의 원인을 설명한다", "기울기가 0.9487이다"라는 뜻이 아니다.

분모에서 단위가 상쇄되므로 r 에는 단위가 없다. 두 표준편차가 모두 양수일 때 $-1 \leq r \leq 1$ 이다. 한 변수가 모든 관측에서 같은 값이면 표준편차가 0이 되어 이 상관계수는 정의되지 않는다.

상관계수	기본 해석	주의할 점
$r > 0$	양의 선형 경향	인과 방향을 알려주지 않음
$r < 0$	음의 선형 경향	관계가 약하다는 뜻이 아님
$ r $ 가 1에 가까움	직선에 가까운 경향	이상점·표본 크기·맥락도 확인
$r = 0$	표본의 선형 동행이 상쇄됨	관계 자체가 없다는 뜻은 아님
$r = 1$ 또는 -1	모든 점이 양·음의 기울기의 직선 위	두 변수 모두 변동이 있어야 함

방향은 부호, 선형관계의 강도는 절댓값

실제 점의 모양을 함께 확인한다 · 합성 자료




그림 6. 방향은 부호로, 직선 주변에 모이는 정도는 절댓값으로 읽는다. "강함"의 보편적인 경계값이 있는 것은 아니며, 이 자료의 맥락에서 해석해야 한다.

풀이 예제 4: 분을 초로 바꾸어도 상관은 같은가?

풀이 예제 2의 자료를 시간 측정의 합성 예로 생각하고 $Y^* = 60Y$ 로 바꾸자.

1. 새 공분산: $s_{x,y^*} = 60 \times 2 = 120$.

2. 새 표준편차: $s_{y^*} = 60s_y$.
3. 상관계수에서 60이 약분된다.

$$r_{X,Y^*} = \frac{60s_{xy}}{s_x(60s_y)} = r_{X,Y} \approx 0.9487.$$

양의 단위 변환과 평행이동은 상관을 바꾸지 않는다. 반면 $Y^* = -Y$ 처럼 방향을 뒤집으면 부호가 반대가 된다. “어떤 변환을 해도 상관은 불변”이라고 외우면 안 된다. 제곱·로그 같은 비선형 변환도 일반적으로 상관을 바꾼다.

직접 확인 E3. 같은 자료의 Y 에 100을 더하면 공분산과 상관계수는 어떻게 되는가? Y 에 -1 을 곱하는 경우와 비교하라.

7. 숫자가 0이어도 관계는 남아 있을 수 있다

교재는 비선형 관계가 있는데 상관계수는 0인 예를 제시한다. 원리를 더 쉽게 계산하기 위해 아래의 작은 합성 자료를 사용한다.

X	-2	-1	0	1	2
$Y = X^2$	4	1	0	1	4

이때 $\bar{x} = 0$, $\bar{y} = 2$ 이다. 편차 곱은 순서대로 $-4, 1, 0, -1, 4$ 이며 합은 0이다. 따라서 $s_{xy} = 0$, $r = 0$ 이다. 하지만 X 를 알면 $Y = X^2$ 로 정확히 알 수 있다.

$r = 0$ 이어도 관계가 없다는 뜻은 아니다

$Y = X^2$ · 편차 곱의 합 = $-4 + 1 + 0 - 1 + 4 = 0$




그림 7. 왼쪽 구간에서는 X 가 증가할 때 Y 가 감소하고, 오른쪽에서는 증가한다. 두 방향이 상쇄된 결과가 상관 0이다. 교재 그림 3.2의 핵심을 별도의 작은 자료로 재구성했다.

직접 확인 E4. 이 자료에서 “ $r = 0$ 이므로 X 를 알아도 Y 예측에 도움이 없다”라는 주장이 틀린 이유를 한 문장으로 설명하라.

거의 같은 상관계수, 전혀 다른 네 그림

거의 같은 상관계수, 서로 다른 네 그림

R datasets::anscombe · 각 11개 관측 · 같은 축 범위




그림 8. R 내장 `anscombe`의 실제 수치로 다시 그린 네 산점도다. 상관계수는 모두 약 0.816이지만, 첫째는 비교적 선형이고 둘째는 곡선이며 셋째와 넷째는 특정 점의 영향이 크다. 교재 그림 3.3과 같은 통계적 사실을 독립적인 배치와 표시로 시각화했다.

상관계수는 많은 점을 하나의 숫자로 압축한다. 그 과정에서 형태·이상점·집단 구조 같은 정보를 잃는다. **상관을 계산하기 전에 산점도, 계산한 뒤에도 산점도를 확인한다.**

8. 실제 사례: 컴퓨터 수리시간 14건

주교재 3.3은 컴퓨터를 판매·수리하는 회사의 수리기록을 다룬다. 반응변수 `Minutes`는 수리시간(분), 예측변수 `Units`는 교체·수리가 필요한 부품 수(개)다. 다음은 교재 표 3.4의 수치이며, 기존 수업 데이터 파일과 대조했다.

관측	Units	Minutes	관측	Units	Minutes
1	1	23	8	6	97
2	2	29	9	7	109
3	3	49	10	8	119
4	4	64	11	9	149
5	4	74	12	9	145

관측	Units	Minutes	관측	Units	Minutes
6	5	87	13	10	154
7	6	96	14	10	166

컴퓨터 수리시간: 부품 수가 많으면 시간이 긴가?

주교재 3.3 · 14건 · 표본 공분산 136, 상관계수 0.9937




그림 9. 오른쪽 위로 매우 뚜렷하게 증가한다. 같은 부품 수에서도 시간이 조금씩 달라 완전한 직선은 아니다. 교재 그림 3.4의 데이터를 직접 다시 그렸다.

풀이 예제 5: 표 전체를 공식과 연결한다

1단계. 데이터의 개수와 합

$$n = 14, \quad \sum x_i = 84, \quad \sum y_i = 1361.$$

2단계. 평균

$$\bar{x} = 84/14 = 6, \quad \bar{y} = 1361/14 \approx 97.2143.$$

3단계. 행 하나를 먼저 이해한다. 첫 수리 건 (1, 23)의 편차는 $1 - 6 = -5$, $23 - 97.2143 = -74.2143$ 이다. 두 변수 모두 평균보다 작으므로 편차 곱은 양수다.

$$(-5)(-74.2143) \approx 371.0714.$$

부품이 6개인 관측에서는 $x_i - \bar{x} = 0$ 이므로 편차 곱이 0이다. 그 관측이 불필요한 자료라는 뜻은 아니다. 공분산의 해당 항만 0인 것이다.

4단계. 14개 행을 합한다. 중간값을 반올림하지 않고 계산하면 다음 값을 얻는다.

$$S_{xx} = 114, \quad S_{yy} \approx 27768.3571, \quad S_{xy} = 1768.$$

5단계. 공분산과 상관계수

$$s_{xy} = \frac{1768}{13} = 136 \text{ 개·분}, \quad r = \frac{1768}{\sqrt{114 \times 27768.3571}} \approx 0.9937.$$

6단계. 말로 해석한다. “이 14건에서는 부품 수와 수리시간 사이에 매우 강한 양의 선형관계가 관찰된다.” 표본이 작고 한 회사의 기록이므로 모든 회사·모든 수리 상황에 같은 관계가 그대로 적용된다고 단정하지 않는다.

상관 0.9937은 강한 관계를 보여주지만, 여전히 ‘부품 7개면 몇 분인가?’라는 질문의 단위 있는 답은 아니다. 예측에는 관계를 수식으로 표현하는 추가 단계가 필요하다.

9. 회귀분석을 배우는 이유: 평균에서 조건부 예측으로

아무 정보가 없다면 모든 수리에 전체 평균인 약 97.2분을 배정하는 방법을 생각할 수 있다. 하지만 부품 1개인 수리와 10개인 수리에 같은 시간을 배정하는 것이 적절할까?

관계를 요약하는 숫자에서, 시간을 예측하는 규칙으로

빨간 세로선: 실제-예측 · 오른쪽은 설명용 후보이며 추정 결과가 아님





그림 10. 왼쪽은 부품 수를 사용하지 않은 평균 예측이다. 오른쪽은 설명을 위해 제안한 후보 규칙 $\hat{Y} = 5 + 15X$ 다. 이 규칙은 이번 예시에서 비교하기 위해 정한 것이며, 최적이라고 추정한 결과가 아니다. 실제 점과 예측선 사이의 세로 차이에 주목한다.

풀이 예제 6: 후보 예측 규칙을 실제 관측과 비교한다

후보 규칙을 “기본 준비시간 5분에 부품당 15분을 더한다”라고 읽어보자.

$$\hat{Y} = 5 + 15X.$$

$\hat{Y}$ 는 실제 시간이 아니라 **예측값**이다. 5의 단위는 분, 15의 단위는 분/개다. 이 해석은 후보 규칙의 산술적 의미이며 실제 작업의 고정시간·부품당 시간이 확인됐다는 뜻은 아니다.

부품 수 X	실제 시간 Y	후보 예측 $\hat{Y}$	실제-예측 $Y - \hat{Y}$
4	64	$5 + 15 \times 4 = 65$	-1
4	74	65	9
9	149	$5 + 15 \times 9 = 140$	9
9	145	140	5

양의 차이는 예측보다 실제 시간이 길었다는 뜻이고, 음의 차이는 짧았다는 뜻이다. 같은 X 에는 같은 후보 예측을 주지만 실제 Y 는 서로 다르다. 다음 차시에는 데이터를 이용해 이러한 예측 직선을 어떻게 정하고 차이를 어떻게 평가하는지 배운다.

직접 확인 E5. 후보 규칙으로 부품 7개의 시간을 계산하라. 그 값이 미래의 모든 수리에서 반드시 맞다고 말할 수 없는 이유도 쓰라.

상관과 회귀의 역할을 구분하기

비교	상관계수	회귀분석
기본 질문	두 변수의 선형관계는 어느 방향·정도인가?	X 를 알 때 Y 를 어떻게 설명·예측할까?
변수 역할	$r_{XY} = r_{YX}$ 로 대칭적	예측변수와 반응변수의 역할을 정함
결과 단위	없음	시간 예측이라면 분처럼 반응변수 단위
주의	숫자 하나가 형태를 모두 담지 못함	모형 가정·불확실성·적용 범위를 확인해야 함

수리시간으로 부품 수를 역으로 예측하는 문제는 다른 예측 문제다. X, Y 를 바꾸어도 상관계수는 같지만, 회귀 문제의 목표까지 같아지는 것은 아니다.

10. 두 가지 경고: 이상점과 인과관계

점 하나가 상관계수를 크게 바꿀 수 있다

합성 자료 · 이상점을 보았다고 임의로 삭제하지 않는다






그림 11. 합성 자료의 점 하나가 전체 상관을 크게 바꿀 수 있다. 상관을 원하는 방향으로 만들기 위해 점을 임의로 삭제하면 안 된다. 입력 오류인지, 다른 조건의 관측인지, 중요한 실제 사례인지 먼저 조사한다.

함께 변한다 ≠ 한 변수가 다른 변수를 일으킨다

가상의 설명 도식 · 실제 인과효과를 추정할 자료가 아님



두 결과의 동행만으로 직접적인 인과효과를 결론내릴 수 없다.

그림 12. 인과 오해를 설명하기 위한 가상의 개념도다. 아이스크림 판매와 물놀이 인구가 함께 늘었다고 판매가 물놀이를 유발했다고 결론 내릴 수 없다. 날씨 같은 공통 원인이 있을 수 있다. 이 도식은 실제 자료에서 인과효과를 추정한 결과가 아니다.

직접 확인 E6. 공부시간과 시험점수의 상관관계가 양수라는 관찰만으로 “누구나 공부시간을 1시간 늘리면 점수가 정확히 일정량 오른다”고 말할 수 있는가? 기초학력·학습방법 같은 다른 요인도 고려하라.

11. 짧은 R 확인: 손으로 이해한 계산을 실행한다

다음 코드는 기본 R만 사용한다. x , y 는 같은 길이의 숫자 벡터이며 같은 위치의 원소가 관측 쌍이다.

`plot(x,y)`의 첫 인자는 가로축, 두 번째는 세로축이다. `cov()`와 `cor()`는 각각 공분산과 Pearson 상관관계수 하나를 반환한다.

```
x <- c(1, 2, 3, 4)
y <- c(2, 4, 4, 6)
plot(x, y, pch = 19, xlab = "X", ylab = "Y")
abline(v = mean(x), h = mean(y), lty = 2)
cov(x, y)
cor(x, y)
```

위 코드는 풀이 예제의 확인용이다. 예상 출력은 공분산 2, 상관관계수 약 0.9487이다. **별도 학생 실습**에서는 단위 변환·빈칸 채우기·오류 수정·실제 수리 데이터·앱 입력 변경을 직접 해본다. 실습 파일에는 필요한 데이터와 공통 함수가 포함되므로 데이터 다운로드나 패키지 설치부터 시작하지 않는다.

NA가 있으면 기본 `cov()`·`cor()` 결과도 NA가 될 수 있다. 이번 자료에는 결측이 없다. 실제 자료에서 결측을 발견하면 원인을 확인하고 같은 관측 쌍을 일관되게 처리해야 한다. 서로 다른 행을 따로 제거해 엉뚱한 쌍을 만들지 않는다.

앱에서 확인할 것: 단위를 분에서 초로 바꾸기, 실제 자료와 곡선 자료 비교하기, 평균선 표시 바꾸기. 입력 → 데이터 변환 → 공통 계산 함수 → 표·산점도의 순서를 찾아본다. 공통 함수는 이미 만들어진 계산 절차를 재사용하는 것이며 모델 학습을 수행하지 않는다.

12. 점검 퀴즈

다음 질문은 먼저 스스로 답한 뒤 별도 퀴즈 해설로 확인한다.

1. 산점도에서 한 점은 무엇을 나타내는가?
2. 두 변수가 모두 평균보다 작은 관측의 편차 곱은 왜 양수인가?
3. 공분산이 양수이면 그 값이 회귀직선의 기울기를 뜻하는가?
4. 시간을 분에서 초로 바꾸면 공분산과 상관계수는 각각 어떻게 달라지는가?
5. 상관계수가 0이어도 두 변수 사이에 관계가 있을 수 있는가?
6. 상관계수가 거의 같더라도 산점도를 따로 살펴야 하는 이유는 무엇인가?
7. 한 변수의 모든 값이 같을 때 Pearson 상관계수는 정의되는가?
8. 수리시간 사례에서 상관계수만으로 부품 7개의 수리시간을 바로 예측할 수 있는가?

참고자료와 그림 안내

- Ali S. Hadi-Samprit Chatterjee, 『Chatterjee 예제를 통한 회귀분석 제6판: R 활용』, 자유아카데미, 2024, 3.2–3.3, pp.92–100. 그림 3.1–3.4의 교육적 개념과 표 3.4의 수리시간 수치를 참고했다. 원본 스캔은 포함하지 않았다.
- 수리시간 데이터는 기존 수업의 Computer.Repair.txt를 재사용했다. 이 노트의 0.9937은 14개 관측을 반올림하지 않고 재계산한 값이다.
- [R 공식 문서: 공분산·상관계수](#): 기본 Pearson 방식과 표본 공분산의 분모.
- [R 공식 문서: Anscombe 데이터](#): 내장 데이터와 네 산점도 비교. 원출처 F. J. Anscombe (1973), “Graphs in Statistical Analysis”.
- [NIST: Scatter Plot](#): 형태·산포·이상점 탐색 및 연관성과 인과의 구분.
- 그림 1–7, 10–12의 배치·색상·예시와 풀이 예제 1–4, 6은 수업용으로 새로 설계했다. 그림 8은 R 내장 데이터, 그림 9는 교재 사례의 수치를 직접 그린 것이다. 합성 자료와 실제 사례를 구분해 표시했다.