W05B · 수학과 제약 계산 보충

본문의 질문을 행렬과 계산으로 확인하는 선택 보충입니다. 주교재 §4.6–4.11을 벗어난 새 진단 단원을 추가하지 않습니다. p는 설명변수 수, k=p+1은 절편을 포함한 계수 수, n은 관측 수입니다. X는 n×k 완전 열계수 설계행렬이고 첫 열은 1입니다.

1. 중심화의 불변성은 재매개화에서 나온다

원래 모형에 xj=xcj+평균xj를 대입하면 다음과 같습니다.

$$\beta_0 + \sum_j \beta_j x_j = \left(\beta_0 + \sum_j \beta_j \bar{x}_j\right) + \sum_j \beta_j x_j^c.$$

설명변수의 원점만 바꾸면 같은 예측함수 집합을 다른 절편으로 표현합니다. 따라서 동일한 최소 SSE와 적합값을 얻습니다. 절편을 포함하지 않는 모형에서는 이동으로 생긴 상수항을 흡수할 곳이 없으므로 이 주장을 그대로 쓰지 못합니다. X와 Y를 모두 표준화하면 원래 예측은 평균y+표준편차y×표준화 예측으로 복원합니다.

$$\hat{\beta}_j^{(z)} = \hat{\beta}_j \frac{s_j}{s_y}, \qquad \hat{\beta}_0 = \bar{y} - \sum_j \hat{\beta}_j \bar{x}_j.$$

평균과 표준편차는 학습 자료에서 계산한 값이어야 합니다. 상호작용·비선형 항을 포함할 때에는 모든 관련 항의 변환을 함께 고려해야 하며, 벌점이 있는 추정법의 척도 효과까지 이 OLS 결과로 일반화하지 않습니다.

2. 최소제곱추정량의 평균과 분산

모형 y=Xβ+ε에서 OLS 식에 대입합니다.

$$\hat{\beta} = (X^\mathsf{T}X)^{-1}X^\mathsf{T}y = \beta + (X^\mathsf{T}X)^{-1}X^\mathsf{T}\varepsilon.$$

X를 조건으로 E(ε|X)=0이면 바로 E(β̂|X)=β입니다. 오차 공분산이 σ²I이면 선형변환의 공분산 공식으로 다음을 얻습니다.

$$\mathrm{Var}(\hat{\beta} \mid X) = (X^\mathsf{T}X)^{-1}X^\mathsf{T}(\sigma^2 I)X(X^\mathsf{T}X)^{-1} = \sigma^2(X^\mathsf{T}X)^{-1}.$$

이 계산에는 정규분포를 쓰지 않았습니다. s²=SSE/(n−k)로 σ²를 추정하면 vcov(fit)가 s²(XᵀX)⁻¹을 반환하고, 대각 원소의 제곱근이 계수별 SE입니다. 오차분산 s² 하나와 계수 공분산행렬을 구별하세요.

3. BLUE의 비교 대상과 범위

다른 선형 불편추정량을 Ay라 쓰면 AX=I여야 합니다. A=(XᵀX)⁻¹Xᵀ+D라고 두면 DX=0입니다. 따라서 공분산의 차이는 다음과 같습니다.

$$\mathrm{Var}(Ay \mid X) - \mathrm{Var}(\hat{\beta} \mid X) = \sigma^2 DD^\mathsf{T} \succeq 0.$$

임의 벡터 v에 대해 vᵀDDᵀv=‖Dᵀv‖²≥0이므로 다른 선형 불편추정량의 분산을 더 작게 만들 수 없다는 결론입니다. 모든 비선형·편향 추정량까지 포함한 최적성, 예측 MSE의 절대 우월성, 개별 표본의 정확성을 주장한 정리가 아닙니다.

4. 정규성은 t와 F 분포에서 사용한다

정규오차라면 β̂는 다변량 정규분포이고, SSE/σ²는 자유도 n−k의 카이제곱분포이며 β̂와 독립입니다. 분산을 모르는 정규 추정량을 독립적인 분산 추정값으로 표준화하여 t분포를 얻습니다.

$$\frac{\hat{\beta}_j - \beta_{j,0}}{s\sqrt{[(X^\top X)^{-1}]_{jj}}} \sim t_{n-k}.$$

따라서 t검정과 계수 신뢰구간은 같은 표준오차와 자유도를 사용합니다. 이 수업의 정확한 소표본 결과를 비정규·이분산 자료에 가정 확인 없이 그대로 적용했다고 말하지 않습니다.

5. R과 R²의 연결

절편 포함 OLS의 잔차 e는 적합값 ŷ 및 상수 열과 직교합니다. y−평균y=(ŷ−평균y)+e이므로 제곱합이 더해집니다. 또한 표본 공분산의 분자는 다음과 같습니다.

$$\sum_i (y_i - \bar{y})(\hat{y}_i - \bar{y}) = \sum_i (\hat{y}_i - \bar{y})^2.$$

적합값이 비상수이면 cor(y,ŷ)=√(SSR/SST)=√R²입니다. 수정 R²는 자유도당 제곱합의 비를 1에서 뺀 지표라서 동일한 상관제곱으로 표현되지 않습니다.

6. 일반 선형가설 · Lβ=r

L은 q×k 행렬이고 각 행이 하나의 독립 제약입니다. 계수 순서는 반드시 `names(coef(fit))`와 맞춰야 합니다. 예를 들어 두 변수 모형의 순서는 절편, complaints, learning입니다.

$$F = \frac{(L\hat{\beta} - r)^\top [L\widehat{\mathrm{Var}}(\hat{\beta})L^\top]^{-1}(L\hat{\beta} - r)}{q} \sim F_{q,n-k} \quad \text{under } H_0.$$

vcov()는 이미 s²를 포함하므로 이 식에 s²를 다시 나누지 않습니다. 제약이 한 개면 이차형식은 표준화한 차이의 제곱이어서 F=t²가 됩니다.

```
fit2 <- lm(rating~complaints+learning, data=attitude)
L <- matrix(c(0,1,-1), nrow=1)
delta <- as.vector(L %*% coef(fit2))
variance <- as.numeric(L %*% vcov(fit2) %*% t(L))
F_equal <- delta^2/variance
pf(F_equal, 1, df.residual(fit2), lower.tail=FALSE)
```

β1−β3의 분산은 Var(β̂1)+Var(β̂3)−2Cov(β̂1,β̂3)입니다. 두 표준오차를 더하거나 제곱만 더하면 공분산 항을 놓칩니다. 이 자료에서 두 기울기의 추정 공분산은 약 −0.0095023입니다.

7. 동일성 제약을 축소모형으로 검산

```
equal_model <- lm(rating~I(complaints+learning), data=attitude)
anova(equal_model, fit2)
```

축소모형은 절편과 공통 기울기, 총2개 계수이고 완전모형은3개입니다. q=1, 분모 자유도27입니다. F≈3.657224, p≈0.066490으로 위 일반 선형가설과 일치합니다. 두 모형의 반응과 관측행이 같기 때문에 이 anova() 비교가 유효합니다.

8. 합 제약 · 원래 반응으로 복원하기

```
sum_model <- lm(I(rating-learning)~I(complaints-learning), data=attitude)
fitted_original_y <- fitted(sum_model)+attitude$learning
SSE_reduced <- sum((attitude$rating-fitted_original_y)^2)
F_sum <- ((SSE_reduced-deviance(fit2))/1)/
         (deviance(fit2)/df.residual(fit2))
c(F=F_sum, p=pf(F_sum,1,27,lower.tail=FALSE))
```

원래 y로 계산한 축소 SSE≈1329.547455, F≈1.611813, p≈0.215071입니다. 일반 선형가설에서는 L=(0,1,1), r=1을 사용합니다. anova(sum_model,fit2)는 반응변수가 달라 올바른 비교가 아닙니다. 소프트웨어 경고를 숨기지 말고 무엇을 비교했는지 바로잡아야 합니다.

동일성과 합을 동시에 제약할 때는 L의 두 행을 (0,1,−1), (0,1,1), r=(0,1)로 둡니다. 두 기울기는 제약 아래에서 각각0.5가 되고 절편만 추정하므로 q=2입니다. 이 동시 검정의 F≈2.3126, p≈0.1183 역시 비기각이 값의 증명이라는 뜻은 아닙니다.

9. 평균과 새 관측의 분산

새 조건 x0에서 추정 평균은 $x_0^T\hat{\beta}$입니다. 선형변환의 분산으로 평균 추정 분산 $\sigma^2 h_0$를 얻습니다. 새 부서의 오차 ε0가 학습 오차와 독립이고 같은 분산 σ^2를 갖는다면 새 관측 예측오차에 그 분산이 추가됩니다.

$$\mathbf{Var}(\hat{y}_0 \mid X) = \sigma^2 h_0, \qquad \mathbf{Var}(y_0 - \hat{y}_0 \mid X) = \sigma^2(1 + h_0).$$

평균 조건에서는 절편 포함 OLS의 h0=1/n입니다. 두 변수 모형의 n=30, s≈6.816779, $t_{0.975,27}$≈2.05183을 넣으면 평균 CI 폭≈5.107285, 새 관측 PI 폭≈28.436159입니다. 관측 단위는 부서이며 새 직원 개인의 응답 범위가 아닙니다.

```
x0 <- c(1, mean(attitude$complaints), mean(attitude$learning))
X <- model.matrix(fit2)
h0 <- as.numeric(t(x0) %*% solve(crossprod(X), x0))
c(h0=h0, mean_SE=sigma(fit2)*sqrt(h0), new_SE=sigma(fit2)*sqrt(1+h0))
```

이 역행렬 표현은 작은 예에서 이론을 검산하기 위한 것입니다. 일반 회귀 적합은 lm()의 수치 알고리즘을 사용합니다. 신뢰수준·오차분산·설계 위치가 구간 폭에 각각 어떤 역할을 하는지 분리해서 읽으세요.

참고자료

주교재 §4.6–4.11의 식과 제약 사례를 R 내장 attitude로 검산했습니다. R vcov, anova.lm, predict.lm, 2026-09-29 확인. 재매개화와 가정 구분, 잘못된 반응 비교의 교정은 수업용 추가 해설입니다.