

W05B · 수학과 제약 계산 보충

본문의 질문을 행렬과 계산으로 확인하는 선택 보충입니다. 주교재 §4.6–4.11을 벗어난 새 진단 단원을 추가하지 않습니다. p 는 설명변수 수, $k=p+1$ 은 절편을 포함한 계수 수, n 은 관측 수입니다. X 는 $n \times k$ 완전 열계수 설계행렬이고 첫 열은 1입니다.

1. 중심화의 불변성은 재매개화에서 나온다

원래 모형에 $x_j = \bar{x}_j + (x_j - \bar{x}_j)$ 를 대입하면 다음과 같습니다.

$$\beta_0 + \sum_j \beta_j x_j = \left(\beta_0 + \sum_j \beta_j \bar{x}_j \right) + \sum_j \beta_j (x_j - \bar{x}_j).$$

설명변수의 원점만 바꾸면 같은 예측함수 집합을 다른 절편으로 표현합니다. 따라서 동일한 최소 SSE와 적합값을 얻습니다. 절편을 포함하지 않는 모형에서는 이동으로 생긴 상수항을 흡수할 곳이 없으므로 이 주장을 그대로 쓰지 못합니다. X 와 y 를 모두 표준화하면 원래 예측은 $\bar{y} + \text{표준편차}_y \times \text{표준화 예측}$ 으로 복원합니다.

$$\hat{\beta}_j^{(z)} = \hat{\beta}_j \frac{s_j}{s_y}, \quad \hat{\beta}_0 = \bar{y} - \sum_j \hat{\beta}_j \bar{x}_j.$$

평균과 표준편차는 학습 자료에서 계산한 값이어야 합니다. 상호작용·비선형 항을 포함할 때에는 모든 관련 항의 변환을 함께 고려해야 하며, 벌점이 있는 추정법의 척도 효과까지 이 OLS 결과로 일반화하지 않습니다.

2. 최소제곱추정량의 평균과 분산

모형 $y = X\beta + \epsilon$ 에서 OLS 식에 대입합니다.

$$\hat{\beta} = (X^T X)^{-1} X^T y = \beta + (X^T X)^{-1} X^T \epsilon.$$

X 를 조건으로 $E(\epsilon|X)=0$ 이면 바로 $E(\hat{\beta}|X)=\beta$ 입니다. 오차 공분산이 $\sigma^2 I$ 이면 선형변환의 공분산 공식으로 다음을 얻습니다.

$$\text{Var}(\hat{\beta} | X) = (X^T X)^{-1} X^T (\sigma^2 I) X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}.$$

이 계산에는 정규분포를 쓰지 않았습니다. $s^2 = \text{SSE}/(n-k)$ 로 σ^2 를 추정하면 $\text{vcov}(\text{fit})$ 가 $s^2(X^T X)^{-1}$ 을 반환하고, 대각 원소의 제곱근이 계수별 SE입니다. 오차분산 s^2 하나와 계수 공분산행렬을 구별하세요.

3. BLUE의 비교 대상과 범위

다른 선형 불편추정량을 Ay 라 쓰면 $AX=I$ 여야 합니다. $A=(X^T X)^{-1} X^T + D$ 라고 두면 $DX=0$ 입니다. 따라서 공분산의 차이는 다음과 같습니다.

$$\text{Var}(Ay | X) - \text{Var}(\hat{\beta} | X) = \sigma^2 D D^T \succeq 0.$$

임의 벡터 v 에 대해 $v^T D D^T v = \|D^T v\|^2 \geq 0$ 이므로 다른 선형 불편추정량의 분산을 더 작게 만들 수 없다는 결론입니다. 모든 비선형·편향 추정량까지 포함한 최적성, 예측 MSE의 절대 우월성, 개별 표본의 정확성을 주장한 정리가 아닙니다.

4. 정규성은 t와 F 분포에서 사용한다

정규오차라면 $\hat{\beta}$ 는 다변량 정규분포이고, SSE/σ^2 는 자유도 $n-k$ 의 카이제곱분포이며 $\hat{\beta}$ 와 독립입니다. 분산을 모르는 정규 추정량을 독립적인 분산 추정값으로 표준화하여 t분포를 얻습니다.

$$\frac{\hat{\beta}_j - \beta_{j,0}}{s\sqrt{[(X^T X)^{-1}]_{jj}}} \sim t_{n-k}.$$

따라서 t검정과 계수 신뢰구간은 같은 표준오차와 자유도를 사용합니다. 이 수업의 정확한 소표본 결과를 비정규·이분산 자료에 가정 확인 없이 그대로 적용했다고 말하지 않습니다.

5. R과 R²의 연결

절편 포함 OLS의 잔차 e 는 적합값 $\hat{y}$ 및 상수 열과 직교합니다. $y - \text{평균}y = (\hat{y} - \text{평균}y) + e$ 이므로 제곱합이 더해집니다. 또한 표본 공분산의 분자는 다음과 같습니다.

$$\sum_i (y_i - \bar{y})(\hat{y}_i - \bar{y}) = \sum_i (\hat{y}_i - \bar{y})^2.$$

적합값이 비상수이면 $\text{cor}(y, \hat{y}) = \sqrt{SSR/SST} = \sqrt{R^2}$ 입니다. 수정 R^2 는 자유도당 제곱합의 비를 1에서 뺀 지표로서 동일한 상관제곱으로 표현되지 않습니다.

6. 일반 선형가설 · $L\beta = r$

L 은 $q \times k$ 행렬이고 각 행이 하나의 독립 제약입니다. 계수 순서는 반드시 `names(coef(fit))`와 맞춰야 합니다. 예를 들어 두 변수 모형의 순서는 절편, complaints, learning입니다.

$$F = \frac{(L\hat{\beta} - r)^T [L\widehat{\text{Var}}(\hat{\beta})L^T]^{-1} (L\hat{\beta} - r)}{q} \sim F_{q, n-k} \quad \text{under } H_0.$$

`vcov()`는 이미 s^2 를 포함하므로 이 식에 s^2 를 다시 나누지 않습니다. 제약이 한 개면 이차형식은 표준화한 차이의 제곱이어서 $F=t^2$ 가 됩니다.

```
fit2 <- lm(rating~complaints+learning, data=attitude)
L <- matrix(c(0,1,-1), nrow=1)
delta <- as.vector(L %*% coef(fit2))
variance <- as.numeric(L %*% vcov(fit2) %*% t(L))
F_equal <- delta^2/variance
pf(F_equal, 1, df.residual(fit2), lower.tail=FALSE)
```

$\beta_1 - \beta_3$ 의 분산은 $\text{Var}(\hat{\beta}_1) + \text{Var}(\hat{\beta}_3) - 2\text{Cov}(\hat{\beta}_1, \hat{\beta}_3)$ 입니다. 두 표준오차를 더하거나 제곱만 더하면 공분산 항을 놓칩니다. 이 자료에서 두 기울기의 추정 공분산은 약 -0.0095023 입니다.

7. 동일성 제약을 축소모형으로 검산

```
equal_model <- lm(rating~l(complaints+learning), data=attitude)
anova(equal_model, fit2)
```

축소모형은 절편과 공통 기울기, 총2개 계수이고 완전모형은3개입니다. $q=1$, 분모 자유도27입니다. $F \approx 3.657224$, $p \approx 0.066490$ 으로 위 일반 선형가설과 일치합니다. 두 모형의 반응과 관측행이 같기 때문에 이 `anova()` 비교가 유효합니다.

8. 합 제약 · 원래 반응으로 복원하기

```
sum_model <- lm(l(rating-learning)~l(complaints-learning), data=attitude)
fitted_original_y <- fitted(sum_model)+attitude$learning
SSE_reduced <- sum((attitude$rating-fitted_original_y)^2)
F_sum <- ((SSE_reduced-deviance(fit2))/1)/
          (deviance(fit2)/df.residual(fit2))
c(F=F_sum, p=pf(F_sum,1,27,lower.tail=FALSE))
```

원래 y 로 계산한 축소 $SSE \approx 1329.547455$, $F \approx 1.611813$, $p \approx 0.215071$ 입니다. 일반 선형가설에서는 $L=(0,1,1)$, $r=1$ 을 사용합니다. `anova(sum_model, fit2)`는 반응변수가 달라 올바른 비교가 아닙니다. 소프트웨어 경고를 숨기지 말고 무엇을 비교했는지 바로잡아야 합니다.

동일성과 합을 동시에 제약할 때는 L 의 두 행을 $(0,1,-1)$, $(0,1,1)$, $r=(0,1)$ 로 둡니다. 두 기울기는 제약 아래에서 각각0.5가 되고 절편만 추정하므로 $q=2$ 입니다. 이 동시 검정의 $F \approx 2.3126$, $p \approx 0.1183$ 역시 비기각이 값의 증명이라는 뜻은 아닙니다.

9. 평균과 새 관측의 분산

새 조건 x_0 에서 추정 평균은 $x_0^T \hat{\beta}$ 입니다. 선형변환의 분산으로 평균 추정 분산 $\sigma^2 h_0$ 를 얻습니다. 새 부서의 오차 ϵ_0 가 학습 오차와 독립이고 같은 분산 σ^2 를 갖는다면 새 관측 예측오차에 그 분산이 추가됩니다.

$$\text{Var}(\hat{y}_0 | X) = \sigma^2 h_0, \quad \text{Var}(y_0 - \hat{y}_0 | X) = \sigma^2(1 + h_0).$$

평균 조건에서는 절편 포함 OLS의 $h_0=1/n$ 입니다. 두 변수 모형의 $n=30$, $s \approx 6.816779$, $t_{0.975,27} \approx 2.05183$ 을 넣으면 평균 CI 폭 ≈ 5.107285 , 새 관측 PI 폭 ≈ 28.436159 입니다. 관측 단위는 부서이며 새 직원 개인의 응답 범위가 아닙니다.

```
x0 <- c(1, mean(attitude$complaints), mean(attitude$learning))
X <- model.matrix(fit2)
h0 <- as.numeric(t(x0) %*% solve(crossprod(X), x0))
c(h0=h0, mean_SE=sigma(fit2)*sqrt(h0), new_SE=sigma(fit2)*sqrt(1+h0))
```

이 역행렬 표현은 작은 예에서 이론을 검산하기 위한 것입니다. 일반 회귀 적합은 `lm()`의 수치 알고리즘을 사용합니다. 신뢰수준·오차분산·설계 위치가 구간 폭에 각각 어떤 역할을 하는지 분리해서 읽으세요.

참고자료

주교재 §4.6–4.11의 식과 제약 사례를 R 내장 `attitude`로 검산했습니다. [R vcov](#), [anova.lm](#), [predict.lm](#), 2026-09-29 확인. 재매개화와 가정 구분, 잘못된 반응 비교의 교정은 수업용 추가 해설입니다.