

W06A · 잔차의 분산과 내적·외적 표준화: 수학 보충

주교재 §5.2-5.3을 이해하기 위한 선택 보충입니다. 본 수업에서는 그림과 한 부서의 계산을 먼저 공부하고, 유도는 이 노트에서 다시 확인합니다. §5.7 이후의 정규성 검정·영향력 진단 절차로 범위를 확장하지 않습니다.

1. 기호와 조건을 먼저 고정하기

n 은 관측 수, p 는 설명변수 수, $k=p+1$ 은 절편을 포함한 계수 수, $v=n-k$ 는 잔차 자유도입니다. X 는 $n \times k$ 의 완전 열계수 설계행렬입니다. 비가중 OLS, 무오프셋 모형을 사용합니다.

$$Y = X\beta + \varepsilon, \quad E(\varepsilon | X) = 0, \quad \text{Cov}(\varepsilon | X) = \sigma^2 I_n.$$

오차의 정규성은 아래 분포를 말하는 단계에서 추가합니다. 평균·공분산 계산 자체에 정규성을 미리 끼워 넣을 필요는 없습니다.

2. 잔차를 행렬로 표현하기

$$\hat{\beta} = (X^T X)^{-1} X^T Y, \quad H = X(X^T X)^{-1} X^T, \quad \hat{Y} = HY.$$

H 는 대칭이고 멱등입니다. 즉 $H^T = H$, $H^2 = H$ 이며, X 의 열공간 위로의 직교사영입니다. $HX = X$ 이므로 평균 부분은 잔차에서 사라집니다.

$$e = (I - H)Y = (I - H)X\beta + (I - H)\varepsilon = (I - H)\varepsilon.$$

따라서 잔차는 원래 오차 자체가 아니라, 적합 과정이 오차를 섞고 일부 성분을 제거한 결과입니다.

3. 잔차의 공분산 유도

$$\begin{aligned} \text{Cov}(e | X) &= (I - H) \text{Cov}(\varepsilon | X) (I - H)^T \\ &= \sigma^2 (I - H)(I - H) \\ &= \sigma^2 (I - H). \end{aligned}$$

마지막 줄은 $H^2 = H$ 를 사용합니다. 대각원소와 비대각원소를 따로 읽으면 다음을 얻습니다.

$$\text{Var}(e_i | X) = \sigma^2(1 - h_{ii}), \quad \text{Cov}(e_i, e_j | X) = -\sigma^2 h_{ij} \quad (i \neq j).$$

따라서 오차가 독립이어도 잔차는 일반적으로 독립이 아닙니다. 잔차 표준편차에 지레값 보정이 필요한 이유도 대각원소에 나타납니다. '지레값이 크면 오차 분산이 작다'가 아니라 '같은 오차 분산 아래 잔차 분산이 작다'입니다.

4. 잔차합0의 정확한 근거

OLS 정상방정식은 $X^T e = 0$ 을 줍니다. X 에 모두 1인 절편 열이 있으면 그 열과 잔차의 내적이 0이므로 잔차합이 0입니다.

$$X^T e = 0 \implies \sum_i e_i = 0 \quad (\text{절편 열이 있을 때}).$$

이는 모형을 적합한 뒤의 대수적 성질입니다. $E(\epsilon|X)=0$ 은 여러 가능한 표본을 생성하는 과정에 대한 조건부 평균 가정입니다. 둘은 논리적으로 같은 명제가 아닙니다. 절편 없는 모형에서 잔차합0을 무조건 요구하는 것도 잘못입니다.

5. 보통·참 규모·내적 표준화

$$s^2 = \frac{e^T e}{\nu}, \quad z_i = \frac{e_i}{\sigma \sqrt{1 - h_{ii}}}, \quad r_i = \frac{e_i}{s \sqrt{1 - h_{ii}}}.$$

참 σ 를 사용하는 z 는 위 평균·분산 조건에서 평균0, 분산1을 가집니다. 조건부 정규오차까지 가정하면 각 z_i 는 표준정규입니다. 그러나 z 들의 상호 독립성이 따라오는 것은 아닙니다. 실제 분석에서는 σ 가 알려져 있지 않으므로 s 를 쓴 내적 표준화잔차를 계산합니다.

내적 r 은 분자 e_i 와 분모 s 가 같은 자료를 공유합니다. 따라서 단순히 '정규를 추정 표준편차로 나누었으니 자유도 ν 의 t '라고 말하면 안 됩니다. 독립성 조건이 빠져 있습니다.

6. 한 관측을 제외한 분산

$h_{ii} < 1$ 이고 삭제 후 모형도 필요한 계수와 양의 잔차분산을 유지할 때 다음 항등식이 성립합니다.

$$SSE_{(i)} = SSE - \frac{e_i^2}{1 - h_{ii}}, \quad s_{(i)}^2 = \frac{SSE_{(i)}}{\nu - 1}.$$

관측 수가 하나 줄었으므로 자유도도 ν 에서 $\nu-1$ 로 줄어듭니다. SSE에서 단순히 e_i^2 만 빼지 않는 이유는 나머지 관측에 적합하는 계수도 달라지기 때문입니다. 지레값 향이 그 재적합 효과를 반영합니다.

$$r_i^* = \frac{e_i}{s_{(i)} \sqrt{1 - h_{ii}}}.$$

분자는 전체 자료의 e_i 입니다. 삭제 후 모형의 예측을 분자에 쓰는 양은 다음의 삭제예측잔차입니다.

$$e_{i,\text{pred}} = y_i - \hat{y}_{i,(-i)} = \frac{e_i}{1 - h_{ii}}.$$

외적 표준화의 정의와 혼합하지 마세요. 두 값은 서로 다른 질문에 답합니다.

7. 내적과 외적 값의 변환

$e_i^2/(1-h_{ii})=r_i^2 s^2$, $SSE=vs^2$ 를 대입합니다.

$$s_{(i)}^2 = s^2 \frac{\nu - r_i^2}{\nu - 1}.$$

따라서 양의 분모 범위에서 교재 식 5.15를 얻습니다.

$$r_i^* = r_i \sqrt{\frac{\nu - 1}{\nu - r_i^2}} = r_i \sqrt{\frac{n - p - 2}{n - p - 1 - r_i^2}}.$$

조건부 정규오차, 완전 열계수, $h_{ii} < 1$ 등 필요한 조건 아래 외적 표준화잔차의 주변분포는 $t_{(\nu-1)}$ 입니다. 이 사례의 자유도는 26입니다. t 분포를 표준정규와 완전히 같거나 정확히 분산1이라고 말하지 않습니다. 자유도 26의 분산은 26/24이며, 여러 관측의 외적 잔차가 서로 독립이라는 뜻도 아닙니다.

8. R로 세 경로 검산하기

```
fit <- lm(rating~complaints+learning,data=attitude)
e <- residuals(fit); h <- hatvalues(fit); nu <- df.residual(fit)
r <- e/(sigma(fit)*sqrt(1-h))
t_from_r <- r*sqrt((nu-1)/(nu-r^2))
stopifnot(max(abs(r-rstandard(fit)))<1e-10)
stopifnot(max(abs(t_from_r-rstudent(fit)))<1e-10)
i <- 1
minus_i <- lm(rating~complaints+learning,data=attitude[-i,])
t_refit <- e[i]/(sigma(minus_i)*sqrt(1-h[i]))
c(transform=t_from_r[i],refit=t_refit,R=rstudent(fit)[i])
```

직접 식, 삭제 후 재적합, R 기본 함수가 일치해야 합니다. 출력의 미세한 차이는 부동소수점 계산 오차 범위에
서 비교합니다. 함수의 결과가 맞다는 사실과 모형의 현실 적합성은 별도로 판단합니다.

9. 그림 선택으로 돌아오기

이 유도의 목적은 행렬 계산을 더 많이 하는 데 있지 않습니다. 보통잔차 크기를 비교할 때 왜 관측별 비교 기
준이 달라지는지, 외적 표준화에서 왜 분모 추정만 바뀌는지 설명하기 위한 근거입니다. $h=1$ 이나 분산0처럼
공식이 성립하지 않는 경우도 결과의 일부로 정직하게 표시합니다.

근거: 주교재 §5.3 및 [R 공식 진단 함수 설명](#). 조건부 행렬 유도과 세 경로 검산은 추가 해설입니다.