W06A B · 같은 잔차를 왜 여러 방식으로 표현하는가?

회귀분석의 이해 · 2026년 10월 5일 · 주교재 §5.3(pp.191–194)

A: 가정 · C: 그래프 · 수학 보충 · R Colab A

1. 같은 한 부서에서 시작하기

R의 attitude는 30개 부서의 설문 집계 자료입니다. 부서별 약35명의 응답을 집계한 긍정 응답 비율(%)이며, 한 행은 직원 한 명이 아니라 **부서 하나**입니다. 지난 W05B와 같은 `rating ~ complaints + learning` 모형을 사용합니다. 행번호1은 시간1이나 첫 조사 시점이라는 뜻이 아닙니다.

```
d <- datasets::attitude
fit <- lm(rating ~ complaints + learning, data=d)
c(observed=d$rating[1], fitted=fitted(fit)[1], residual=residuals(fit)[1])
```

첫 부서의 관측 rating은43%, 적합값은약50.926760%입니다. 따라서 보통잔차는 약−7.926760퍼센트포인트입니다. 음수는 이 부서의 관측값이 모형 적합값보다 낮다는 뜻이지, 부서 자체가 잘못되었다는 뜻이 아닙니다.

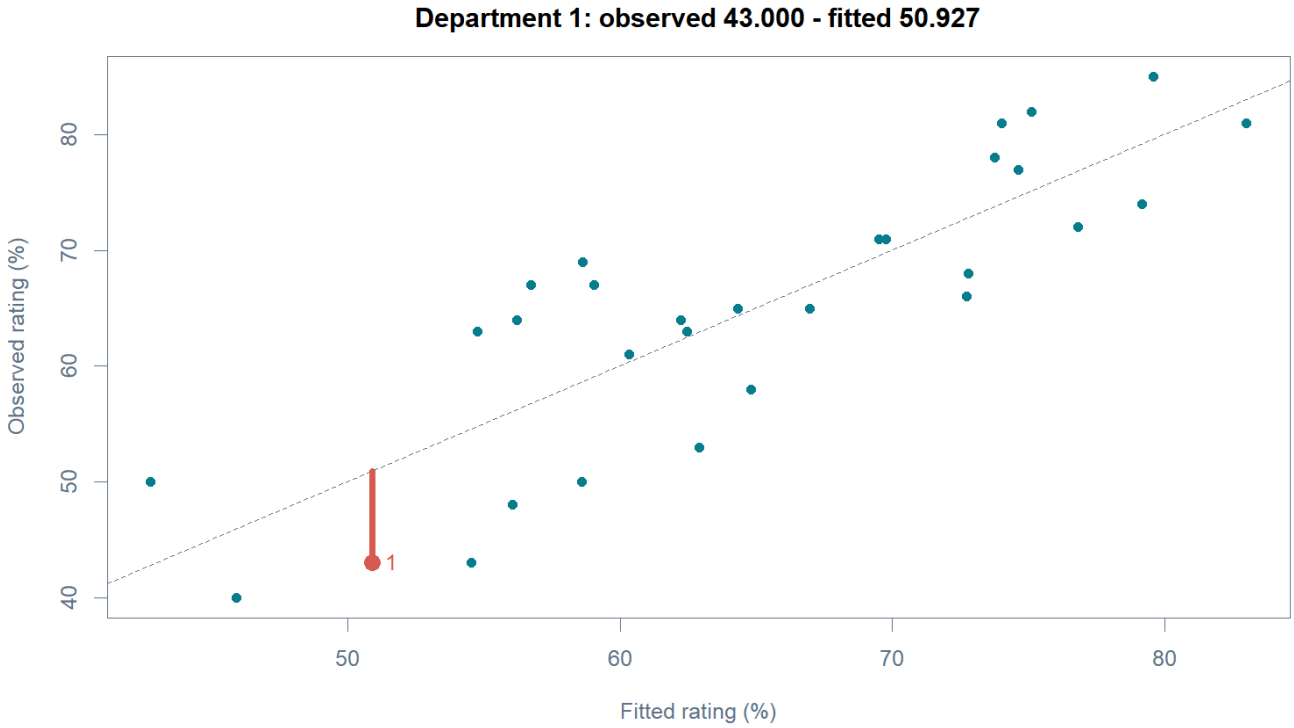


그림 B1. 가로축이 원래 설명변수 하나가 아니라 적합값임을 먼저 확인하세요. 회색 대각선 위에서는 관측값과 적합값이 같습니다. 강조된 수직 선분을 아래로 따라가면 부서1의 음의 잔차를 읽을 수 있습니다.

$$e_1 = 43 - 50.926760 = -7.926760.$$

2. 같은 절댓값이면 같은 정도로 큰 잔차일까요?

오차 분산이 모든 관측에서 σ²로 같아도, 잔차의 분산은 관측마다 같지 않습니다. 잔차를 구할 때 그 점 자신도 회귀식 적합에 참여했기 때문입니다. 지레값 h_{ii}는 여기서 **잔차 분산을 보정하는 양**으로 사용합니다. 영향 관측을 판별하는 상세 절차는 이번 범위를 넘어가므로 다루지 않습니다.

$$\mathrm{Var}(e_i \mid X) = \sigma^2(1 - h_{ii}).$$

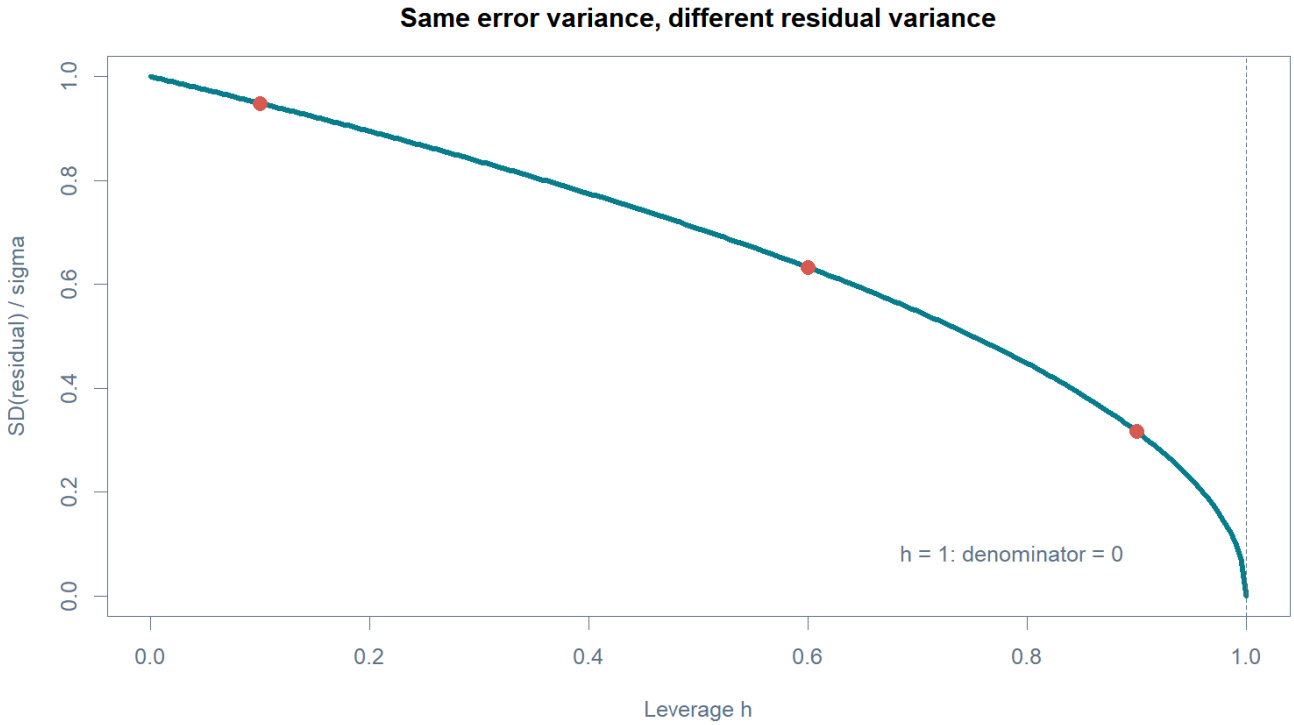


그림 B2. 세로축은 잔차 표준편차를 σ로 나눈 값입니다. h가0.1, 0.6, 0.9일 때 같은 원잔차의 비교 기준이 다릅니다. 지레값이 크다는 사실만으로 잘못된 관측이나 큰 잔차라고 결론낼 수 없습니다.

간단한 비교를 해봅시다. 두 점의 보통잔차가 모두2이고 s=2라고 가정합니다. h=0.1인 점의 내적 표준화잔차는 약1.054, h=0.6인 점은 약1.581입니다. 분자가 같아도 두 번째 점의 비교 기준인 분모가 더 작기 때문입니다. 이 숫자는 이해를 위한 가상 비교이며 attitude의 두 실제 부서를 뜻하지 않습니다.

E4 · 분모 읽기. h가 커질수록 위 가상 비교의 표준화잔차 절댓값이 커지는 이유를 식의 분모로 설명하세요. 이것만으로 해당 점을 삭제해야 하나요?

3. 교재의 용어와 R 함수 정확히 대응시키기

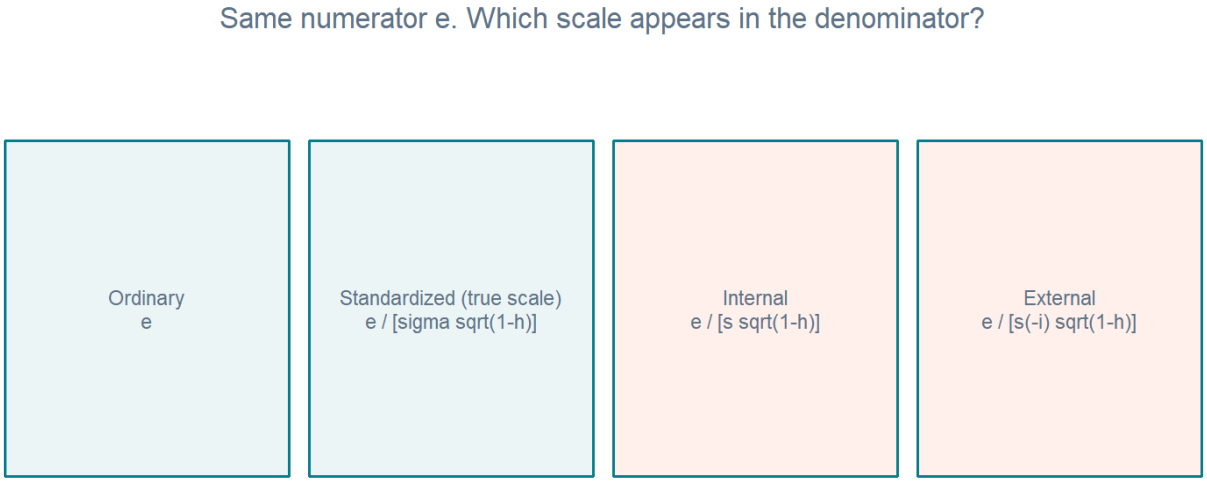


그림 B3. 모든 표현의 출발점은 같은 보통잔차 e입니다. 두 번째 상자는 참 σ를 알고 있을 때, 세 번째는 전체 자료로 추정한 s, 네 번째는 해당 관측을 제외해 추정한 $s_{(i)}$를 사용합니다. 실제 자료에서는 참 σ를 모르므로 추정한 규모를 사용합니다.

$$z_i = \frac{e_i}{\sigma\sqrt{1-h_{ii}}}, \qquad r_i = \frac{e_i}{s\sqrt{1-h_{ii}}}, \qquad r_i^* = \frac{e_i}{s_{(i)}\sqrt{1-h_{ii}}}.$$

교재 표현	오차 규모의 기준	R 대응	단위
보통잔차 e	나누지 않음	`residuals(fit)`	Y의 차이 단위
표준화잔차 z	참 σ	σ를 알고 직접 계산	없음
내적 표준화잔차 r	전체 관측으로 추정한 s	`rstandard(fit)`	없음
외적 표준화잔차 r*	i를 제외해 추정한 $s_{(i)}$	`rstudent(fit)`	없음

`rstandard()`라는 함수 이름만 보고 교재의 z와 같다고 해석하지 마세요. 이 수업에서는 교재 용어를 유지하고, 함수가 실제 사용하는 분모를 대응시킵니다. s만으로 나눈 e/s도 교재의 내적 표준화잔차와 다릅니다.

4. 전체 오차 규모 s 계산하기

설명변수 수를 p, 절편을 포함한 총 계수 수를 k=p+1, 잔차 자유도를 ν=n−p−1로 둡니다. 이번 모형은 n=30, p=2, k=3, ν=27입니다.

$$s^2 = \frac{\sum_{j=1}^{n} e_j^2}{n-p-1} = \frac{\mathrm{SSE}}{\nu}.$$

```
nu <- df.residual(fit)
s <- sqrt(sum(residuals(fit)^2)/nu)
c(nu=nu, s=s, R_sigma=sigma(fit))
```

s는 약6.816780%p입니다. s가 크다는 것은 모형 주위에서 남은 차이의 전반적 규모가 크다는 뜻입니다. 특정 회귀계수의 표준오차와는 다릅니다.

첫 부서의 $h_{11} \approx 0.1132912$를 넣으면 내적 표준화잔차를 구할 수 있습니다.

$$r_1 = \frac{-7.926760}{6.816780\sqrt{1 - 0.1132912}} \approx -1.2348835.$$

```
i <- 1
manual <- residuals(fit)[i]/(sigma(fit)*sqrt(1-hatvalues(fit)[i]))
c(manual=manual, R=rstandard(fit)[i])
```

E5 · 오류 고치기. `residuals(fit)[1]/sigma(fit)`를 내적 표준화잔차라고 쓴 코드에서 빠진 항을 고치고, R 함수와의 일치를 확인하세요.

5. 외적 표준화는 무엇을 제외하는가?

큰 잔차를 가진 관측이 전체 s를 키우면, 그 관측의 잔차를 큰 분모로 나누게 됩니다. 외적 표준화는 **오차 규모를 추정할 때 그 관측의 기여를 제외**합니다. 그렇다고 분자까지 삭제 후 예측오차로 바꾸는 것은 아닙니다.

$$s_{(i)}^2 = \frac{\mathrm{SSE} - e_i^2/(1-h_{ii})}{\nu - 1}.$$

```
i <- 1
f_minus <- lm(rating~complaints+learning, data=d[-i,])
s_minus <- sigma(f_minus)
external <- residuals(fit)[i]/(s_minus*sqrt(1-hatvalues(fit)[i]))
c(manual=external, R=rstudent(fit)[i])
```

첫 부서의 외적 표준화잔차는약−1.2475416입니다. 내적 값과 조금 다르지만, 이 사례에서 아주 크게 달라지지는 않습니다. **제외 후 재적합은 정의를 확인하기 위한 계산 실험**이며, 이 부서를 실제 분석에서 삭제하자는 지시가 아닙니다.

삭제한 부서를 삭제 후 모형으로 예측해 구한 차이는 다음과 같습니다.

$$y_i - \hat{y}_{i,(-i)} = \frac{e_i}{1 - h_{ii}}.$$

이것은 삭제예측잔차이며 외적 표준화잔차의 분자가 아닙니다. 분모의 $s_{(i)}$와 분자의 e_i가 어디에서 왔는지 따로 확인하세요.

E6 · 두 계산 구별하기. 외적 표준화잔차와 삭제예측잔차의 분자 또는 기준 예측을 설명하세요. "외적"이라는 말이 모든 계산에서 해당 관측을 빼야 한다는 뜻인가요?

6. 계산이 안 되는 경우도 의미가 있다

h=1이면 표준화 분모가0입니다. 이를0으로 채우거나 아주 작은 수로 임의 치환하면 수학적 의미가 바뀝니다. Anscombe의4번 자료에는 이런 경계점이 있으므로 네 자료 전체에 표준화잔차 계산을 무조건 적용하는 예제로 사용하지 않습니다. 이번 공통 함수는 이 경우 NA와 이유를 표시합니다.

관측을 제외한 뒤 설계행렬의 계수가 부족해지거나 오차 분산이0이 되는 경우도 별도로 다뤄야 합니다. 따라서 공식의 사용 조건을 먼저 확인합니다. 실습의 attitude 모형은 완전 열계수이며 필요한 자유도를 확보합니다.

7. 잔차합0을 직접 반례로 확인하기

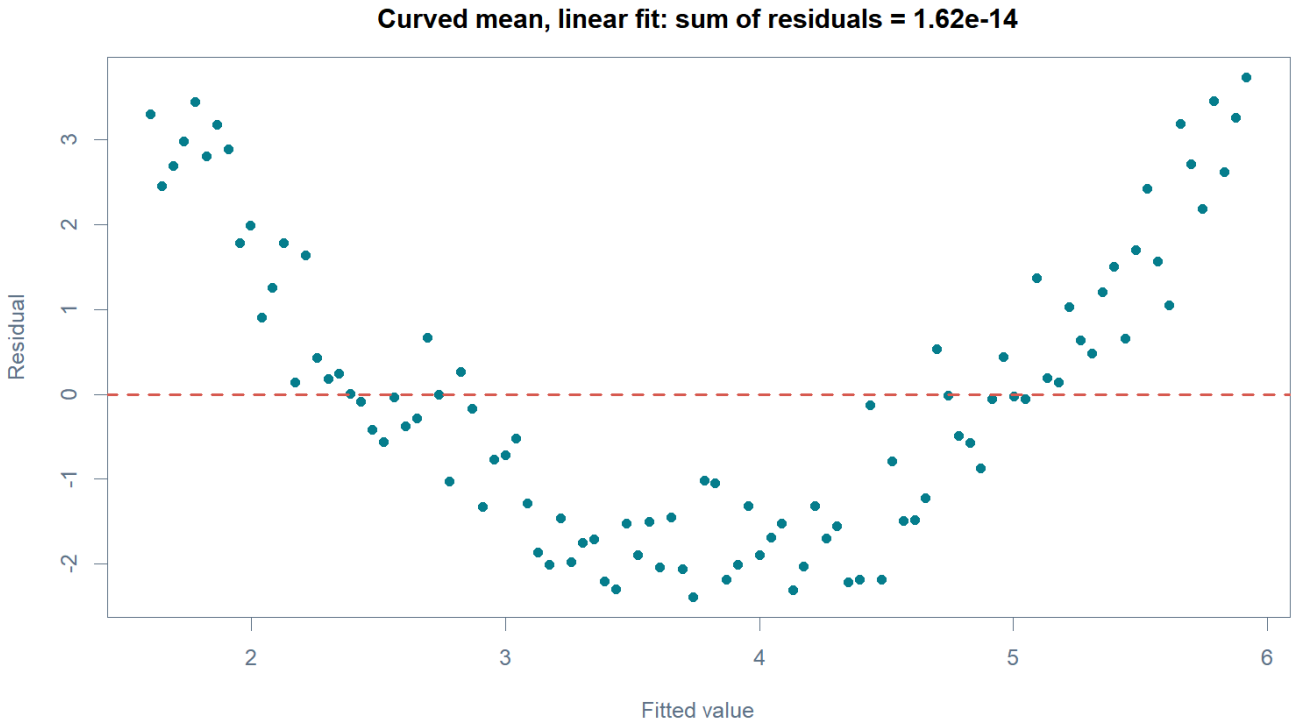


그림 B4. 모의 자료의 참 평균은 곡선이고 적합 모형은 직선입니다. 양·음 잔차가 합쳐져 거의0이어도 체계적인 곡선이 남습니다. 계산기의 작은 지수 표기값은 부동소수점 오차 수준입니다. 이를 "모형이 적절하다"로 바꾸어 말하면 안 됩니다.

오차가 독립이어도 잔차는 같은 추정 회귀식을 공유하므로 서로 독립이 아닙니다. 행렬 표현 $\mathrm{Cov}(e \mid X) = \sigma^2(I-H)$가 이를 보여줍니다. 정확한 유도와 외적 표준화잔차의 t 분포 조건은 수학 보충에 따로 정리했습니다.

8. 공통 함수는 어떻게 읽는가?

diagnostics.R 함수 안내와 실제 선언줄에서 `diag_residuals`를 여세요. 입력은 적합한 lm 객체이며, 반환 표의 raw, h, s, s_deleted, internal, external을 순서대로 읽습니다. 함수는 원자료를 바꾸거나 관측을 삭제하지 않습니다.

```
res <- diag_residuals(fit)
res[1,]
max(abs(res$internal-rstandard(fit)))
max(abs(res$external-rstudent(fit)))
```

수치 오차 수준의 차이는 두 계산이 일치한다는 뜻이며, 모형 가정의 입증은 아닙니다. 근거는 교재 §5.3과 R 공식 진단 함수 설명입니다. 계산 예와 곡선 반례는 추가 해설입니다.