W09B · 수식·분모·자유도 지도와 선택 유도

첫 부분은 계산할 때 곁에 두는 지도입니다. 뒤의 행렬 유도는 선택 보충입니다. 긴 유도를 먼저 외우기보다 E02→E04의 같은 한 행 계산을 설명할 수 있는지 확인합니다.

1. 계산 지도

전제는 절편 포함·비가중·완전열계수 OLS이며 같은 관측과 단위를 사용합니다. p는 설명변수 수, $k = p + 1$, $\nu = n - k > 1$입니다.

양	정의	분모·해석
보통잔차	$e_i = y_i - \hat{y}_i$	반응 단위
오차 규모	$s^2 = \mathrm{SSE}/\nu$	전체 자료
내적 표준화잔차	$r_i = e_i/(s\sqrt{1-h_i})$	전체 오차 규모
삭제 오차 규모	$s^2_{(i)} = \{\mathrm{SSE} - e_i^2/(1-h_i)\}/(\nu-1)$	삭제 후 자유도
외적 표준화잔차	$r_i^* = e_i/(s_{(i)}\sqrt{1-h_i})$	분자는 원래 e_i
Cook	$C_i = (r_i^2/k)h_i/(1-h_i)$	전체 오차 규모, 음이 아님
DFFITS	$r_i^*\sqrt{h_i/(1-h_i)}$	삭제 오차 규모, 방향이 있음
Hadi 정규화	$d_i^2 = e_i^2/\mathrm{SSE}$	내적 잔차 제곱과 다름
잠재성 성분	$P_i = h_i/(1-h_i)$	X 공간
잔차 성분	$R_i = \{k/(1-h_i)\}d_i^2/(1-d_i^2)$	P-R 가로축
Hadi	$H_i = P_i + R_i$	P-R 세로축은 P_i

모든 진단이 항상 정의되는 것은 아닙니다. $h_i = 1$, 삭제 후 순위 저하, 0에 가까운 오차분산 등은 별도 상태로 보고합니다. 계산 가능한 Cook과 계산 불가능한 DFFITS가 함께 존재할 수도 있습니다. NA는 영향력 0의 다른 표기가 아닙니다.

모형	n	p	k	ν
6행 교육용 y ~ x	6	1	2	4
NY 단순모형	20	1	2	18
NY 네 변수 모형	20	4	5	15
경주 두 변수 모형	35	2	3	32
attitude 복습 모형	30	2	3	27

2. 잔차 분산에 지레값이 들어가는 이유 — 선택

$$\hat{\beta} = (X^\top X)^{-1} X^\top y, \quad \hat{y} = Hy, \quad e = (I - H)y, \quad H = X(X^\top X)^{-1} X^\top.$$

오차의 조건부 공분산이 $\sigma^2 I$이면, H의 대칭성과 멱등성으로 다음이 성립합니다.

$$\begin{aligned} \mathrm{Var}(e \mid X) &= (I - H)\sigma^2 I (I - H)^\top \\ &= \sigma^2 (I - H), \\ \mathrm{Var}(e_i \mid X) &= \sigma^2 (1 - h_i). \end{aligned}$$

그래서 보통잔차를 모든 관측에서 같은 s만으로 나누면 관측별 잔차 분산의 차이를 보정하지 못합니다. 내적 표준화의 $\sqrt{1 - h_i}$는 이 차이와 연결됩니다. 이 대수적 유도가 모형의 가정을 자료에서 입증해 주는 것은 아닙니다.

3. 삭제 재적합과 Cook의 두 식 — 선택

x_i를 절편을 포함한 열벡터로 놓고, 삭제 후에도 설계행렬의 순위가 유지된다고 가정합니다.

$$\hat{\beta} - \hat{\beta}_{(i)} = \frac{(X^\top X)^{-1} x_i e_i}{1 - h_i}.$$

원래 모든 행에서 예측 차이는 $X(\hat{\beta} - \hat{\beta}_{(i)})$입니다.

$$\begin{aligned} \| \hat{y} - \hat{y}_{(i)} \|^2 &= \frac{e_i^2}{(1 - h_i)^2} x_i^\top (X^\top X)^{-1} X^\top X (X^\top X)^{-1} x_i \\ &= \frac{e_i^2 h_i}{(1 - h_i)^2}. \end{aligned}$$

이 식을 ks^2로 나누면 Cook의 정의식과 잔차·지레값을 사용한 식이 일치합니다.

$$C_i = \frac{e_i^2 h_i}{k s^2 (1 - h_i)^2} = \frac{r_i^2}{k} \frac{h_i}{1 - h_i}.$$

4. DFFITS의 부호와 삭제 분모 — 선택

관측 i 위치에서는 $\hat{y}_i - \hat{y}_{i(i)} = h_i e_i / (1 - h_i)$입니다.

$$\begin{aligned} \mathrm{DFFITS}_i &= \frac{h_i e_i / (1 - h_i)}{s_{(i)} \sqrt{h_i}} \\ &= \frac{e_i}{s_{(i)} \sqrt{1 - h_i}} \sqrt{\frac{h_i}{1 - h_i}} = r_i^* \sqrt{\frac{h_i}{1 - h_i}}. \end{aligned}$$

Cook의 r_i^2와 달리 DFFITS는 r_i^*의 부호를 유지합니다. 외적 표준화의 분자를 삭제예측잔차 $e_i / (1 - h_i)$로 바꾸면 이 정의와 달라집니다.

5. 첨가변수 기울기의 행렬 지도 — 선택

관심 변수 열을 x_j, 절편을 포함한 나머지 설계행렬을 Z라고 둡니다. 같은 35행의 같은 행렬을 사용합니다.

$$M_Z = I - Z(Z^\top Z)^{-1}Z^\top, \quad u = M_Z x_j, \quad v = M_Z y, \qquad b_j = \frac{u^\top v}{u^\top u}.$$

양쪽에서 Z의 선형 부분을 제거하면 관심 변수에 남은 독립 변동과 반응에 남은 변동을 비교하게 됩니다. u만 또는 v만 다른 관측 집합에서 만들면 이 등식의 전제가 깨집니다. 이번 함수는 한 `lm`의 모형행렬에서 좌표를 함께 만들어 관측 정렬을 보존합니다.

성분잔차는 별도의 좌표 $c_j = e + b_j x_j$입니다. $v - b_j u = e$이지만 c_j의 가로축은 x_j이므로 첨가변수도의 점들을 그대로 옮겨 그린 것이 아닙니다.

주교재 §5.3, §5.8–5.10, §5.13 및 표준 OLS 항등식을 계산 학습용으로 정리했습니다. 기본 R 진단 정의. 로버스트 적합은 이 OLS 지도에 그대로 대입하지 않습니다.