A · 잔차에서 가정 점검으로

회귀분석의 이해 · W09B · 2026년 10월 28일

주교재『Chatterjee 예제를 통한 회귀분석 제6판: R 활용』§5.1–5.6을 복습하고 §5.7의 선형성·정규성 진단으로 이어갑니다. 중간고사 이후에도 기호를 기억하는 것과 한 관측을 계산하는 것은 다를 수 있습니다. 이번에는 모형을 쓰고 → 한 행을 계산하고 → 그림에서 같은 행을 찾고 → R과 비교하고 → 판단의 근거를 설명합니다.

설명용 완성 예제 E01–E10과 직접 풀 연습 L01–L12를 구별합니다. 핵심 계산 예제는 E02·E03·E04·E06·E07·E08입니다. 연습은 L01–L06을 먼저 수행하고, L07–L12를 반복·확장에 사용합니다. 개념 점검 Q01–Q10의 해설은 별도 자료입니다. 새 성적 반영 과제나 제출 기한은 없습니다.

1. 세 가지 자료와 한 가지 복습 자료

자료	한 행과 크기	모형·용도	단위와 주의
추가 구성한 6행 표	교육용 관측 6개	$y \sim x$; 계산 과정을 손으로 확인	임의 교육용 단위, 실제 조사 자료로 해석하지 않음
NYRivers	강 20개	단순모형은 영향력, 네 변수 모형은 민감도 비교	공식 파일의 농도·토지이용 비율 척도 유지
Scottish.Hills	경주 35개	변수 효과·변수 추가·로버스트 비교	Time 초, Distance 마일, Climb 고도 상승량 피트
attitude	부서 30개	W06A의 잔차 복습에만 사용	긍정 응답 비율(%), 차이는 %p

NYRivers의 이 차시 검토 원문과 파일에는 물리 농도 단위가 명시되어 있지 않습니다. 숫자에 새 물리 단위를 붙이지 않고 원자료 척도로 계산합니다. `ComIndl`은 상업·산업 토지이용 비율입니다. Scottish.Hills의 `Climb`은 교재의 '경사' 변수이며 각도나 기울기 비율이 아니라 피트로 기록한 상승량입니다.

모든 계산에서 p는 설명변수 수, $k = p + 1$은 절편을 포함한 계수 수, $\nu = n - k$는 잔차 자유도입니다. 설계행렬은 완전열계수이고, 이번 계산은 절편을 포함한 비가중 OLS입니다. 교재의 지레값 p_{ii}를 이 자료에서는 h_i로도 씁니다.

2. 오차·잔차·분모를 다시 연결하기 (§5.1–5.3)

$$Y_i = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} + \varepsilon_i, \qquad \hat{y}_i = b_0 + \sum_{j=1}^{p} b_j x_{ij}, \qquad e_i = y_i - \hat{y}_i.$$

오차는 참 조건부 평균과 관측의 차이이고, 잔차는 자료로 추정한 적합값과 관측의 차이입니다. 우리가 직접 계산하는 것은 잔차입니다. 관측이 적합식 계산에 참여하기 때문에 잔차의 산포는 관측별로 달라집니다.

$$\mathrm{Var}(e_i \mid X) = \sigma^2(1 - h_i), \qquad s^2 = \frac{\mathrm{SSE}}{\nu}, \qquad r_i = \frac{e_i}{s\sqrt{1 - h_i}}, \qquad r_i^* = \frac{e_i}{s_{(i)}\sqrt{1 - h_i}}.$$

내적 표준화잔차 r_i는 전체 자료의 s를, 외적 표준화잔차 r_i^*는 관측 i를 제외한 오차 규모 $s_{(i)}$를 사용합니다. 두 식의 분자는 모두 전체 자료에서 얻은 e_i입니다. R에서는 각각 `rstandard()`와 `rstudent()`에 대응합니다.

E01 · 익숙한 부서 한 행을 복원하기 — 추가 반복

W06A와 같은 `rating ~ complaints + learning`을 사용합니다. $n = 30$, $p = 2$, $k = 3$, $\nu = 27$입니다. 첫 부서의 실제 rating은 43%, 적합값은 약 50.926760%입니다.

$$
\begin{aligned}
e_1 &= 43 - 50.926760 = -7.926760\ , \\
s\sqrt{1 - h_1} &= 6.816780\sqrt{1 - 0.1132912} \approx 6.419, \\
r_1 &\approx -1.234884, \qquad r_1^{*} \approx -1.247542.
\end{aligned}
$$

음수는 실제 응답 비율이 예측보다 낮다는 방향입니다. 표준화잔차에는 단위가 없습니다. 분모에서 $\sqrt{1 - h_1}$를 빼면 교재의 내적 표준화잔차가 되지 않습니다. 끝자리 차이는 표시값을 먼저 반올림한 데서 생길 수 있으므로 검산에서는 원래 정밀도를 사용합니다.

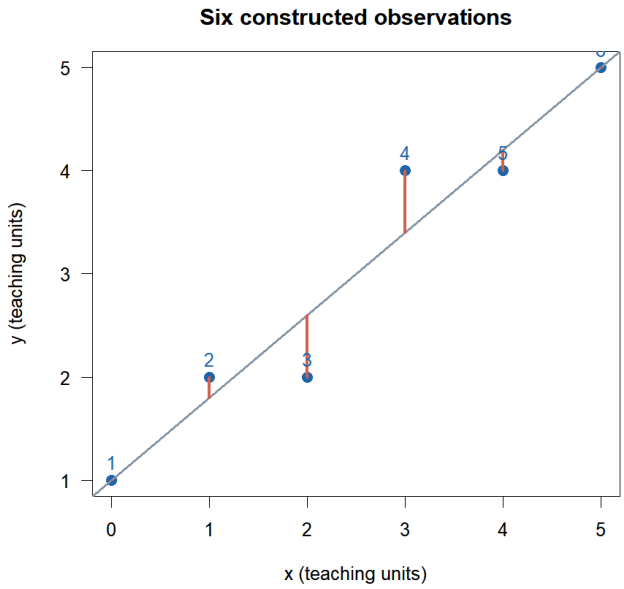
확인 C01. 잔차합이 0이면 조건부 오차 평균이 0이라는 가정도 확인된 것인지 먼저 판단하세요.

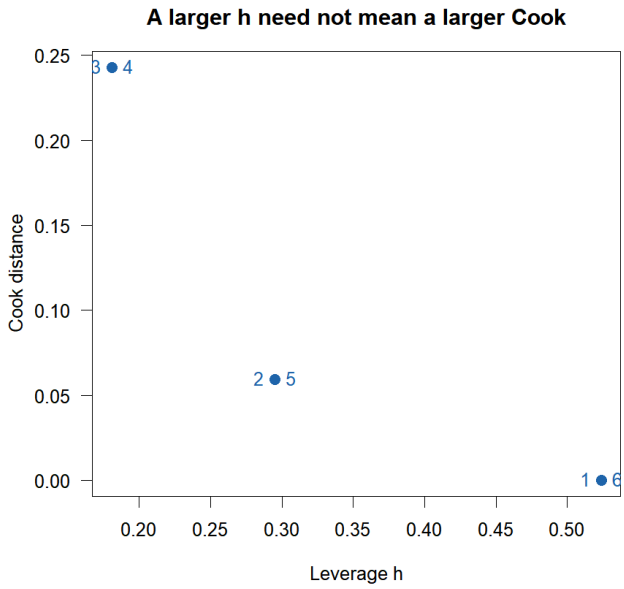
3. 6행 계산표의 회귀식 만들기 — E02, 핵심

아래는 계산을 위해 추가 구성한 표입니다. 원 교재의 실제 사례를 대체하는 자료가 아닙니다.

행 i	x_i	y_i	$\hat{y}_i = 1 + 0.8x_i$	e_i
1	0	1	1.0	0.0
2	1	2	1.8	0.2
3	2	2	2.6	-0.6
4	3	4	3.4	0.6
5	4	4	4.2	-0.2
6	5	5	5.0	0.0

$$
\begin{aligned}
\bar{x} = 2.5, \quad \bar{y} = 3, \quad S_{xx} = 17.5, \quad S_{xy} = 14, \\
b_1 = \frac{14}{17.5} = 0.8, \qquad b_0 = 3 - 0.8(2.5) = 1, \\
\mathrm{SSE} = 0^2 + 0.2^2 + (-0.6)^2 + 0.6^2 + (-0.2)^2 + 0^2 = 0.8, \\
\nu = 6 - 2 = 4, \quad s^2 = 0.8/4 = 0.2, \quad s = \sqrt{0.2} \approx 0.447214.
\end{aligned}
$$





그림은 추가 구성 자료를 직접 계산해 그렸습니다. 왼쪽의 주황 선분은 관측과 적합값의 차이입니다. 오른쪽에서는 높은 지레값과 큰 Cook의 거리가 서로 다른 관측에 나타납니다. 3·4행은 같은 지레값과 반대 부호의 잔차를 가지므로 Cook은 같고 DFFITS의 부호는 반대가 됩니다. 이 표의 지레값과 영향력은 다음 B 노트에서 계산합니다.

부분 완성. 4행에서 $e_4 = 4 - (1 + 0.8 \times \square)$의 마지막 항을 채운 뒤, 관측을 바꾼 L01을 풀어 보세요. 이 빈칸은 E02의 계산을 되짚는 설명 단계입니다.

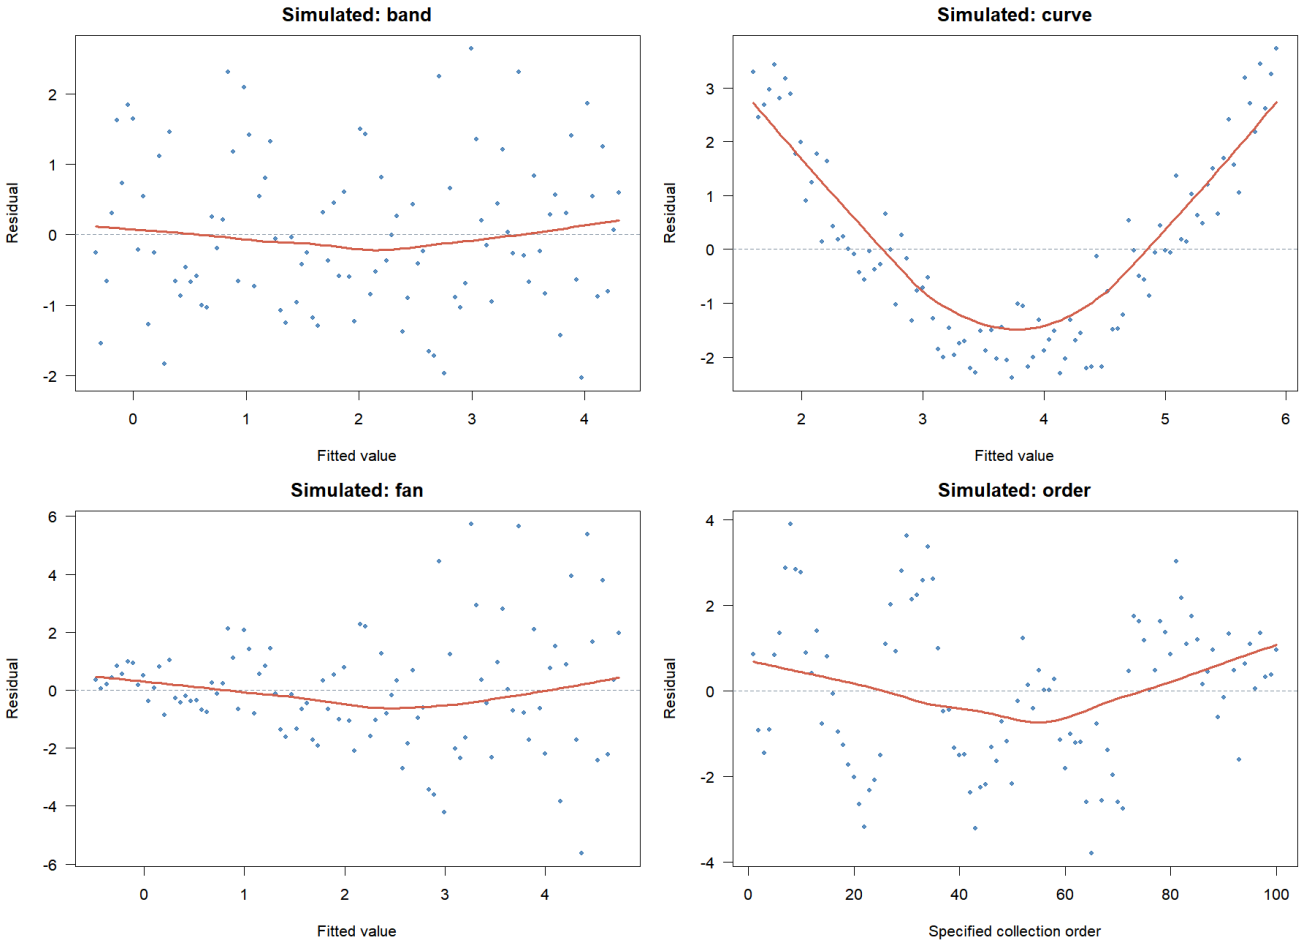
4. 적합 전·후 그림은 서로 다른 질문에 답한다 (§5.4–5.6 복습)

적합 전에는 각 변수의 분포, 쌍별 관계, 관측 단위·측정 오류, 결합 관계를 확인합니다. 쌍별 상관이 작다는 이유만으로 다른 변수를 통제한 관계도 작다고 결정할 수 없습니다. W06A의 Hamilton 사례는 쌍별 투영과 함께 보는 관계의 차이를 보여 주었습니다.

적합 후에는 가정 위반, 특이값·영향 관측, 변수의 효과를 진단합니다. 한 개의 높은 R^2나 작은 p값은 이 검토를 대신하지 못합니다. 절편을 포함한 OLS의 $\sum e_i = 0$은 적합 방식의 대수적 성질이며 좋은 모형의 인증서가 아닙니다.

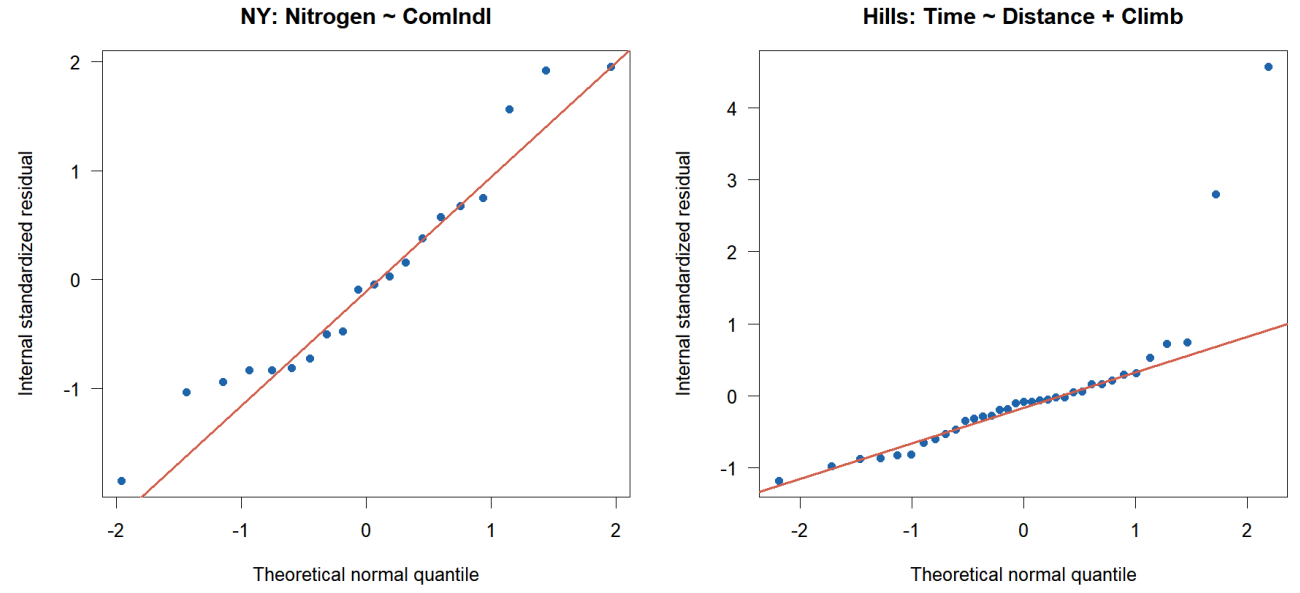
5. 선형성과 정규성을 구별해 읽기 (§5.7)

그래프	먼저 읽을 것	추가로 확인할 것
잔차–적합값	0 주변의 띠, 곡선, 산포 변화	평균식·분산 구조·특이 관측
잔차–각 설명변수	특정 변수 방향의 곡선·구간	변환·추가 항의 필요성, 변수 범위
정규 Q-Q	이론 분위수와 잔차 분위수의 관계	꼬리·비대칭·개별 관측·모형 형태
잔차–수집순서	실제 수집 과정에 따른 연속 패턴	의존성, 측정 조건의 변화



이 그림은 W06A의 공개 함수 `diag_patterns()`로 만든 모의 자료입니다. 각 패널은 각각의 자료에 직선을 적합한 결과입니다. 곡선 패턴은 평균식의 재검토, 부채꼴은 분산 구조의 재검토, 실제 순서 패턴은 의존성의 재검토를 제안합니다. 원인을 확정하는 그림으로 사용하지 않습니다. `attitude`의 부서 번호나 경주 파일의 행 번호를 시간순서로 간주하지 않습니다.

확인 C02. Q-Q가 직선에 가까우면 $\boldsymbol{X}$의 분포가 정규라는 결론을 내릴 수 있는지 설명하세요.



두 패널은 서로 다른 자료·모형을 명시해 그린 실제 잔차입니다. 정확한 소표본 t/F 추론의 정규성은 주어진 X에서 오차의 분포에 관한 가정입니다. X나 Y의 주변 히스토그램이 정규여야 한다는 뜻이 아닙니다. Q-Q의 직선 근사만으로 모든 가정을 입증할 수도 없습니다. 잔차는 적합에 의해 서로 연관되며 유한 표본의 그림에는 변동이 있습니다.

관찰 기록 형식: '무엇이 보였다 → 가능한 설명은 무엇이다 → 무엇을 더 확인한다'의 세 문장으로 씁니다. 먼저 그림의 축·모형·자료를 적은 뒤 해석합니다.

출처와 연결

주교재 §5.1–5.7, pp.188–205. 공식 데이터: 저자 6판 자료실. 잔차 함수 대응: R 공식 진단 문서. 그림은 표시한 모의 자료·공식 자료·추가 6행 자료로 새로 계산했습니다.

온라인 R 실습 · 고정 버전의 함수 안내