A · 잔차에서 가정 점검으로

회귀분석의 이해 · W09B · 2026년 10월 28일

주교재『Chatterjee 예제를 통한 회귀분석 제6판: R 활용』§5.1–5.6을 복습하고 §5.7의 선형성·정규성 진단으로 이어갑니다. 중간고사 이후에도 기호를 기억하는 것과 한 관측을 계산하는 것은 다를 수 있습니다. 이번에는 모형을 쓰고 → 한 행을 계산하고 → 그림에서 같은 행을 찾고 → R과 비교하고 → 판단의 근거를 설명합니다.

설명용 완성 예제 E01–E10과 직접 풀 연습 L01–L12를 구별합니다. 핵심 계산 예제는 E02·E03·E04·E06·E07·E08입니다. 연습은 L01–L06을 먼저 수행하고, L07–L12를 반복·확장에 사용합니다. 개념 점검 Q01–Q10의 해설은 별도 자료입니다. 새 성적 반영 과제나 제출 기한은 없습니다.

1. 세 가지 자료와 한 가지 복습 자료

자료	한 행과 크기	모형·용도	단위와 주의
추가 구성한 6행 표	교육용 관측 6개	$y \sim x$; 계산 과정을 손으로 확인	임의 교육용 단위, 실제 조사 자료로 해석하지 않음
NYRivers	강 20개	단순모형은 영향력, 네 변수 모형은 민감도 비교	공식 파일의 농도·토지이용 비율 척도 유지
Scottish.Hills	경주 35개	변수 효과·변수 추가·로버스트 비교	Time 초, Distance 마일, Climb 고도 상승량 피트
attitude	부서 30개	W06A의 잔차 복습에만 사용	긍정 응답 비율(%), 차이는 %p

NYRivers의 이 차시 검토 원문과 파일에는 물리 농도 단위가 명시되어 있지 않습니다. 숫자에 새 물리 단위를 붙이지 않고 원자료 척도로 계산합니다. `ComInd`은 상업·산업 토지이용 비율입니다. Scottish.Hills의 `Climb`은 교재의 '경사' 변수이며 각도나 기울기 비율이 아니라 피트로 기록한 상승량입니다.

모든 계산에서 p는 설명변수 수, $k = p + 1$은 절편을 포함한 계수 수, $\nu = n - k$는 잔차 자유도입니다. 설계행렬은 완전열계수이고, 이번 계산은 절편을 포함한 비가중 OLS입니다. 교재의 지레값 p_{ii}를 이 자료에서는 h_i로도 씁니다.

2. 오차·잔차·분모를 다시 연결하기 (§5.1–5.3)

$$Y_i = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} + \varepsilon_i, \qquad \hat{y}_i = b_0 + \sum_{j=1}^{p} b_j x_{ij}, \qquad e_i = y_i - \hat{y}_i.$$

오차는 참 조건부 평균과 관측의 차이이고, 잔차는 자료로 추정한 적합값과 관측의 차이입니다. 우리가 직접 계산하는 것은 잔차입니다. 관측이 적합식 계산에 참여하기 때문에 잔차의 산포는 관측별로 달라집니다.

$$\mathrm{Var}(e_i \mid X) = \sigma^2(1-h_i), \qquad s^2 = \frac{\mathrm{SSE}}{\nu}, \qquad r_i = \frac{e_i}{s\sqrt{1-h_i}}, \qquad r_i^* = \frac{e_i}{s_{(i)}\sqrt{1-h_i}}.$$

내적 표준화잔차 r_i는 전체 자료의 s를, 외적 표준화잔차 r_i^*는 관측 i를 제외한 오차 규모 $s_{(i)}$를 사용합니다. 두 식의 분자는 모두 전체 자료에서 얻은 e_i입니다. R에서는 각각 `rstandard()`와 `rstudent()`에 대응합니다.

E01 · 익숙한 부서 한 행을 복원하기 — 추가 반복

W06A와 같은 `rating ~ complaints + learning`을 사용합니다. $n=30$, $p=2$, $k=3$, $\nu=27$입니다. 첫 부서의 실제 rating은 43%, 적합값은 약 50.926760%입니다.

$$\begin{aligned} e_1 &= 43 - 50.926760 = -7.926760\ , \\ s\sqrt{1-h_1} &= 6.816780\sqrt{1-0.1132912} \approx 6.419, \\ r_1 &\approx -1.234884, \qquad r_1^* \approx -1.247542. \end{aligned}$$

음수는 실제 응답 비율이 예측보다 낮다는 방향입니다. 표준화잔차에는 단위가 없습니다. 분모에서 $\sqrt{1-h_1}$를 빼면 교재의 내적 표준화잔차가 되지 않습니다. 끝자리 차이는 표시값을 먼저 반올림한 데서 생길 수 있으므로 검산에서는 원래 정밀도를 사용합니다.

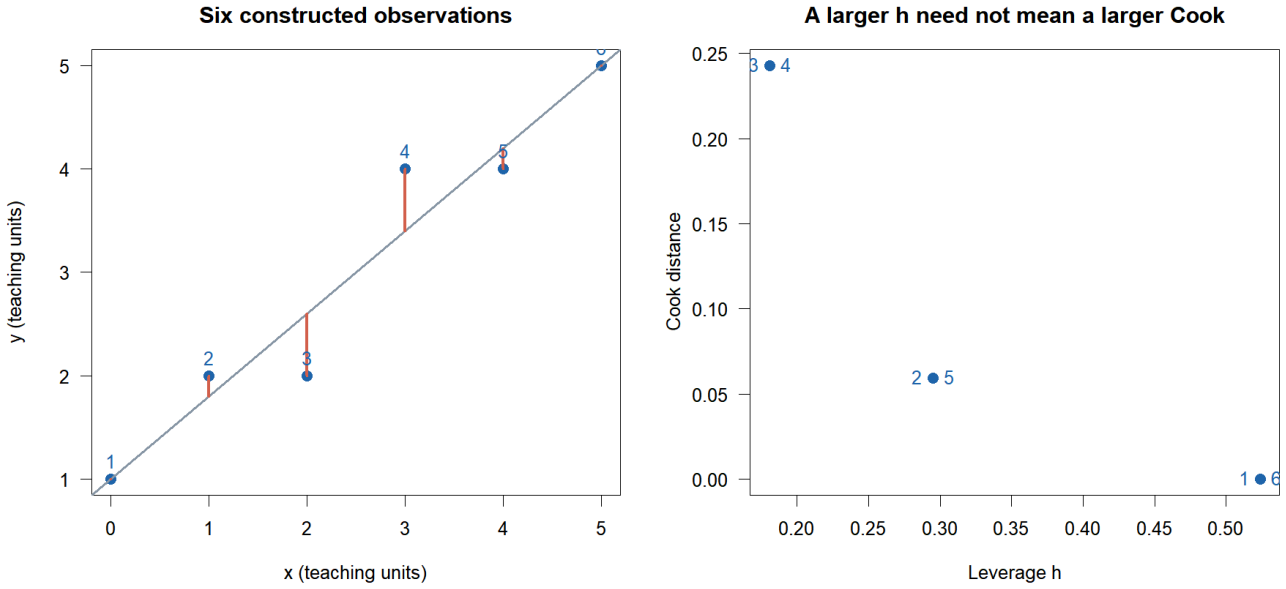
확인 C01. 잔차합이 0이면 조건부 오차 평균이 0이라는 가정도 확인된 것인지 먼저 판단하세요.

3. 6행 계산표의 회귀식 만들기 — E02, 핵심

아래는 계산을 위해 추가 구성한 표입니다. 원 교재의 실제 사례를 대체하는 자료가 아닙니다.

행 i	x_i	y_i	$\hat{y}_i = 1 + 0.8x_i$	e_i
1	0	1	1.0	0.0
2	1	2	1.8	0.2
3	2	2	2.6	-0.6
4	3	4	3.4	0.6
5	4	4	4.2	-0.2
6	5	5	5.0	0.0

$$\bar{x} = 2.5, \quad \bar{y} = 3, \quad S_{xx} = 17.5, \quad S_{xy} = 14,$$
$$b_1 = \frac{14}{17.5} = 0.8, \qquad b_0 = 3 - 0.8(2.5) = 1,$$
$$\mathrm{SSE} = 0^2 + 0.2^2 + (-0.6)^2 + 0.6^2 + (-0.2)^2 + 0^2 = 0.8,$$
$$\nu = 6 - 2 = 4, \quad s^2 = 0.8/4 = 0.2, \quad s = \sqrt{0.2} \approx 0.447214.$$



그림은 추가 구성 자료를 직접 계산해 그렸습니다. 왼쪽의 주황 선분은 관측과 적합값의 차이입니다. 오른쪽에서는 높은 지레값과 큰 Cook의 거리가 서로 다른 관측에 나타납니다. 3·4행은 같은 지레값과 반대 부호의 잔차를 가지므로 Cook은 같고 DFFITS의 부호는 반대가 됩니다. 이 표의 지레값과 영향력은 다음 B 노트에서 계산합니다.

부분 완성. 4행에서 $e_4 = 4 - (1 + 0.8 \times \square)$의 마지막 항을 채운 뒤, 관측을 바꾼 L01을 풀어 보세요. 이 빈칸은 E02의 계산을 되짚는 설명 단계입니다.

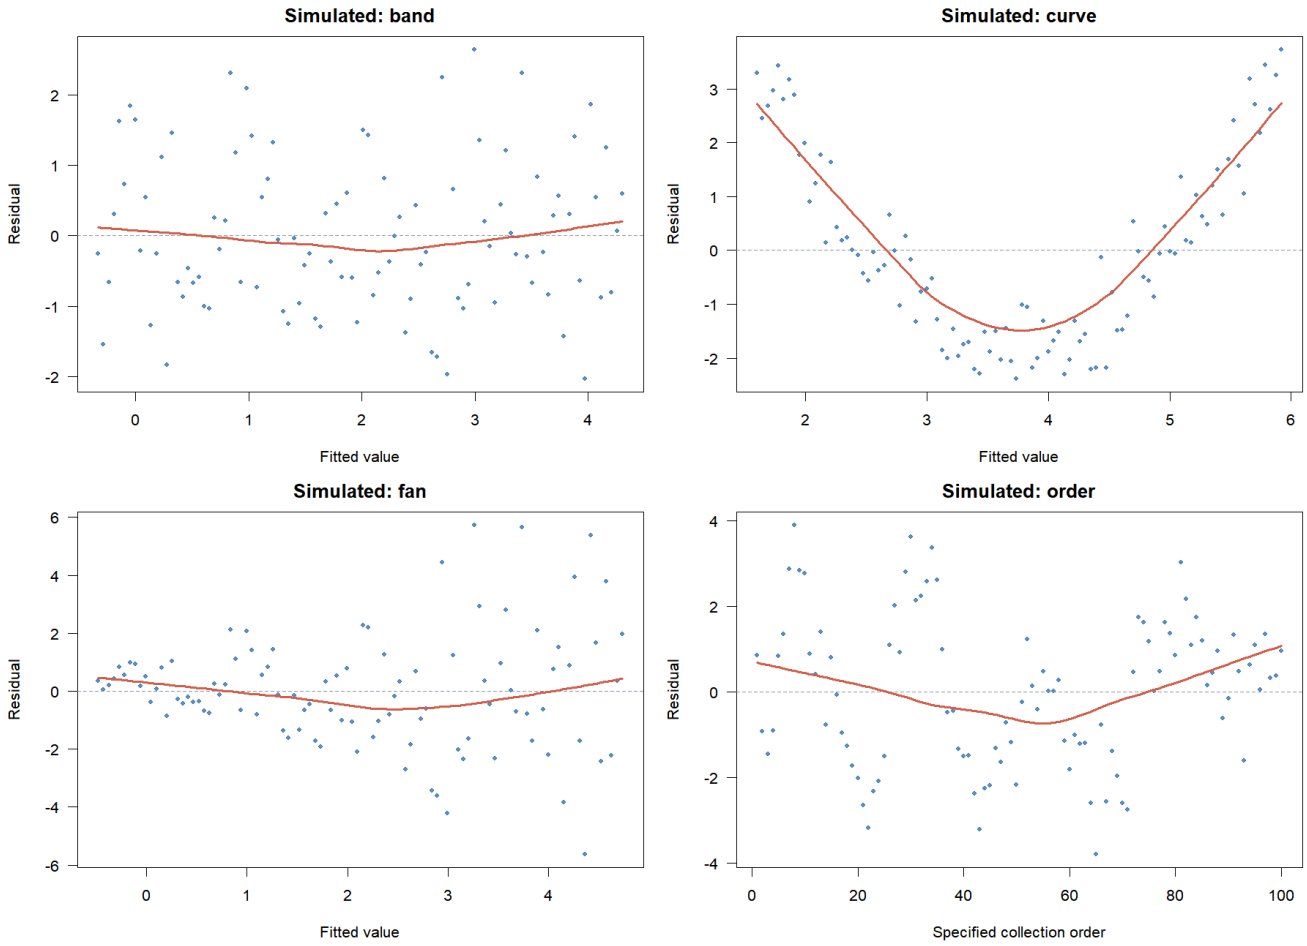
4. 적합 전·후 그림은 서로 다른 질문에 답한다 (§5.4–5.6 복습)

적합 전에는 각 변수의 분포, 쌍별 관계, 관측 단위·측정 오류, 결합 관계를 확인합니다. 쌍별 상관이 작다는 이유만으로 다른 변수를 통제한 관계도 작다고 결정할 수 없습니다. W06A의 Hamilton 사례는 쌍별 투영과 함께 보는 관계의 차이를 보여 주었습니다.

적합 후에는 가정 위반, 특이값·영향 관측, 변수의 효과를 진단합니다. 한 개의 높은 R^2나 작은 p값은 이 검토를 대신하지 못합니다. 절편을 포함한 OLS의 $\sum e_i = 0$은 적합 방식의 대수적 성질이며 좋은 모형의 인증서가 아닙니다.

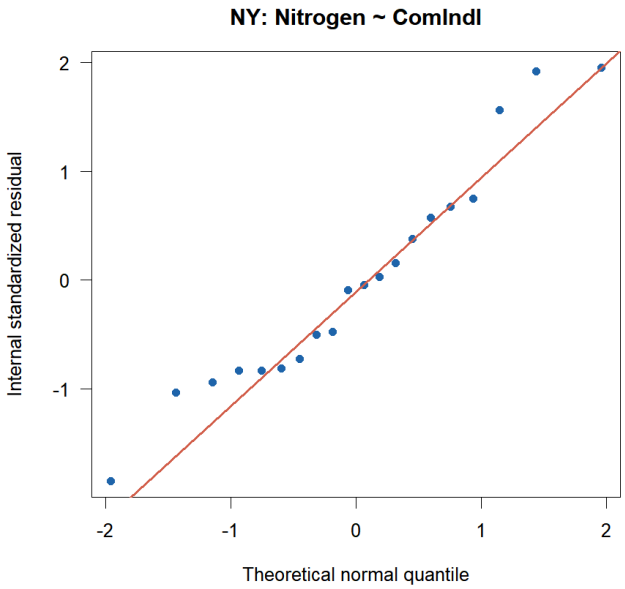
5. 선형성과 정규성을 구별해 읽기 (§5.7)

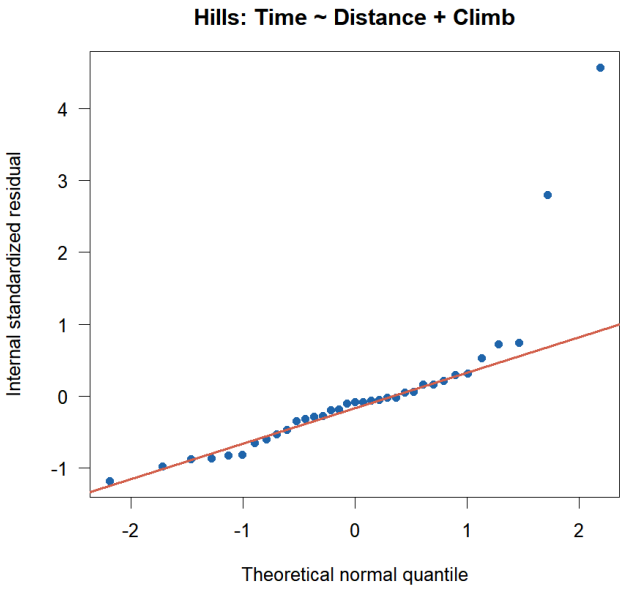
그래프	먼저 읽을 것	추가로 확인할 것
잔차–적합값	0 주변의 띠, 곡선, 산포 변화	평균식·분산 구조·특이 관측
잔차–각 설명변수	특정 변수 방향의 곡선·구간	변환·추가 항의 필요성, 변수 범위
정규 Q-Q	이론 분위수와 잔차 분위수의 관계	꼬리·비대칭·개별 관측·모형 형태
잔차–수집순서	실제 수집 과정에 따른 연속 패턴	의존성, 측정 조건의 변화



이 그림은 W06A의 공개 함수 `diag_patterns()`로 만든 모의 자료입니다. 각 패널은 각각의 자료에 직선을 적합한 결과입니다. 곡선 패턴은 평균식의 재검토, 부채꼴은 분산 구조의 재검토, 실제 순서 패턴은 의존성의 재검토를 제안합니다. 원인을 확정하는 그림으로 사용하지 않습니다. `attitude`의 부서 번호나 경주 파일의 행 번호를 시간순서로 간주하지 않습니다.

확인 C02. Q-Q가 직선에 가까우면 X의 분포가 정규라는 결론을 내릴 수 있는지 설명하세요.





두 패널은 서로 다른 자료·모형을 명시해 그린 실제 잔차입니다. 정확한 소표본 t/F 추론의 정규성은 주어진 $\boldsymbol{X}$에서 오차의 분포에 관한 가정입니다. $\boldsymbol{X}$나 $\boldsymbol{Y}$의 주변 히스토그램이 정규여야 한다는 뜻이 아닙니다. Q-Q의 직선 근사만으로 모든 가정을 입증할 수도 없습니다. 잔차는 적합에 의해 서로 연관되며 유한 표본의 그림에는 변동이 있습니다.

관찰 기록 형식: '무엇이 보였다 → 가능한 설명은 무엇이다 → 무엇을 더 확인한다'의 세 문장으로 씁니다. 먼저 그림의 축·모형·자료를 적은 뒤 해석합니다.

출처와 연결

주교재 §5.1–5.7, pp.188–205. 공식 데이터: 저자 6판 자료실. 잔차 함수 대응: R 공식 진단 문서. 그림은 표시한 모의 자료·공식 자료·추가 6행 자료로 새로 계산했습니다.

온라인 R 실습 · 고정 버전의 함수 안내

B · 지레값·영향력·잠재성–잔차도

W09B · 주교재 §5.8–5.11, pp.205–219

이 노트의 질문은 어느 관측을 더 살펴봐야 하며, 그 관측이 적합 결과에 어떻게 관여했는가입니다. 큰 잔차, 높은 지레값, 큰 영향력을 구별합니다. $\boldsymbol{p}$는 설명변수 수, $\boldsymbol{k = p + 1}$은 절편 포함 계수 수, $\boldsymbol{\nu = n - k}$입니다.

1. 세 개념을 한 관측에서 구별하기 (§5.8)

개념	비교하는 공간·결과	대표 도구
반응 방향 특이값	같은 설명변수 조건에서 평균식으로부터의 거리	내적·외적 표준화잔차
높은 지레점	다른 관측과 비교한 $\boldsymbol{X}$ 공간의 위치	$h_i = p_{ii}$
영향력 있는 관측	관측을 제외했을 때 적합 결과의 변화	Cook·DFFITS·재적합 민감도 등

영향력은 선택한 모형·결과에 의존합니다. 실제로 드문 조건을 잘 측정한 관측도 높은 지레점을 가질 수 있습니다. 큰 진단값을 오류의 확정이나 삭제 명령으로 읽지 않습니다.

$$H = X(X^\top X)^{-1}X^\top, \quad h_i = H_{ii}, \quad \sum_i h_i = k, \quad \bar{h} = k/n.$$

절편 포함 단순회귀에서는 $h_i = 1/n + (x_i - \bar{x})^2/S_{xx}$입니다. 지레값은 $\boldsymbol{X}$만으로 정해집니다. $\boldsymbol{Y}$를 바꾸면 잔차·Cook은 변할 수 있지만 같은 $\boldsymbol{X}$의 지레값은 유지됩니다. $2k/n$은 관측을 살펴보는 경험적 기준이지 확정 검정이나 삭제 기준이 아닙니다.

E03 · 6행 표의 지레값과 표준화 분모 — 핵심

A의 6행 표에서 $n = 6$, $k = 2$, $\bar{x} = 2.5$, $S_{xx} = 17.5$입니다. 4행은 $x_4 = 3$입니다.

$$h_4 = \frac{1}{6} + \frac{(3 - 2.5)^2}{17.5} = 0.18095238,$$
$$1 - h_4 = 0.81904762, \qquad r_4 = \frac{0.6}{\sqrt{0.2}\sqrt{0.81904762}} = 1.48245554.$$

1행과 6행은 $h = 0.52380952$로 더 높습니다. 그러나 두 행의 잔차는 수치 오차를 제외하면 0입니다. 이 표에서는 가장 높은 지레값도 $2k/n = 2/3$을 넘지 않습니다. '자료 안에서 상대적으로 높다'와 '경험적 기준을 넘는다'를 구분합니다.

확인 C03. 4행의 y만 바꾸면 h_4도 바뀌는지 예상하고 이유를 쓰세요.

2. 영향력은 실제 제외 전·후와 연결한다 (§5.9)

Cook의 거리는 관측 i를 제외해 적합한 식이 **원래 모든 관측 위치에서** 얼마나 달라졌는지를 전체 자료의 오차 규모로 표준화합니다.

$$C_i = \frac{\sum_{j=1}^{n}(\hat{y}_j - \hat{y}_{j(i)})^2}{ks^2} = \frac{r_i^2}{k}\frac{h_i}{1 - h_i}.$$

DFFITS는 관측 i 위치의 적합값 변화를 삭제 후 오차 규모로 표준화합니다. 방향을 갖습니다.

$$\mathrm{DFFITS}_i = \frac{\hat{y}_i - \hat{y}_{i(i)}}{s_{(i)}\sqrt{h_i}} = r_i^{*}\sqrt{\frac{h_i}{1-h_i}}.$$

Cook에는 내적 r_i와 전체 s를, DFFITS에는 외적 r_i^{*}와 삭제 $s_{(i)}$를 사용합니다. DFFITS가 음수이면 해당 위치에서 전체 적합값이 삭제 후 적합값보다 낮다는 뜻입니다. 절댓값으로 크기를 보고 부호로 방향을 읽습니다.

E04 · 같은 4행으로 Cook·DFFITS·Hadi를 끝까지 계산 — 핵심

6행 표의 $e_4 = 0.6$, $h_4 = 0.18095238$, $\mathrm{SSE} = 0.8$, $k = 2$, $\nu = 4$를 그대로 사용합니다.

$$\begin{aligned}
s_{(4)}^2 &= \frac{0.8 - 0.6^2/(1-0.18095238)}{4-1} \approx 0.12015504,\\
r_4^{*} &= \frac{0.6}{\sqrt{0.12015504}\sqrt{0.81904762}} \approx 1.91260673,\\
C_4 &= \frac{1.48245554^2}{2}\,\frac{0.18095238}{0.81904762} \approx 0.24276636,\\
\mathrm{DFFITS}_4 &= 1.91260673\sqrt{0.18095238/0.81904762} \approx 0.89898668.
\end{aligned}$$

실제 4행을 제외해 회귀식을 다시 적합하고 원래 6개 x에서 예측하면 Cook의 정의식도 같은 값을 줍니다. 분모의 s^2는 전체 모형의 0.2로 유지합니다. 제외한 5개 행만으로 예측 차이의 합을 구하면 정의식과 다른 계산입니다.

Hadi는 잔차를 $\sqrt{\mathrm{SSE}}$로 정규화한 $d_i = e_i/\sqrt{\mathrm{SSE}}$를 사용합니다. 이 d_i는 r_i나 r_i^{*}와 다릅니다.

$$P_i = \frac{h_i}{1-h_i}, \qquad R_i = \frac{k}{1-h_i}\,\frac{d_i^2}{1-d_i^2}, \qquad H_i = P_i + R_i.$$

$$\begin{aligned}
d_4^2 &= 0.6^2/0.8 = 0.45,\\
P_4 &= 0.18095238/0.81904762 \approx 0.22093023,\\
R_4 &= \frac{2}{0.81904762}\,\frac{0.45}{0.55} \approx 1.99788584,\\
H_4 &\approx 2.21881607.
\end{aligned}$$

이 세 수치는 서로 다른 정의입니다. 크기를 같은 자로 비교하거나 모두에 임계값 1을 적용하지 않습니다. 3행으로 바꾼 독립 계산이 L02입니다.

확인 C04. 잔차가 0이고 $h_i > 0$인 점의 Cook과 Hadi가 둘 다 0이어야 하는지 설명하세요.

3. 잔차만 보면 놓치는 이유: 가면·수렁 (§5.8.3)

가면(masking)은 실제로 살펴볼 특이 관측이 다른 관측들의 영향 등으로 숨는 경우입니다. 수렁(swamping)은 특이하지 않은 관측이 특이한 것으로 잘못 표시되는 경우입니다. 일부 관측이 적합선을 자기 쪽으로 끌어당기면 자신의 잔차는 작아지고 다른 관측의 잔차는 커질 수 있습니다.

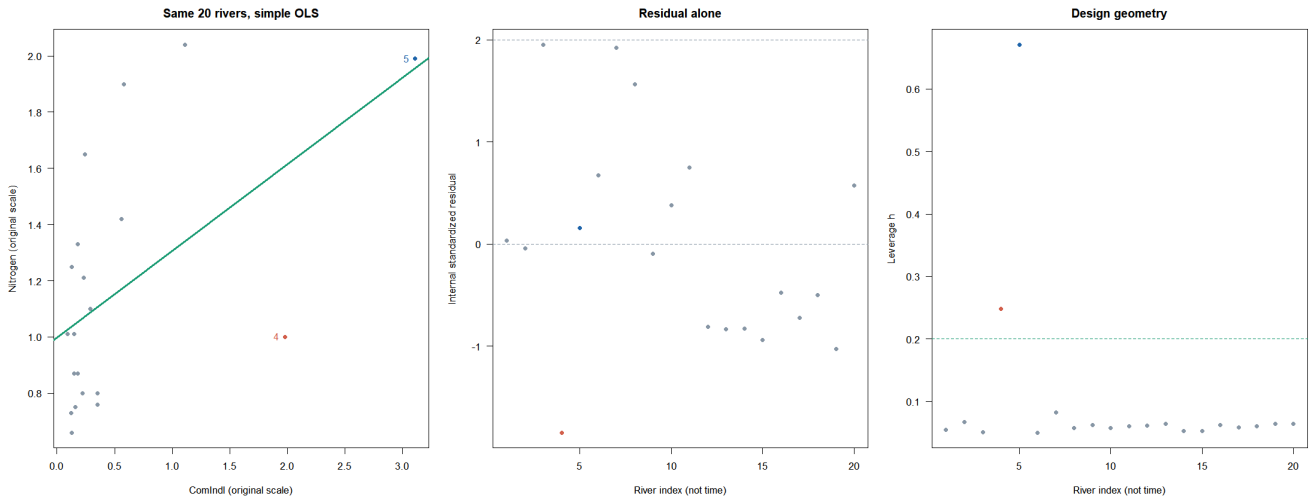
$$h_i + \frac{e_i^2}{\mathrm{SSE}} \le 1.$$

이 관계는 높은 지레값에서 보통잔차가 작게 나타날 수 있는 구조를 보여 줍니다. 작은 잔차 하나로 그 관측의 중요성을 판단하지 않는 이유입니다. 여러 특이 관측이 서로 가릴 수 있으므로 한 행씩 제외하는 분석도 모든 군집 영향을 해결하지 못합니다.

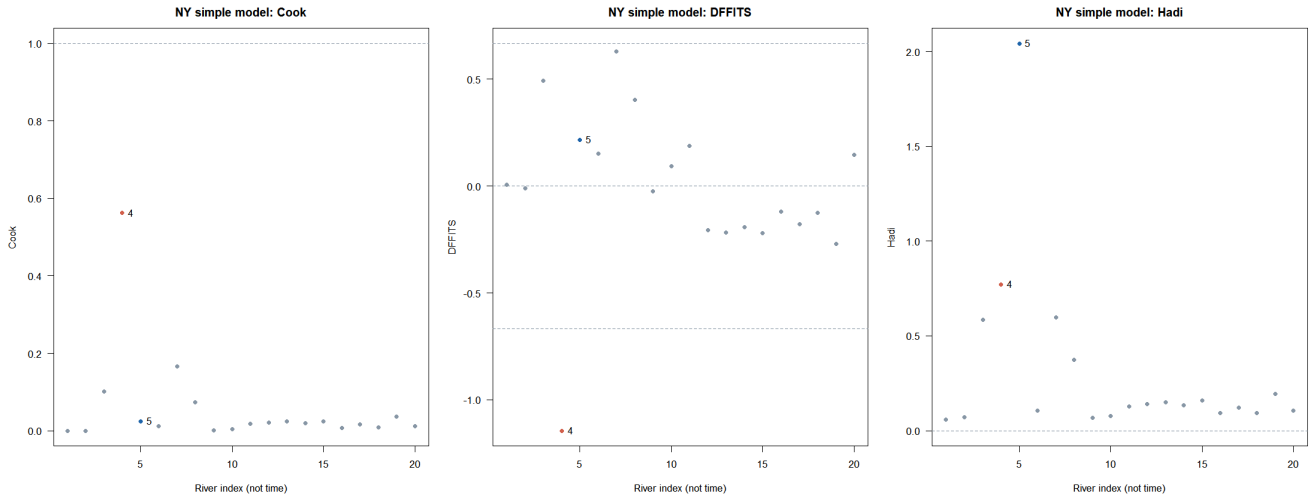
E05 · NYRivers에서 모형을 적은 뒤 비교하기 — 추가 반복

먼저 교재 식 (5.18)의 단순모형 `Nitrogen ~ ComIndl`을 사용합니다. $n = 20$, $k = 2$, $\nu = 18$입니다. 아래 숫자는 공식 파일을 재계산한 값입니다.

관측	내적 r_i	외적 r_i^*	h_i	Cook	DFFITS
4 Neversink	-1.847232	-1.994123	0.247865	0.562255	-1.144754
5 Hackensack	0.155291	0.151017	0.671010	0.024593	0.215674



5번은 내적 잔차가 작지만 지레값이 큽니다. 4번은 잔차와 Cook·DFFITS가 눈에 띕니다. 5번의 작은 Cook을 '자료가 평범하다'로 바꾸어 말하면 $\boldsymbol{X}$ 공간의 특수성을 놓칩니다.



교재 수치 검산 주석. p.215 본문에는 DFFITS 기준의 수치가 2.3으로 인쇄되어 있지만, 같은 식에 $n = 20, p = 1$을 넣으면 다음과 같습니다. 같은 쪽 R 코드도 $\pm 2/3$ 선을 그립니다.

$$2\sqrt{\frac{p+1}{n-p-1}} = 2\sqrt{\frac{2}{18}} = \frac{2}{3}.$$

여기서는 해당 식을 직접 계산한 $2/3$을 사용합니다. 출판사의 공식 정오표로 확인했다는 뜻은 아닙니다. Cook 1 또는 DFFITS의 경험적 선을 넘지 않아도 상대적으로 중요한 관측을 검토할 수 있습니다.

다음 표는 **다른 모형**, 즉 교재 표 5.2의 `Nitrogen ~ Agr + Forest + Rsdntial + ComIndl`입니다. 여기서는 $k = 5$이고 전체 자료의 잔차 자유도는 15입니다. 각 제외 모형은 19행을 사용합니다.

계수의 t값	전체	4번 제외	5번 제외
절편	1.3955	1.2060	2.0817
Agr	0.3864	0.9229	0.2466
Forest	-0.9308	-0.7424	-1.4476
Rsdntial	-0.2136	-3.1470	4.0811
ComIndl	1.8620	4.4483	0.6636

Rsdntial의 부호와 t값이 크게 바뀝니다. 이는 결과가 특정 관측에 민감하다는 진단입니다. 유리한 p값을 만들기 위해 해당 관측을 삭제하는 근거로 삼지 않습니다. 단순모형에서의 5번 Cook 값과 이 네 변수 모형의 계수 변화를 섞어 같은 모형의 결론처럼 보고하지 않습니다.

확인 C05. 5번의 작은 단순모형 잔차를 보고 네 변수 모형에서도 영향이 없다고 말할 수 있는지 판단하세요.

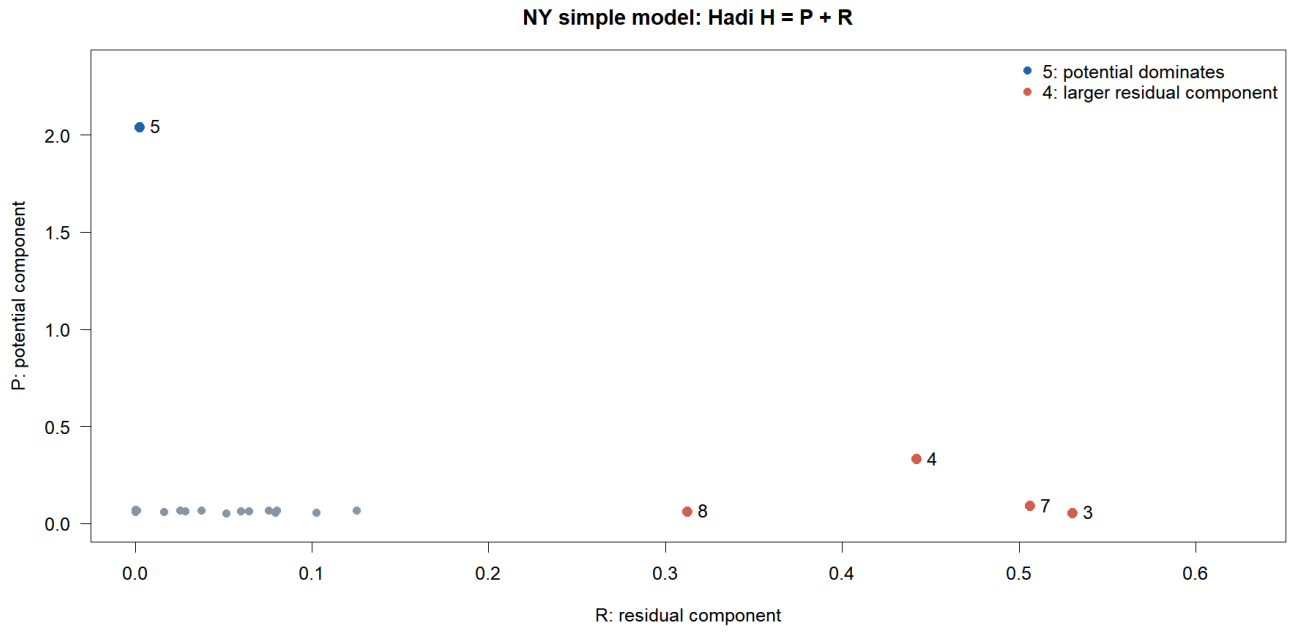
4. 잠재성–잔차도의 축을 읽기 (§5.10)

E06 · NY 4번·5번의 Hadi 성분 비교 — 핵심

계속 단순모형을 사용합니다. $P_i = h_i/(1-h_i)$는 X 공간의 잠재성 성분이고, R_i는 잔차 성분입니다.

관측	P_i	R_i	$H_i = P_i + R_i$
4 Neversink	0.329549	0.442189	0.771738
5 Hackensack	2.039602	0.002681	2.042283

예를 들어 5번은 $P_5 = 0.6710096/(1-0.6710096) \approx 2.039602$입니다. 잔차 성분이 작더라도 잠재성 성분이 남습니다. Cook·DFFITS가 잔차와 지레의 결합을 곱 형태로 반영하는 데 비해 Hadi는 두 성분을 더합니다.



가로축은 R_i, 세로축은 P_i입니다. 교재 그림 5.8 및 `plot(res, pot)` 코드와 맞춥니다. 위쪽은 잠재성이 큰 관측, 오른쪽은 잔차 성분이 큰 관측입니다. 두 축을 별도로 보고 관측이 어디에 놓이는지 설명합니다. 일반 잔차–지레값 산점도와는 축의 정의가 다릅니다.

확인 C06. 5번 점은 P-R 그림의 위쪽과 오른쪽 중 어느 방향으로 두드러지는지, 그 이유를 성분으로 설명하세요.

5. 손계산을 R 함수에 연결하기 (§5.11)

교재의 양	기본 R 또는 이번 공통 함수	결과를 읽는 기준
보통잔차 e_i	`residuals(fit)`	원래 반응 단위
내적 r_i / 외적 r_i^*	`rstandard(fit)` / `rstudent(fit)`	전체 / 삭제 오차 규모
지레값 $p_{ii} = h_i$	`hatvalues(fit)`	설계행렬의 기하
Cook / DFFITS	`cooks.distance(fit)` / `dffits(fit)`	전체 변화 / 해당 위치의 방향 있는 변화
Hadi의 세 성분	`diag_influence(fit)`	`potential`, `residual_component`, `Hadi`
실제 삭제 재적합	`diag_deleted_fit(fit, i)`	원래 모든 행의 예측 비교

교재 표 5.5의 `ols_leverage`, `ols_plot_dffits`, `ols_hadi`, `ols_plot_hadi`, `ols_plot_resid_pot`는 추가 패키지 `olsrr`의 도구입니다. 이번에는 추가 설치 부담을 줄이기 위해 지레값·Cook·DFFITS는 기본 R로, Hadi와 P-R은 교재 식 (5.24)–(5.25)을 구현한 공개 함수로 계산합니다. 함수 이름을 외우기 전에 각 열의 정의를 확인합니다.

지레값이 1이거나 삭제 후 순위가 떨어지면 일부 진단이 정의되지 않습니다. 표의 `NA`와 상태 메시지를 읽습니다. 이를 0으로 채우거나 작은 수를 분모에 임의로 넣어 정상 결과처럼 만들지 않습니다. 로버스트 `rlm`, 가중회귀, 변환·상호작용 모형은 이번 공통 OLS 함수의 입력 계약 밖입니다.

주교재 §5.8–5.11, 식 (5.17), (5.20)–(5.25), 표 5.2–5.5, 그림 5.5–5.8을 공식 데이터로 재계산·재구성했습니다. R 공식 진단 문서 · 고정 버전 함수와 정의 줄

C · 변수 효과를 분리해서 읽기

W09B · 주교재 §5.13–5.14, pp.221–228

한 설명변수의 효과는 다른 설명변수를 어떻게 다루는지에 따라 달라집니다. 원 산점도의 기울기, 첨가변수플롯의 기울기, 성분잔차플롯의 축을 구별하며 실제 계산으로 연결합니다. 여기서 말하는 효과는 적합한 모형의 조건부 선형 관계입니다.

1. 같은 경주 자료·같은 행·같은 단위

공식 `Scottish.Hills.txt`의 35개 경주를 사용합니다. Time은 초, Distance는 마일, Climb은 고도 상승량 피트입니다. $p = 2$, $k = 3$, $\nu = 35 - 3 = 32$입니다. 전체 모형의 적합식은 다음과 같습니다.

$$\widehat{\text{Time}} = -539.482907 + 373.072677\,\text{Distance} + 0.662888\,\text{Climb}.$$

Climb이 같은 조건에서 Distance 1마일의 차이는 예측 시간 약 373.073초의 차이에 대응합니다. Distance가 같은 조건에서 Climb 1피트의 차이는 약 0.662888초의 차이에 대응합니다. 거리·상승량이 모두 다른 두 경주의 실제 시간 차이를 한 계수만으로 설명하지 않습니다. 관측 연구의 이 기울기로 거리나 코스를 변경하는 인과효과를 확정하지도 않습니다.

절편은 Distance와 Climb이 모두 0인 조건의 적합값입니다. 그 조건은 관측된 경주의 범위와 거리가 있으므로 음수 절편을 실제 음수 기록 시간으로 해석하지 않습니다.

자료 버전 주석. `MASS::hills`는 시간을 분으로 기록합니다. 공식 교재 파일은 초입니다. 또한 공식 파일 23행 2859초와 `MASS::hills`의 대응 값에 60을 곱한 2857.98초에는 단위 변환 외의 차이도 있습니다. 이번 실습은 공식 교재 파일을 정본으로 고정합니다. 단위를 바꾼 근사 자료로 교재의 계수를 정확하게 재현했다고 말하지 않습니다.

2. 첨가변수플롯: 양쪽에서 같은 것을 제거한다 (§5.13.1)

Distance의 효과를 보려면 Time과 Distance 양쪽에서 Climb의 선형 부분을 제거합니다. 절편도 함께 포함합니다.

$$u_i = \text{Distance}_i - \widehat{\text{Distance}}_i(\text{Climb}), \qquad v_i = \text{Time}_i - \widehat{\text{Time}}_i(\text{Climb}).$$

가로축은 u_i, 세로축은 v_i입니다. 이 둘은 원래 거리와 시간이 아니라 각각 다른 설명변수를 선형적으로 제거한 잔차입니다. 잔차 단위는 원래 거리·시간 단위와 같습니다.

E07 · 첨가변수 기울기를 직접 만들기 — 핵심

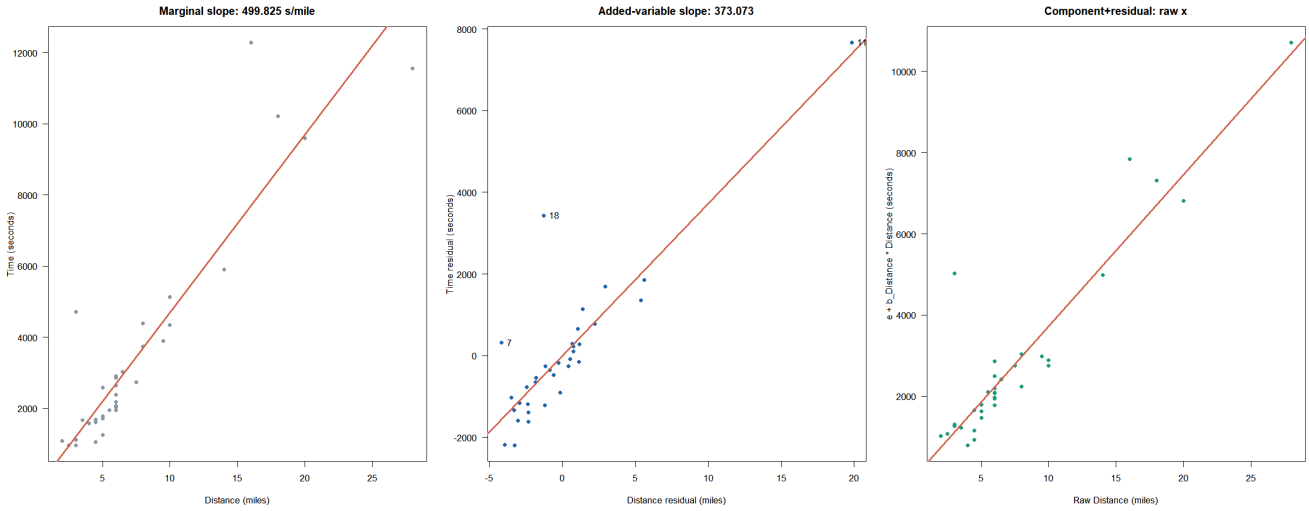
같은 35행에서 두 잔차를 만들면 다음 합을 얻습니다. 표시값은 반올림했습니다.

$$\sum_i u_i v_i \approx 222340.0652,$$
$$\sum_i u_i^2 \approx 595.9698,$$
$$\frac{\sum_i u_i v_i}{\sum_i u_i^2} \approx 373.072677 = b_{\text{Distance}}.$$

따라서 전체 다중회귀의 Distance 계수는 양쪽 잔차의 원점을 지나는 회귀 기울기와 같습니다. 잔차들은 평균 0이므로 절편을 함께 추정해도 절편은 수치 오차 범위에서 0입니다. Time만 잔차화하고 Distance는 원래 값으로 두면 이 계산이 아닙니다.

```
rx <- residuals(lm(Distance ~ Climb, data=hills))
ry <- residuals(lm(Time ~ Climb, data=hills))
sum(rx*ry) / sum(rx^2)
coef(lm(Time ~ Distance + Climb, data=hills))["Distance"]
```

R의 첫 두 줄은 각각 다른 종속변수를 가진 보조 회귀입니다. 마지막 두 줄은 같은 조건부 기울기를 서로 다른 방식으로 계산합니다. 이 코드는 설명용 E07의 검산이며, 관측·관심 변수를 바꾼 L04의 완성 답안은 포함하지 않습니다.



왼쪽은 다른 변수를 제거하지 않은 원 산점도입니다. 가운데는 두 축에서 Climb을 제거했으며 기울기가 전체 모형의 373.073초/마일입니다. 7·11·18번 같은 관측이 관계와 적합에 어떻게 관여하는지도 함께 봅니다. 이 그림은 교재 그림 5.11–5.12의 구분을 공식 파일로 재계산해 구성했습니다.

확인 C07. Distance의 첨가변수플롯에서 Time만 Climb에 대해 잔차화하면 되는지 판단하고, 필요한 두 축을 말하세요.

3. 성분잔차플롯: 원래 설명변수 축을 유지한다 (§5.13.2)

관심 변수의 적합 성분을 전체 모형의 잔차에 다시 더합니다.

$$c_{ij} = e_i + b_j x_{ij}.$$

가로축은 원래 x_{ij}, 세로축은 성분잔차 c_{ij}입니다. 첨가변수플롯과 달리 가로축을 잔차화하지 않습니다. 원래 변수 척도에서 곡선 등 평균 형태를 살펴보는 데 도움이 되지만, 다른 설명변수와의 강한 상관이 형태를 가릴 수 있으므로 이 그림만으로 모형을 확정하지 않습니다.

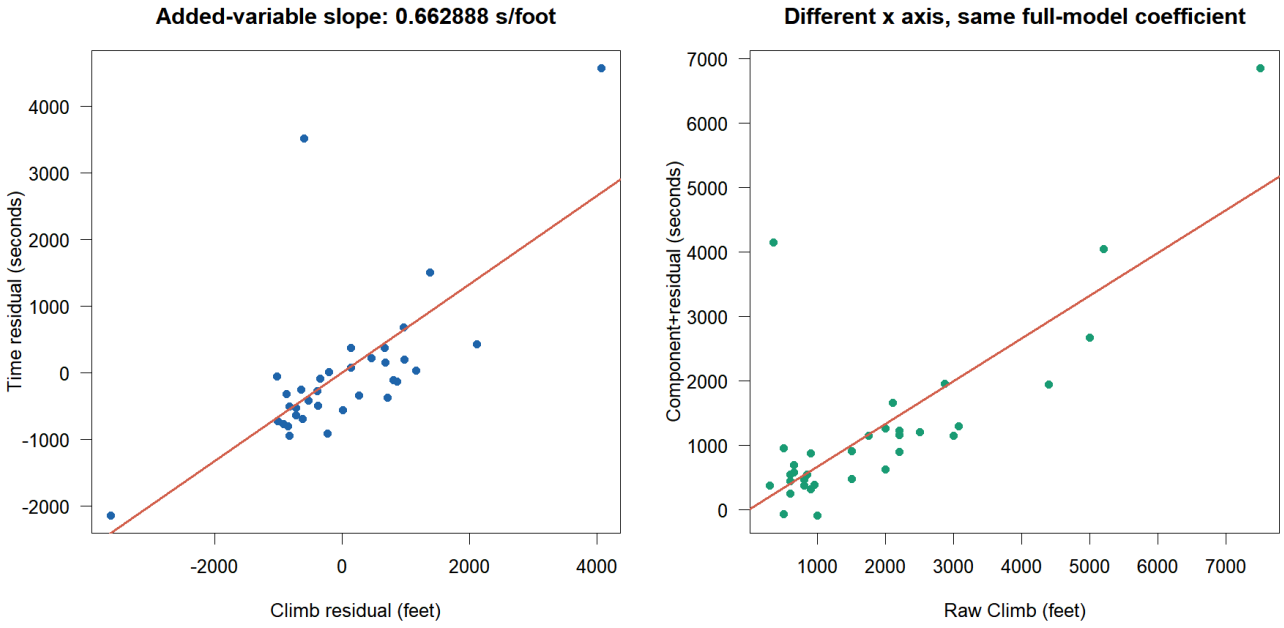
E08 · 첫 경주의 성분잔차 한 행 — 핵심

첫 경주 Greenmantle New Year Dash는 Time 965초, Distance 2.5마일, Climb 650피트입니다. 먼저 전체 모형으로 적합값과 잔차를 계산합니다.

$$\hat{y}_1 = -539.482907 + 373.072677(2.5) + 0.662888(650) \approx 824.0760,$$
$$e_1 = 965 - 824.0760 \approx 140.9240,$$
$$c_{1,\text{Distance}} = 140.9240 + 373.072677(2.5) \approx 1073.6057.$$

성분잔차도에서 이 점의 좌표는 (2.5마일, 약 1073.6057초)입니다. 1073.6057을 실제 완주 시간이라고 읽지 않습니다. 설명변수 한 성분을 잔차에 더한 진단 좌표입니다. 첨가변수플롯의 첫 좌표와 다르지만 같은 전체 모형 계수와 연결됩니다.

구분	가로축	세로축	읽는 초점
원 산점도	x_j	y	주변 관계
첨가변수플롯	x_j를 다른 변수에 회귀한 잔차	y를 같은 다른 변수에 회귀한 잔차	조정된 선형 기울기·영향 관측
성분잔차플롯	원래 x_j	$e + b_j x_j$	원래 척도에서의 성분 형태



여기서는 관심 변수를 Climb으로 바꾸었습니다. 두 축에서 제거하는 변수는 Distance입니다. 오른쪽 성분잔차도는 여전히 원래 Climb을 가로축으로 사용합니다. 기울기 단위는 초/피트입니다.

확인 C08. E08의 성분잔차 1073.6057초가 실제 관측 Time 965초와 달라도 계산 오류가 아닌 이유를 설명하세요.

4. 새 변수의 효과는 두 질문으로 읽는다 (§5.14)

새 변수의 계수에 대한 유의성과 기존 계수의 변화는 다른 질문입니다. 교재의 경우 A–D를 다음과 같이 보존합니다. '큰 변화'의 판단에는 연구 척도·불확실성과 변수의 역할을 함께 고려합니다.

교재 경우	새 계수	기존 계수	검토 방향
A	유의하지 않음	큰 변화 없음	이론적 필요 등 외부 조건과 함께 포함 여부 검토
B	유의함	큰 변화 있음	새 변수의 역할과 공선성 탐색
C	유의함	큰 변화 없음	교재가 이상적 상황으로 설명; 새 정보의 기여 검토
D	유의하지 않음	큰 변화 있음	공선성 등 구조를 점검한 뒤 결정

이 표를 p값 하나로 실행하는 자동 선택 규칙으로 사용하지 않습니다. 모형의 가정·변수 측정·분석 목적과 진단 결과를 함께 검토합니다. 새 변수가 유의하더라도 인과적 해석이나 새 자료 예측 성능이 자동으로 보장되지는 않습니다.

E09 · Distance만 적합한 뒤 Climb 추가 — 추가 반복

같은 공식 경주 35행을 사용합니다.

모형	Distance 계수 (초/마일)	Climb 계수 (초/피트)	잔차 df
`Time ~ Distance`	499.8253	포함하지 않음	33
`Time ~ Distance + Climb`	373.0727	0.662888	32

새 Climb 계수의 t값은 약 5.387060, p값은 약 6.44×10^{-6}입니다. Distance 추정값은 약 126.753초/마일 감소했습니다. 단순 기울기를 기준으로 하면 약 25.36%의 차이입니다. 같은 자료에서도 두 기울기가 답하는 조건이 다르다는 것을 E07의 잔차화가 보여 줍니다.

'새 계수 유의 + 기존 추정값 변화'는 교재 B형 상황을 검토하게 하는 관찰입니다. 위 표만으로 계수 차이에 대한 별도 유의성 검정을 한 것은 아닙니다. 두 모형의 p값을 비교해 계수 차이의 p값으로 대신하지 않습니다. 변화가 곧 교란 제거의 완료나 인과관계의 입증이라는 뜻도 아닙니다.

확인 C09. 새 Climb의 p값이 작다는 사실과 Distance 계수가 바뀌었다는 사실이 같은 검정 결과인지 구별하세요.

출처와 구현

주교재 §5.13–5.14, 그림 5.10–5.13, 식 (5.26), pp.221–228. 공식 경주 파일 · R car 첨가변수도 설명 · R car 성분잔차도 설명.

실습은 car를 필수 설치하지 않고 같은 정의를 기본 R과 diag_added_variable()·diag_component_residual()로 계산합니다. 공통 함수의 정확한 입력·출력·정의 줄.

D · 특이 관측의 처리와 로버스트 회귀 도입

W09B · 주교재 §5.12 및 §5.15, pp.220–221, 228

진단의 목적은 자료를 편하게 정리하는 것이 아니라 분석이 무엇에 의존하는지 밝히는 것입니다. 의심 관측이 오류인지, 중요한 실제 조건인지, 평균식이 잘못된 것인지 조사하고 조치의 근거를 남깁니다.

1. 특이한 점이 모형의 한계를 알려 줄 수 있다 (§5.12)

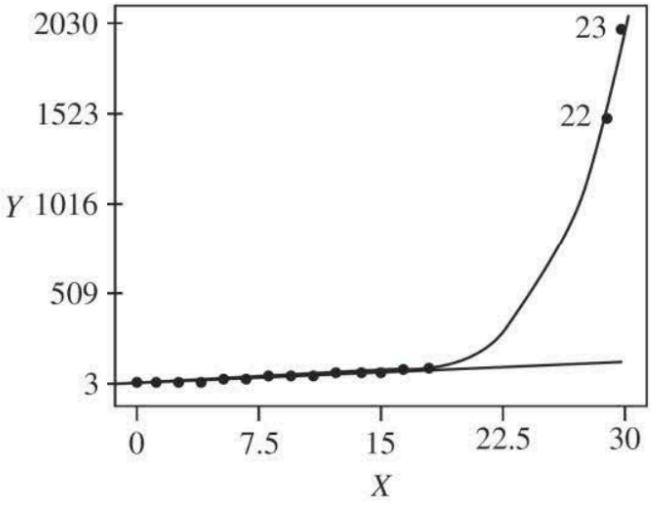


그림 5.9 개체수 Y 대 시간 X의 산점도. 곡선은 전체 데이터에 대하여 지수함수를 적합하여 얻어졌다. 직선은 22, 23번 개체를 제외하고 얻은 최소제곱직선이다.

원본 그림 발췌: 『Chatterjee 예제를 통한 회귀분석 제6판: R 활용』, 5장 p.220 그림 5.9. 교수자가 제공한 교재에서 수업에 필요한 그림만 선별했습니다. 곡선은 전체 자료에 대한 지수함수 적합이고, 직선은 22·23번을 제외한 최소제곱 적합입니다.

처음에는 대부분의 작은 값이 직선에 가까워 보이므로 22·23번을 지우면 문제가 사라지는 것처럼 보일 수 있습니다. 그러나 두 점은 성장이 가속되는 중요한 정보를 담고 있습니다. 직선이라는 평균식의 선택을 먼저 재검토해야 합니다. '잔차가 크므로 오기'라는 결론은 그림만으로 성립하지 않습니다.

확인 C10. 위 그림에서 두 관측을 제외한 직선의 잔차가 작아졌다는 사실만으로 그 제외를 정당화할 수 있는지 설명하세요.

2. 조사·수정·비교·보고의 순서

확인된 상황	가능한 조치	남길 기록
입력·측정 오류가 확인됨	근거를 보존해 정정	원값, 정정값, 확인 자료
다른 모집단·수집 조건일 가능성	조건 조사, 모형 구분 검토	관측 단위·선정 기준·조건
평균의 비선형성	변환·추가 항·다른 평균식 검토	선택 이유·원단위 해석·재진단
실제로 드문 유효 관측	유지, 민감도와 적용 범위 보고	유지 근거·포함/제외 비교
특정 관측에 민감한 추정	목적에 맞는 로버스트 적합 등 비교	추정 대상·가중치·한계
자료가 부족함	추가 조사·수집·설계 재검토	부족한 조건·수집 계획

원자료는 그대로 보존합니다. 제외 재적합은 '이 점이 없었다면'의 진단적 비교로 표시합니다. 실제 분석에서 제외를 확정하려면 별도의 내용 근거가 필요합니다. 결과가 마음에 드는 모형을 고르기 위해 관측을 반복 삭제하는 과정은 적절한 검증이 아닙니다.

3. 로버스트 회귀의 좁고 정확한 도입 (§5.15)

교재 §5.15는 로버스트 회귀를 짧게 소개하고 자세한 알고리즘을 §14.5로 넘깁니다. 이번에는 같은 경주 자료에 OLS와 `MASS::rlm`의 기본 Huber M 적합을 적용하여 계수·가중치를 비교합니다. 전체 로버스트 알고리즘의 유도는 선택 보충으로 남깁니다.

OLS의 제곱 손실은 큰 잔차에 큰 벌점을 줍니다. Huber M 적합은 표준화 잔차의 크기에 따라 큰 잔차의 상대적 기여를 줄입니다. 반복 가중 적합이라는 관점으로 이해할 수 있습니다. 이 가중치는 자료가 유효할 확률이나 학생이 임의로 정하는 삭제 여부가 아닙니다.

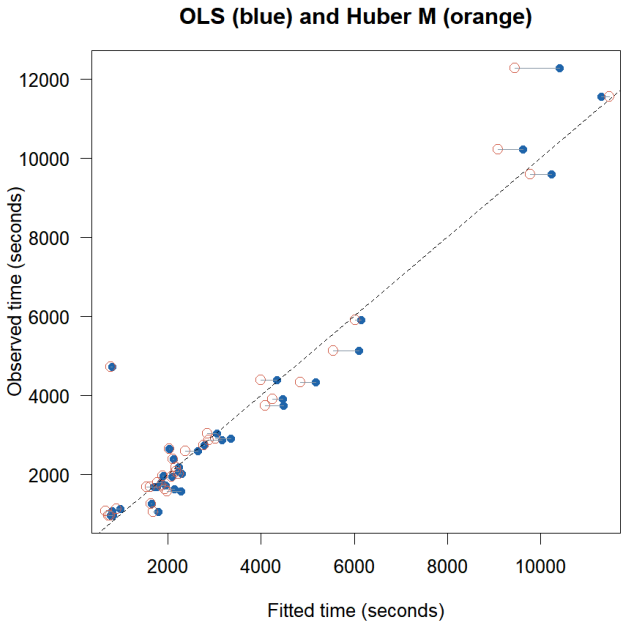
E10 · 같은 35경주의 OLS와 Huber M 비교 — 추가 반복

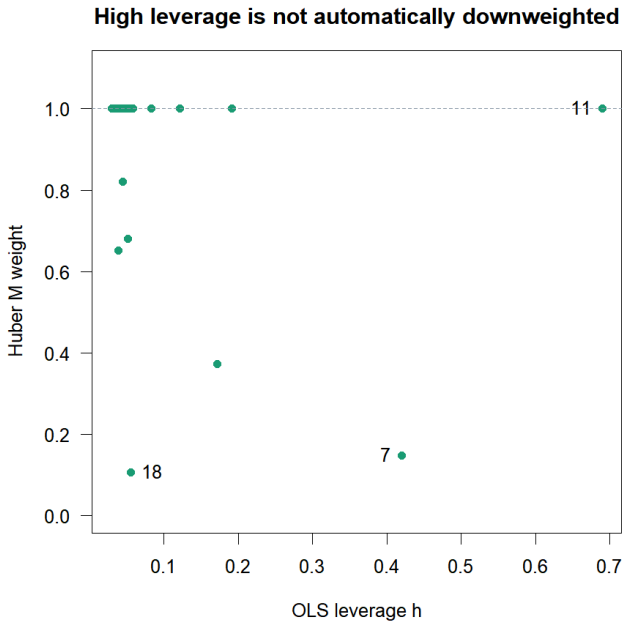
Time 초, Distance 마일, Climb 피트를 유지하며 두 모형 모두 같은 35행을 사용합니다.

계수	OLS	Huber M (MASS::rlm)
절편 (초)	-539.482907	-576.383657
Distance (초/마일)	373.072677	393.037461
Climb (초/피트)	0.662888	0.497789

공식 자료의 이 적합은 수렴했습니다. 대표 관측의 가중치를 OLS의 지레값과 나란히 봅니다.

경주 번호	OLS 지레값	Huber M 가중치
7	0.420435	0.148497
11	0.689816	1.000000
18	0.055355	0.106648





11번은 지레값이 높지만 이 Huber M 적합에서 가중치 1을 유지합니다. **잔차에 기초한 M 가중치가 높은 지레값을 모두 자동으로 낮추지는 않습니다.** 교재의 로버스트 접근에 대한 일반적 소개와 이번에 실제 사용한 Huber M의 성질을 구별합니다. 다른 로버스트 방법들의 성질을 이 한 방법으로 대표시키지 않습니다.

```
robust_fit <- MASS::rlm(Time ~ Distance + Climb, data=hills)
robust_fit$converged
coef(robust_fit)
robust_fit$w
robust_fit$df.residual
```

rlm의 df.residual은 의도적으로 NA입니다. 이를 일반 lm의 자유도·통상적인 t/F 검정으로 읽거나, 이번 OLS 전용 영향력 함수에 그대로 넣지 않습니다. 로버스트 회귀로 계수를 추정하는 일과 OLS 계수에 로버스트 표준오차를 붙이는 일도 다른 절차입니다. 좋은 평균식·수집 과정·새 자료 검증의 필요성은 남습니다.

확인 C11. 지레값이 가장 큰 11번의 가중치가 1이라는 사실이 계산 실패를 의미하는지 설명하세요.

4. 마지막은 입력–함수–표·그림 연결

설치 없는 R 실습에서 계산한 뒤 누적 Shiny 편집기를 엽니다. 기존 차시 기능에 W09B 진단·변수 효과·로버스트 비교를 더했습니다.

1. NY 단순모형에서 관측 4와 5를 선택하고 표와 P-R 그림의 같은 관측을 연결합니다.
2. 경주 자료에서 관심 변수를 Distance와 Climb으로 바꾸고 두 진단도의 축을 확인합니다.
3. L06에서 출력 연결 한 곳을 직접 수정합니다. Run 후 입력을 바꾸어 수정이 반영되는지 봅니다.
4. 관찰표 CSV와 편집한 R 코드를 내려받고, 원상 복구 후 준비 단계부터 다시 실행합니다.

확인 C12. 앱에서 바꾼 입력 하나, 이를 읽는 공통 함수 하나, 달라진 출력 하나를 연결해 말하세요.

브라우저에 보관한 코드는 서버에 제출된 결과가 아닙니다. 초기 엔진·패키지 준비에는 인터넷이 필요합니다. 다운로드한 R/QMD를 사용할 때에는 data 폴더를 함께 보관합니다. 온라인 R, 데스크톱 R/QMD, R Colab은 대체 실행 경로입니다.

학습을 마무리하며

출구 X01: 지레값이 큰데 Cook은 작은 관측을 다른 관측 하나에 적용해 설명합니다.

출구 X02: Climb의 첨가변수플롯에서 두 축을 어떤 두 회귀로 만드는지 말합니다.

출구 X03: 특이 관측을 유지·제외하거나 평균식을 바꿀 때, 진단 수치 외에 필요한 근거 하나를 제시합니다.

주교재 §5.12, §5.15 및 그림 5.9. MASS 공식 rlm 문서 · MASS hills의 공식 단위. 표와 로버스트 그림은 공식 교재 파일을 사용한 실제 R 계산입니다.

W09B · 계산과 해석 기록지

먼저 L01–L06을 풀고 L07–L12를 반복·확장에 사용합니다. 각 문제는 필요한 조건을 다시 제시합니다. 앞 문제의 답을 옮겨야 다음 문제를 풀 수 있는 구조가 아닙니다. 예상 → 식과 대입 → R 출력 → 한 문장 해석 → 추가 확인을 남깁니다. 답을 먼저 보지 않고 계산한 뒤 설명용 예제와 비교합니다.

공통 기호: p는 설명변수 수, $k = p + 1$은 절편 포함 계수 수, $\nu = n - k$입니다. 모든 기본 계산은 비가중·완전열계수·절편 포함 OLS입니다. h_i는 교재의 p_{ii}입니다. 이 기록지는 연습의 완성 풀이를 포함하지 않습니다. 별도 Q01–Q10는 복습용 개념 점검이며 그 해설은 별도 제공됩니다.

L01 · 한 행의 잔차와 표준화 — 필수

교육용 6행 자료의 적합식은 $\hat{y} = 1 + 0.8x$입니다. $n = 6, k = 2, \nu = 4$, $\bar{x} = 2.5, S_{xx} = 17.5, \mathrm{SSE} = 0.8$입니다. 3행은 $x = 2, y = 2$입니다. 적합값, 보통잔차, 지레값, 내적 표준화잔차를 손으로 구하고 방향과 단위를 설명하세요.

마지막 단계 빈칸: $r_3 = e_3/(\square\sqrt{1 - h_3})$.

힌트: $s^2 = \mathrm{SSE}/\nu$, $h_3 = 1/n + (x_3 - \bar{x})^2/S_{xx}$. 분자의 관측값과 적합값 순서를 확인합니다.

자가 점검: 잔차는 원래 반응 단위, 표준화잔차는 무단위여야 합니다. R은 검산에 사용하고 먼저 식을 적습니다.

예상: _____

계산·대입: _____

R과 비교·설명: _____

L02 · Cook·DFFITS·Hadi 계산 사슬 — 필수

같은 6행 모형에서 **2행의** $e_2 = 0.2, h_2 = 0.295238095238$, $\mathrm{SSE} = 0.8, k = 2, \nu = 4$입니다. $s^2, s^2_{(2)}, r_2, r_2^*$를 구하고 Cook·DFFITS·Hadi의 P, R, H를 계산하세요. E04의 4행과 비교하여 무엇이 달라졌는지 설명하세요.

힌트: 삭제 분산의 분모는 $\nu - 1$입니다. Hadi에는 $d_2^2 = e_2^2/\mathrm{SSE}$를 사용합니다. r_2^2를 대신 넣지 않습니다.

자가 점검: Cook은 음수가 아니고, Hadi는 두 성분의 합입니다. DFFITS의 부호는 적합값 변화의 방향과 연결합니다.

예상: _____

계산·대입: _____

R과 비교·설명: _____

L03 · 다른 강의 P-R 좌표와 추가 확인 — 필수

NYRivers 단순모형 `Nitrogen ~ ComIndl`에서 $n = 20, k = 2, \nu = 18$입니다. 7번 강의 $e_7 \approx 0.6994921442, h_7 \approx 0.0826057856$, 전체 $\mathrm{SSE} \approx 2.5953991583$입니다. d_7^2, P_7, R_7, H_7를 계산하고 P-R 좌표의 가로·세로 순서와 해석을 적으세요. 이 결과만으로 삭제를 결정할 수 있는지도 설명하세요.

힌트: $P = h/(1-h)$, $R = k\{d^2/(1-d^2)\}/(1-h)$. 가로축은 R, 세로축은 P입니다.

자가 점검: 표의 `potential`, `residual_component`와 좌표 순서를 대조합니다. 숫자의 순위와 내용 근거를 구분합니다.

계산·좌표: _____

해석·추가 확인: _____

L04 · Climb의 첨가변수 기울기 — 필수

공식 경주 35행의 `Time ~ Distance + Climb`을 사용합니다. Climb의 효과를 보려면 Climb과 Time 양쪽에서 절편·Distance의 선형 부분을 제거합니다. 그 잔차를 각각 u, v라 할 때 $\sum u^2 \approx 51203719.8608$, $\sum uv \approx 33942330.9833$입니다. 기울기를 계산하고 단위를 쓰세요. 두 보조 회귀의 식과 첨가변수도의 두 축도 적으세요.

힌트: 한쪽만 잔차화하지 않습니다. 같은 35행과 같은 보조 설명변수를 사용합니다.

자가 점검: 전체 모형의 관심 계수와 비교합니다. Climb은 피트이며 경사각이 아닙니다.

두 보조 회귀: _____

계산·단위·설명: _____

L05 · 둘째 경주의 성분잔차 — 필수

둘째 경주 Carnethy는 Time 2901초, Distance 6마일, Climb 2500피트입니다. 전체 적합식은 $\widehat{\mathrm{Time}} = -539.482907 + 373.072677\mathrm{Distance} + 0.662888\mathrm{Climb}$입니다. 적합값과 잔차를 먼저 구하고, Distance의 성분잔차와 그림의 좌표를 계산하세요. 성분잔차가 실제 완주 시간과 다른 이유도 설명하세요.

힌트: $c = e + b_{\mathrm{Distance}}\mathrm{Distance}$. 전체 적합값을 성분잔차로 대신하지 않습니다.

자가 점검: 가로축은 원래 Distance입니다. 세로축의 단위는 초입니다. 마지막 검산은 반올림하지 않은 R 계수로 합니다.

계산·좌표: _____

R과 비교·설명: _____

L06 · 앱의 출력 연결 하나 바꾸기 — 필수

누적 Shiny 편집기의 W09B_L06 표식을 찾습니다. 선택한 강의 요약 출력은 현재 지레값을 표시합니다. 같은 관측 선택 입력을 유지하면서 이 출력을 DFFITS와 그에 맞는 라벨로 바꾸세요. 기본 모형은 NY 단순모형입니다. 4번과 5번을 차례로 선택하고 방향·크기를 설명하세요.

힌트: 입력 w9_row → diag_influence()가 만든 표 → output$w9_selected 순서로 따라갑니다. 계산 함수를 통째로 다시 만들지 않습니다.

자가 점검: 라벨과 값의 정의가 맞아야 합니다. Run 후 두 관측에서 결과가 달라지는지 확인하고 CSV·R 코드를 내려받습니다. 원상 복구 후 처음부터 실행합니다.

수정한 연결: _____

두 관측의 예상·실제·설명: _____

L07 · W06A의 다른 부서로 전이 — 확장

rating ~ complaints + learning의 두 번째 부서는 관측 rating 63%, 적합값 약 62.4603668641%, $h_2 \approx 0.0350361699, s \approx 6.8167793269$입니다. 보통잔차와 내적 표준화 잔차를 구하고 %와 %p, 표준화 후 단위를 구별하세요.

힌트: 먼저 $63 - 62.4603668641$을 계산합니다. 자가 점검: 내적 표준화 분모에 $\sqrt{1 - h_2}$가 있어야 합니다.

계산·설명: _____

L08 · 정규성 진단 코드의 대상 오류 — 확장·디버깅

경주 전체모형의 조건부 오차 정규성을 점검하려는 학생이 `qqnorm(hills$Distance); qqline(hills$Distance)`를 실행했습니다. 이 코드가 무엇을 그리는지 설명하고, 목적에 맞는 잔차 Q-Q 코드로 수정하세요. 수정한 그림의 직선 근사만으로 모든 가정을 입증할 수 있는지도 설명하세요.

힌트: 관심 대상이 설명변수의 주변 분포인지, 적합 모형의 잔차인지 먼저 적습니다. 자가 점검: 사용할 모형은 `fit_hills`입니다.

오류·수정·해석: _____

L09 · 삭제 민감도와 분석상 제외의 차이 — 확장

NY 네 변수 모형을 전체 자료와 5번 제외 자료에 각각 적합해 Rsdntial 계수·t값·잔차 자유도를 비교하세요. 단순모형의 Cook 표를 이 결과에 그대로 붙이면 안 되는 이유를 적고, 실제 제외를 결정하기 전에 필요한 내용 근거 두 가지를 제시하세요.

힌트: `Nitrogen ~ Agr + Forest + Rsdntial + ComIndl`을 두 번 적습니다. 자가 점검: 두 모형의 관측 수와 계수 수를 각각 확인합니다.

비교표·근거: _____

L10 · 새 변수 추가의 네 상황 — 확장

다음은 추가 구성한 판단 상황입니다. 새 변수의 계수 p값이 0.42이고, 기존 주요 계수 추정값은 0.8에서 2.6으로 바뀌며 표준오차도 커졌습니다. 교재 A–D의 어느 상황을 우선 검토할지 쓰고, 공선성·연구 목적과 관련해 무엇을 더 조사할지 설명하세요. 이 숫자만으로 새 변수를 자동 삭제하거나 인과를 주장할 수 있는지도 판단하세요.

힌트: 새 계수의 유의성과 기존 계수의 변화를 두 칸으로 분리합니다. 자가 점검: 경우의 문자만 쓰지 않고 추가 확인을 남깁니다.

분류·해석: _____

L11 · Huber 가중치의 의미 — 확장

같은 경주 Huber M 적합에서 11번의 OLS 지레값은 약 0.689816, 가중치는 1이고, 18번은 지레값 약 0.055355, 가중치 약 0.106648입니다. 두 결과가 모순인지 설명하고, 로버스트 회귀와 OLS의 로버스트 표준오차를 구별하세요. `rlm`의 `df.residual=NA`를 일반 `lm` t/F로 바꾸어 읽으면 안 되는 이유도 적으세요.

힌트: 이번 M 가중치는 잔차에 기초합니다. 자가 점검: 모든 로버스트 방법을 같은 방식으로 일반화하지 않습니다.

해석·주의: _____

L12 · 정의되지 않는 진단과 기록 — 확장

추가 구성 자료 $x = (0, 0, 0, 0, 0, 1)$, $y = (1, 3, 2, 5, 4, 7)$에 절편 포함 `y ~ x`를 적합합니다. 마지막 관측의 h를 확인하고 이를 제외했을 때 설계행렬의 순위가 어떻게 되는지 조사하세요. 어떤 진단을 정상 숫자로 보고하면 안 되는지, `NA`를 0으로 바꾸면 왜 잘못인지 설명하세요.

힌트: 마지막 행을 제외하면 x의 독립 변동이 남는지 확인합니다. 자가 점검: 원자료는 보존하고 상태 메시지를 함께 기록합니다.

계산·상태·설명: _____

개념 점검 질문 원문

Q01. 오차와 잔차는 같은 관측 가능한 양인가?

Q02. 정규성 가정은 설명변수나 반응변수의 주변 분포에 관한 주장인가?

Q03. 높은 지레값은 반드시 큰 Cook의 거리를 뜻하는가?

Q04. 잔차가 0인 관측의 Hadi 성분은 모두 0인가?

Q05. 가면문제와 수렁문제는 무엇이 다른가?

Q06. 첨가변수플롯에서는 왜 두 축을 같은 다른 변수에 대해 잔차화하는가?

Q07. 성분잔차플롯의 가로·세로축은 무엇인가?

Q08. 새 변수의 유의성과 기존 계수의 변화는 같은 검정인가?

Q09. 지수성장 그림의 큰 두 관측을 자동 삭제해도 되는가?

Q10. Huber M 적합은 모든 높은 지레점을 자동으로 낮은 가중치로 처리하는가?

주교재 §5.1–5.15의 개념을 이번 수업 자료와 추가 구성 연습으로 연결했습니다. L10·L12는 추가 교육용 상황입니다. 온라인 R · 누적 앱 편집기

W09B · 수식·분모·자유도 지도와 선택 유도

첫 부분은 계산할 때 곁에 두는 지도입니다. 뒤의 행렬 유도는 선택 보충입니다. 긴 유도를 먼저 외우기보다 E02→E04의 같은 한 행 계산을 설명할 수 있는지 확인합니다.

1. 계산 지도

전제는 절편 포함·비가중·완전열계수 OLS이며 같은 관측과 단위를 사용합니다. p는 설명변수 수, $k = p + 1$, $\nu = n - k > 1$입니다.

양	정의	분모·해석
보통잔차	$e_i = y_i - \hat{y}_i$	반응 단위
오차 규모	$s^2 = \mathrm{SSE}/\nu$	전체 자료
내적 표준화잔차	$r_i = e_i/(s\sqrt{1-h_i})$	전체 오차 규모
삭제 오차 규모	$s^2_{(i)} = \{\mathrm{SSE} - e_i^2/(1-h_i)\}/(\nu-1)$	삭제 후 자유도
외적 표준화잔차	$r_i^* = e_i/(s_{(i)}\sqrt{1-h_i})$	분자는 원래 e_i
Cook	$C_i = (r_i^2/k)h_i/(1-h_i)$	전체 오차 규모, 음이 아님
DFFITS	$r_i^*\sqrt{h_i/(1-h_i)}$	삭제 오차 규모, 방향이 있음
Hadi 정규화	$d_i^2 = e_i^2/\mathrm{SSE}$	내적 잔차 제곱과 다름
잠재성 성분	$P_i = h_i/(1-h_i)$	X 공간
잔차 성분	$R_i = \{k/(1-h_i)\}d_i^2/(1-d_i^2)$	P-R 가로축
Hadi	$H_i = P_i + R_i$	P-R 세로축은 P_i

모든 진단이 항상 정의되는 것은 아닙니다. $h_i = 1$, 삭제 후 순위 저하, 0에 가까운 오차분산 등은 별도 상태로 보고합니다. 계산 가능한 Cook과 계산 불가능한 DFFITS가 함께 존재할 수도 있습니다. NA는 영향력 0의 다른 표기가 아닙니다.

모형	n	p	k	ν
6행 교육용 y ~ x	6	1	2	4
NY 단순모형	20	1	2	18
NY 네 변수 모형	20	4	5	15
경주 두 변수 모형	35	2	3	32
attitude 복습 모형	30	2	3	27

2. 잔차 분산에 지레값이 들어가는 이유 — 선택

$$\hat{\beta} = (X^\top X)^{-1} X^\top y, \quad \hat{y} = Hy, \quad e = (I - H)y, \quad H = X(X^\top X)^{-1} X^\top.$$

오차의 조건부 공분산이 $\sigma^2 I$이면, H의 대칭성과 멱등성으로 다음이 성립합니다.

$$\begin{aligned} \mathrm{Var}(e \mid X) &= (I - H)\sigma^2 I (I - H)^\top \\ &= \sigma^2 (I - H), \\ \mathrm{Var}(e_i \mid X) &= \sigma^2 (1 - h_i). \end{aligned}$$

그래서 보통잔차를 모든 관측에서 같은 s만으로 나누면 관측별 잔차 분산의 차이를 보정하지 못합니다. 내적 표준화의 $\sqrt{1 - h_i}$는 이 차이와 연결됩니다. 이 대수적 유도가 모형의 가정을 자료에서 입증해 주는 것은 아닙니다.

3. 삭제 재적합과 Cook의 두 식 — 선택

x_i를 절편을 포함한 열벡터로 놓고, 삭제 후에도 설계행렬의 순위가 유지된다고 가정합니다.

$$\hat{\beta} - \hat{\beta}_{(i)} = \frac{(X^\top X)^{-1} x_i e_i}{1 - h_i}.$$

원래 모든 행에서 예측 차이는 $X(\hat{\beta} - \hat{\beta}_{(i)})$입니다.

$$\begin{aligned} \| \hat{y} - \hat{y}_{(i)} \|^2 &= \frac{e_i^2}{(1 - h_i)^2} x_i^\top (X^\top X)^{-1} X^\top X (X^\top X)^{-1} x_i \\ &= \frac{e_i^2 h_i}{(1 - h_i)^2}. \end{aligned}$$

이 식을 $k s^2$로 나누면 Cook의 정의식과 잔차·지레값을 사용한 식이 일치합니다.

$$C_i = \frac{e_i^2 h_i}{k s^2 (1 - h_i)^2} = \frac{r_i^2}{k} \frac{h_i}{1 - h_i}.$$

4. DFFITS의 부호와 삭제 분모 — 선택

관측 i 위치에서는 $\hat{y}_i - \hat{y}_{i(i)} = h_i e_i / (1 - h_i)$입니다.

$$\begin{aligned} \mathrm{DFFITS}_i &= \frac{h_i e_i / (1 - h_i)}{s_{(i)} \sqrt{h_i}} \\ &= \frac{e_i}{s_{(i)} \sqrt{1 - h_i}} \sqrt{\frac{h_i}{1 - h_i}} = r_i^* \sqrt{\frac{h_i}{1 - h_i}}. \end{aligned}$$

Cook의 r_i^2와 달리 DFFITS는 r_i^*의 부호를 유지합니다. 외적 표준화의 분자를 삭제예측잔차 $e_i / (1 - h_i)$로 바꾸면 이 정의와 달라집니다.

5. 첨가변수 기울기의 행렬 지도 — 선택

관심 변수 열을 x_j, 절편을 포함한 나머지 설계행렬을 Z라고 둡니다. 같은 35행의 같은 행렬을 사용합니다.

$$M_Z = I - Z(Z^\top Z)^{-1}Z^\top, \quad u = M_Z x_j, \quad v = M_Z y, \qquad b_j = \frac{u^\top v}{u^\top u}.$$

양쪽에서 Z의 선형 부분을 제거하면 관심 변수에 남은 독립 변동과 반응에 남은 변동을 비교하게 됩니다. u만 또는 v만 다른 관측 집합에서 만들면 이 등식의 전제가 깨집니다. 이번 함수는 한 `lm`의 모형행렬에서 좌표를 함께 만들어 관측 정렬을 보존합니다.

성분잔차는 별도의 좌표 $c_j = e + b_j x_j$입니다. $v - b_j u = e$이지만 c_j의 가로축은 x_j이므로 첨가변수도의 점들을 그대로 옮겨 그린 것이 아닙니다.

주교재 §5.3, §5.8–5.10, §5.13 및 표준 OLS 항등식을 계산 학습용으로 정리했습니다. 기본 R 진단 정의. 로버스트 적합은 이 OLS 지도에 그대로 대입하지 않습니다.

회귀진단의 완성: 잔차·영향력·변수 효과를 직접 계산하기 · 퀴즈 해설

W09B 기록지의 Q01–Q10 원문과 대응하는 별도 개념 해설. L01–L12의 완성 풀이와 구별함.

1. 오차와 잔차는 같은 관측 가능한 양인가?

다릅니다. ε_i는 참 조건부 평균으로부터의 오차이고, $e_i = y_i - \hat{y}_i$는 자료로 추정한 적합값과의 차이입니다. 잔차합 0은 절편 포함 OLS의 대수적 성질이며 조건부 오차 평균 가정의 입증이 아닙니다.

2. 정규성 가정은 설명변수나 반응변수의 주변 분포에 관한 주장인가?

아닙니다. 정확한 소표본 t/F 추론의 정규성은 주어진 X에서 오차의 조건부 분포에 관한 가정입니다. 잔차 Q-Q는 이를 살펴보는 단서이며 주변 X 또는 Y의 정규성을 요구하는 주장이 아닙니다.

3. 높은 지레값은 반드시 큰 Cook의 거리를 뜻하는가?

아닙니다. $C_i = (r_i^2/k)h_i/(1-h_i)$이므로 지레값과 잔차가 함께 관여합니다. 지레값이 높아도 잔차가 작으면 Cook이 작을 수 있습니다. 영향력은 해당 모형과 비교 결과에 대해 읽습니다.

4. 잔차가 0인 관측의 Hadi 성분은 모두 0인가?

아닙니다. $e_i = 0$이면 잔차 성분 R_i는 0이지만, $h_i > 0$이면 잠재성 성분 $P_i = h_i/(1-h_i)$가 남습니다. 따라서 $H_i = P_i + R_i$가 0일 필요가 없습니다. $h_i = 1$인 경계는 별도로 정의 불가 상태를 확인합니다.

5. 가면문제와 수렁문제는 무엇이 다른가?

가면은 살펴볼 특이 관측을 놓치는 경우이고, 수렁은 특이하지 않은 관측을 특이하다고 잘못 표시하는 경우입니다. 일부 관측이 적합을 당기고 서로 가릴 수 있으므로 잔차·지레값·영향력·내용 근거를 함께 검토합니다.

6. 첨가변수플롯에서는 왜 두 축을 같은 다른 변수에 대해 잔차화하는가?

다른 변수의 선형 부분을 양쪽에서 같은 조건으로 제거해 관심 변수에 남은 변동과 반응에 남은 변동을 비교하기 위해서입니다. 같은 행의 두 잔차 기울기는 전체 모형의 해당 계수와 일치합니다. 한쪽만 제거하면 그 계산이 아닙니다.

7. 성분잔차플롯의 가로·세로축은 무엇인가?

가로축은 원래 x_j, 세로축은 $e + b_j x_j$입니다. 세로축은 실제 반응값이 아니라 진단용 성분잔차입니다. 두 축을 모두 잔차화하는 첨가변수도와 구별합니다.

8. 새 변수의 유의성과 기존 계수의 변화는 같은 검정인가?

다른 질문입니다. 새 계수의 t검정은 그 모형에서 새 계수가 0인지에 관한 것이고, 기존 계수의 변화는 조건과 모형 변경의 민감도에 관한 것입니다. 두 모형의 p값을 비교해 계수 차이 검정으로 대신하거나 인과를 단정하지 않습니다.

9. 지수성장 그림의 큰 두 관측을 자동 삭제해도 되는가?

자동 삭제할 수 없습니다. 교재 그림5.9의 큰 관측은 지수성장이라는 평균 형태의 중요한 정보를 담을 수 있습니다. 측정 오류·모집단·평균식 등을 조사하고 원자료를 보존하며 조치 근거를 남깁니다.

10. Huber M 적합은 모든 높은 지레점을 자동으로 낮은 가중치로 처리하는가?

아닙니다. 이번 Huber M의 상대 가중치는 적합 잔차에 기초합니다. 높은 지레값 자체가 모두 낮은 가중치를 받는 것은 아닙니다. 수렴·가중치·방법의 한계를 확인하고 일반 lm t/F 또는 로버스트 표준오차와 구별합니다.