W10A A · 한 점에서 잔차와 진단 그림까지

회귀분석의 이해 · 2026년 11월 2일 · 10주차 1차시

지난 자료를 이해하지 못했어도 여기서 다시 시작합니다. 먼저 점 하나를 읽고, 작은 숫자를 계산한 다음 수식으로 정리합니다. 이 본문 → B 지레·영향력 → C 변수 효과·관측 처리 → D 범주형 예측변수 순서로 읽습니다. 설명용 완성 예제 E01–E12와 직접 풀 연습 L01–L12를 구분합니다. 연습 L01–L06을 먼저 하고, 나머지는 반복 학습에 사용합니다. 새 성적 반영 과제나 제출 기한은 없습니다.

1. 관측값·예측값·잔차: 같은 x에서 세로 차이를 읽기

관측값은 실제로 얻은 숫자입니다. **예측값 또는 적합값**은 자료로 구한 회귀식이 그 조건에서 내놓는 숫자입니다. 적합 직선의 높이를 읽으면 됩니다. **잔차**는 관측값에서 적합값을 뺀 차이입니다. 직선과의 수직 거리에 방향을 붙인 것이며, 점에서 직선까지의 가장 짧은 사선 거리가 아닙니다.

다음은 손계산을 위해 추가 구성한 자료입니다. 실제 조사 결과가 아니며 x와 y의 단위는 교육용 단위입니다. 한 행은 하나의 관측입니다.

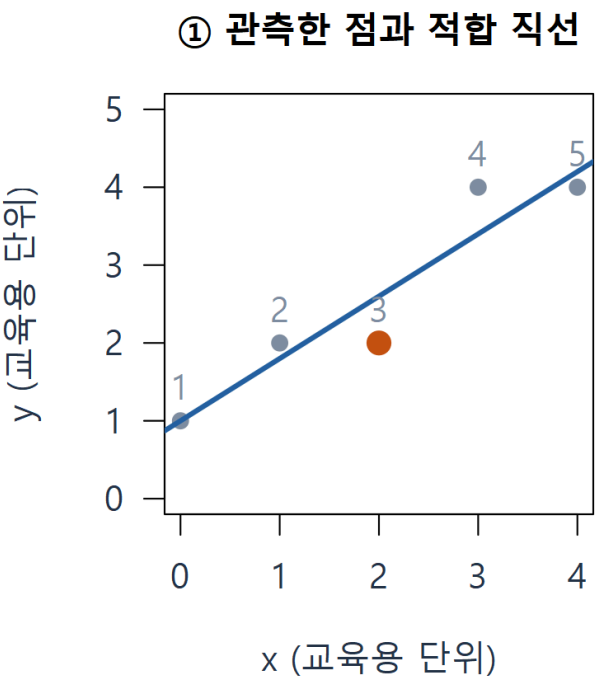
관측 번호	x	관측 y	적합값	잔차
1	0	1	1.0	0.0
2	1	2	1.8	0.2
3	2	2	2.6	-0.6
4	3	4	3.4	0.6
5	4	4	4.2	-0.2

E01 · 3번 점의 잔차를 끝까지 계산하기

이 다섯 점의 최소제곱 적합식은 다음과 같습니다. 모자 기호는 관측 자체가 아니라 추정한 값을 나타냅니다.

$$\hat{y} = 1 + 0.8x, \qquad e_i = y_i - \hat{y}_i.$$

3번 점에서 x=2이므로 예측값은 $1 + 0.8 \times 2 = 2.6$입니다. 실제 y는 2이므로 잔차는 $2 - 2.6 = -0.6$입니다. 음수는 관측이 예측보다 낮다는 뜻입니다. 잔차의 단위는 y의 단위와 같습니다.



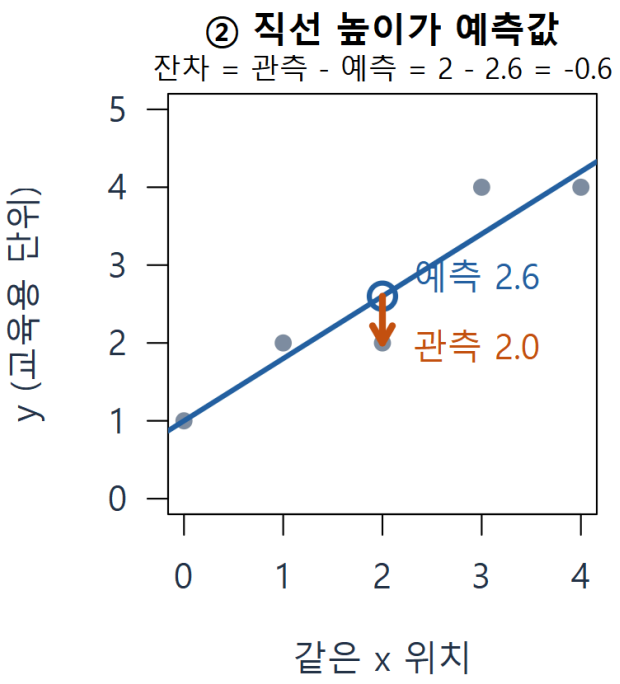


그림 읽기: 회색 점은 관측, 파란 선은 적합 직선입니다. 빈 원은 같은 x에서 읽은 예측값이며, 주황 화살표가 잔차의 방향과 크기를 보여 줍니다. 출처: 위 추가 구성 자료를 R로 계산한 자체 그림.

확인 C01. 잔차가 음수인 것은 관측이 예측보다 높다는 뜻인가요, 낮다는 뜻인가요? 3번의 두 숫자를 짚으며 설명하세요.

2. 오차와 잔차가 다른 이유

조건부 평균은 x 등 조건을 정했을 때 모집단의 y가 평균적으로 놓이는 위치입니다. 참 조건부 평균은 보통 모릅니다. 그래서 자료로 회귀식을 추정합니다.

$$\underbrace{Y_i}_{\text{관측}} = \underbrace{\beta_0 + \beta_1 x_i}_{\text{참 조건부 평균}} + \underbrace{\varepsilon_i}_{\text{오차}}, \qquad \underbrace{e_i}_{\text{계산 가능한 잔차}} = Y_i - \hat{y}_i.$$

오차는 참 평균과의 차이, 잔차는 추정한 평균과의 차이입니다. 실제 자료에서 우리가 바로 계산하는 것은 잔차입니다. 설명용 모의실험에서는 생성한 참 평균을 알기 때문에 오차도 볼 수 있지만, 실제 자료에서도 참 오차를 관찰한 것처럼 말하지 않습니다.

절편을 포함한 최소제곱 적합에서는 잔차의 합이 0이 됩니다. 곡선 관계에 잘못 직선을 적합해도 이 성질은 생깁니다. 따라서 잔차합 0은 모형이 맞다는 보증이 아닙니다.

3. 지레값 h: 내 관측값이 내 예측값을 얼마나 끌어당기는가

지레값을 배우는 첫 질문은 다음과 같습니다. 다른 조건은 고정하고 **한 점의 y만 바꾸어 다시 적합하면, 그 점의 자기 예측값은 얼마나 변할까요?** 그 전달 비율을 h_i라고 부릅니다. 교재에서는 같은 값을 p_{ii}로 씁니다. i는 관측 번호입니다.

E02 · 같은 +10 이동, 서로 다른 자기 예측 변화

먼저 원래 자료로 돌아온 뒤 3번의 y만 2에서 12로 바꿉니다. 새 직선을 적합하면 3번의 예측은 2.6에서 4.6으로 바뀝니다. 관측이 10 증가할 때 자기 예측은 2 증가했습니다. 이 점의 h는 0.2입니다.

별도의 비교에서는 다시 원래 자료로 돌아온 뒤 5번의 y만 4에서 14로 바꿉니다. 자기 예측은 4.2에서 10.2로, 6 증가합니다. 이 점의 h는 0.6입니다. 두 점을 동시에 움직인 결과가 아닙니다.

$$\Delta \hat{y}_i = h_i \Delta y_i, \qquad \Delta e_i = (1 - h_i)\Delta y_i.$$

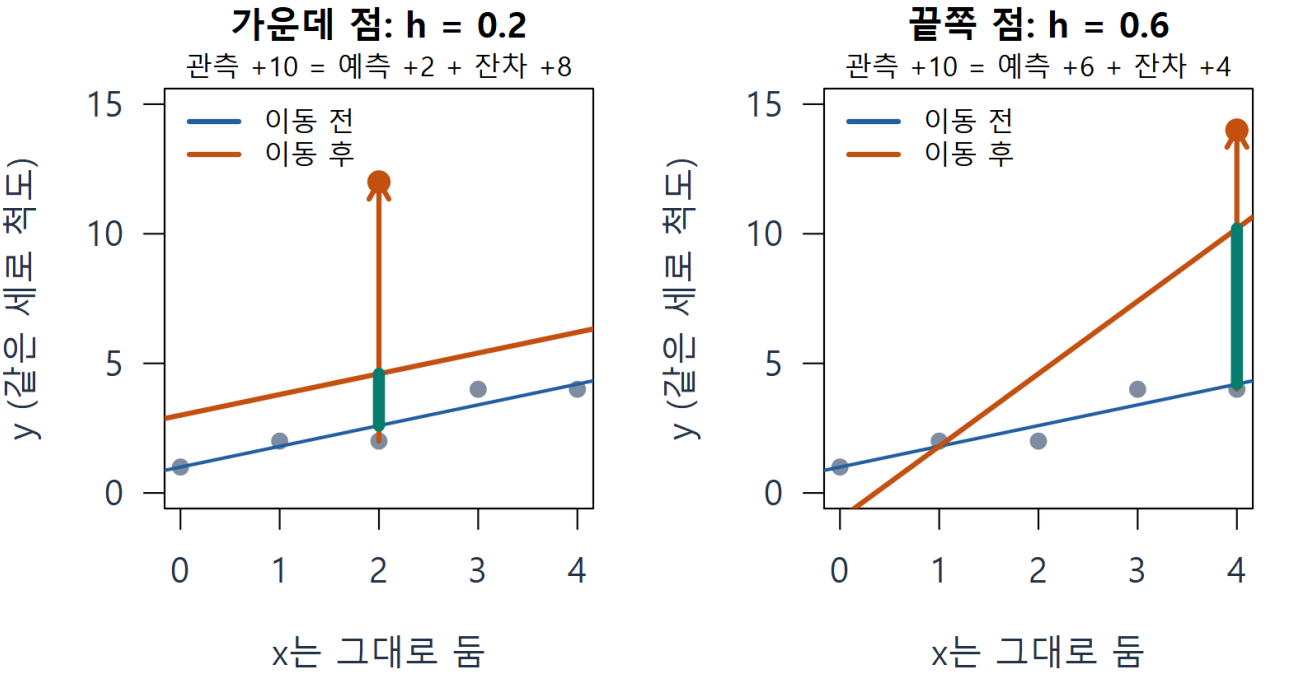


그림 읽기: 파랑은 이동 전, 주황은 이동 후 직선입니다. 긴 주황 화살표는 관측의 +10, 초록 굵은 선분은 자기 예측의 +2 또는 +6입니다. 같은 관측 증가가 예측 변화와 잔차 변화로 나뉩니다. 출처: 위 5행 자료의 실제 재적합.

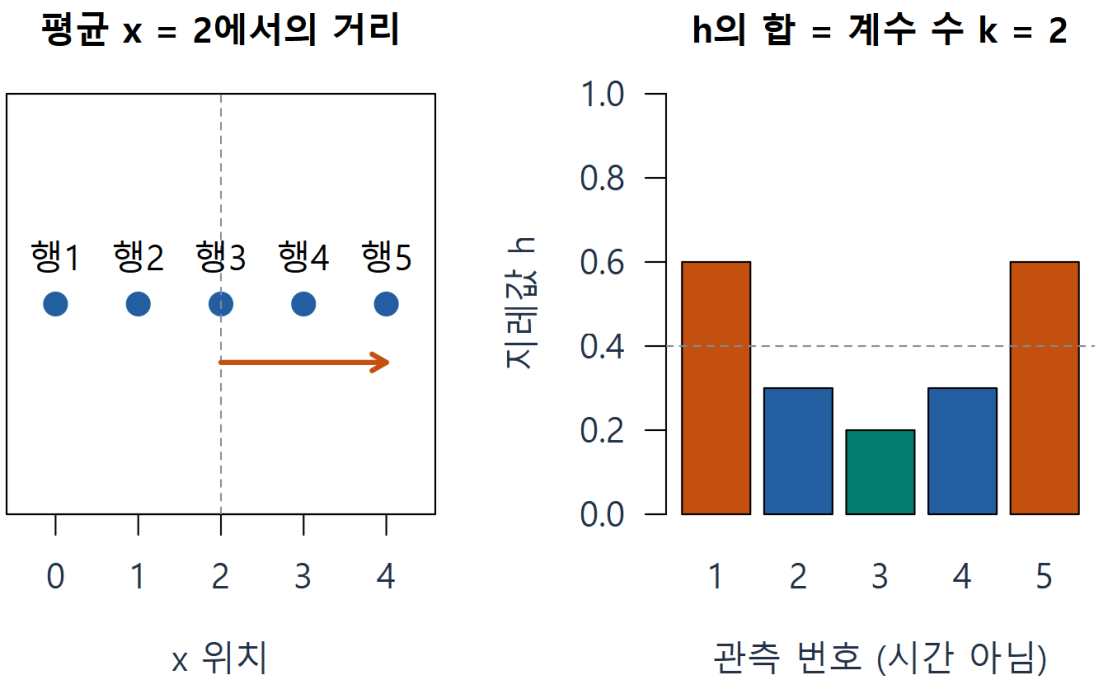
여기서 h는 확률이나 관측이 틀렸을 가능성이 아닙니다. **주어진 x 배치에서 생기는 기하학적 성질**입니다. x를 고정하면 y를 바꾸어도 h 자체는 바뀌지 않습니다. h가 큰 점도 직선에 잘 맞을 수 있으므로 실제 영향력은 B에서 따로 확인합니다.

3.1 행렬 없이 h를 한 번 계산하기

절편을 포함한 단순회귀에서는 다음 식을 쓸 수 있습니다. n은 관측 수, $\bar{x}$는 x의 평균, S_{xx}는 x가 평균에서 떨어진 정도를 제곱해 모두 더한 값입니다.

$$h_i = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}, \qquad S_{xx} = \sum_{j=1}^{n} (x_j - \bar{x})^2.$$

지금은 $n = 5$, $\bar{x} = (0+1+2+3+4)/5 = 2$이고 $S_{xx} = 4+1+0+1+4 = 10$입니다. 가운데 3번은 $1/5 + 0/10 = 0.2$, 끝쪽 5번은 $1/5 + 4/10 = 0.6$입니다. x가 평균에서 멀수록 단순회귀의 h가 커지는 이유가 식에도 보입니다. 다중회귀에서는 각 x를 따로 보는 대신 설명변수들의 **공동 배치**를 봅니다.



점선 높이 0.4는 지레값의 평균 k/n입니다. k는 절편을 포함한 실제 계수 수이며 지금은 2입니다. h의 합은 k=2입니다. 관측 번호는 이 자료의 식별자이고 시간순서가 아닙니다. 출처: 위 5행 자료의 계산.

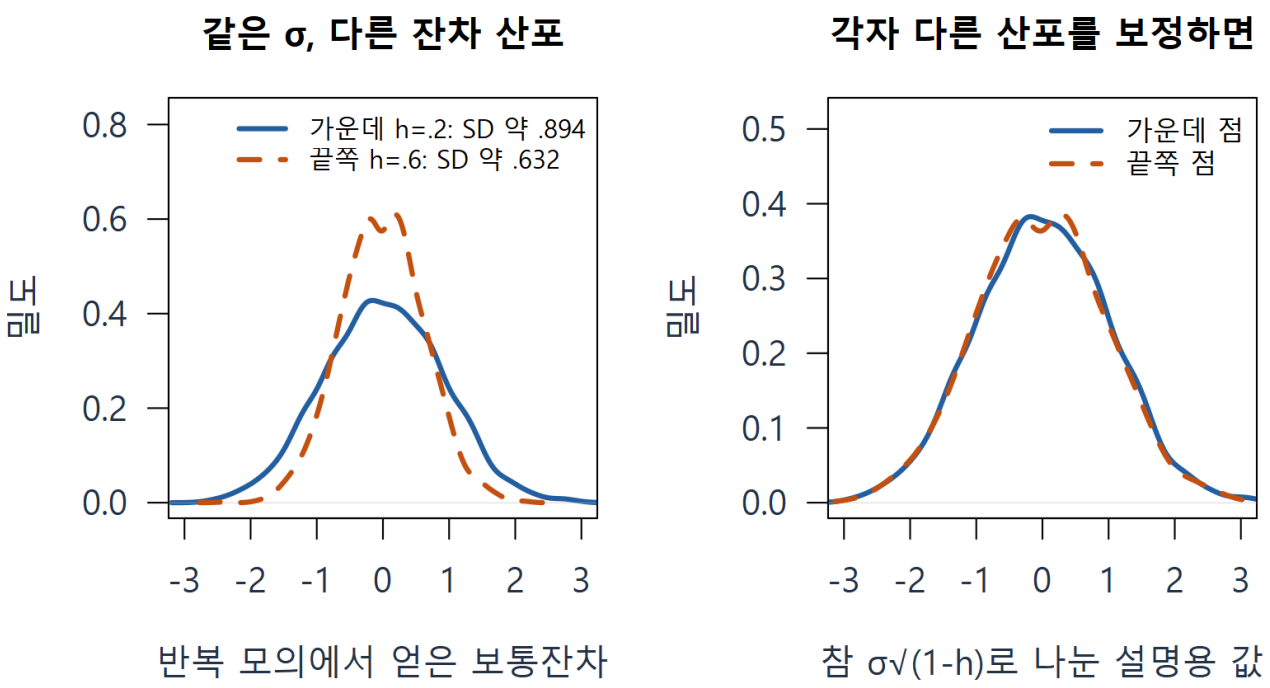
확인 C02. x를 그대로 둔 채 y만 바꾸면 h가 바뀔까요? h=0.6이라는 말이 '오류일 확률 60%'가 아닌 이유도 설명하세요.

4. 왜 잔차를 그냥 크기로 비교하지 않는가

직선을 추정할 때 각 관측이 그 직선을 자기 쪽으로 끌어당깁니다. h가 큰 점의 보통잔차는 그 작용 때문에 작게 보일 수 있습니다. 모형의 평균형태와 같은 오차분산 가정이 맞고 x 배치를 고정하면, 반복해서 자료를 얻을 때의 잔차 분산은 다음과 같습니다.

$$\mathrm{Var}(e_i \mid X) = \sigma^2(1 - h_i).$$

분산은 반복 관측에서 얼마나 퍼지는지를 제곱 단위로 나타낸 값이고, 표준편차는 그 제곱근입니다. σ는 참 오차의 표준편차입니다. 우리가 알고 있는 값은 아니므로 뒤에서 자료로 추정합니다. h=0.2라면 잔차 표준편차는 $\sigma\sqrt{0.8}$, h=0.6이라면 $\sigma\sqrt{0.4}$입니다. 같은 원래 오차 규모에서도 보통잔차의 비교 척도가 다릅니다.



왼쪽의 끝점 잔차는 더 좁게 퍼집니다. 오른쪽은 원리를 보여 주려고 **모의에서 아는 참 σ**로 나눈 그림입니다. 실제 내적 표준화잔차를 소표본에서 정확히 정규분포로 만드는 실험이라고 해석하지 않습니다. 출처: 고정 x에서 정규 오차를 반복 생성한 추가 모의실험.

5. s·자유도·내적/외적 표준화: 분모를 풀어 읽기

먼저 잔차를 제곱해 더한 **잔차제곱합 SSE**를 구합니다. 큰 양수와 큰 음수가 서로 지워지지 않도록 제곱합니다. 그 합을 잔차 자유도로 나누고 제곱근을 취하면 오차 규모의 추정값 s를 얻습니다.

$$\mathrm{SSE} = \sum e_i^2 = 0^2 + 0.2^2 + (-0.6)^2 + 0.6^2 + (-0.2)^2 = 0.8, \quad \nu = n - k = 5 - 2 = 3, \quad s = \sqrt{\frac{0.8}{3}} \approx 0.5164.$$

자유도 3은 다섯 관측으로 절편과 기울기 두 계수를 추정한 뒤의 잔차 자유도입니다. 표에서 두 관측을 실제로 삭제했다는 뜻은 아닙니다. 분모를 무조건 n으로 두지 않습니다. s의 단위는 y의 단위입니다.

내적(내부) 표준화잔차는 전체 자료에서 추정한 s를 사용합니다. **외적(외부) 표준화잔차**는 i번을 빼고 나머지 자료로 다시 적합해서 추정한 $s_{(i)}$를 사용합니다. 이 용어는 벡터의 내적·외적 연산을 말하는 것이 아닙니다.

$$r_i = \frac{e_i}{s\sqrt{1-h_i}}, \qquad r_i^* = \frac{e_i}{s_{(i)}\sqrt{1-h_i}}.$$

분모는 '비교에 쓸 잔차의 표준편차 추정값'입니다. 잔차를 그 척도로 나누므로 결과는 무단위입니다. 두 식의 **분자는 모두 전체 모형의 같은 잔차**입니다. 외적이라고 분자를 삭제 후 예측오차로 바꾸지 않습니다.

E03 · 3번의 두 표준화 값을 비교하기

3번은 $e_3 = -0.6$, $h_3 = 0.2$입니다. 전체 규모로 만든 분모는 $0.5164\sqrt{0.8} \approx 0.4619$이므로 내적 값은 약 -1.2990입니다.

3번을 제외한 나머지 네 점을 **다시 적합**하면 SSE는 0.35, 잔차 자유도는 $4 - 2 = 2$입니다. 따라서 $s_{(3)} = \sqrt{0.35/2} \approx 0.4183$이고, 외적 값은 $-0.6/(0.4183\sqrt{0.8}) \approx -1.6036$입니다.

내적: 전체 5행 사용	외적: 3행 제외 후 재적합
SSE = .8, 자유도 = 3	삭제 SSE = .35, 자유도 = 2
$s = \sqrt{(.8/3)} = .5164$	$s(3) = \sqrt{(.35/2)} = .4183$
$-.6 / (.5164 \times \sqrt{.8})$	$-.6 / (.4183 \times \sqrt{.8})$
$r = -1.2990$	$r^* = -1.6036$
분자는 전체 잔차 -.6으로 같음	분자는 전체 잔차 -.6으로 같음

전체 SSE에서 단순히 3번의 e_3^2만 빼는 계산이 아닙니다. 재적합하면 다른 점의 잔차도 변합니다. 자세한 삭제 항등식은 개념 카드에 있습니다. 이 예에서는 외적 절댓값이 더 크지만 항상 그런 것은 아닙니다. R의 `rstandard()`와 `rstudent()`가 각각 두 값에 대응합니다.

확인 C03. 외적 표준화에서 달라지는 것은 분자인가요, 오차 규모를 추정하는 분모인가요? '다시 적합'이 필요한 이유도 말해 보세요.

6. 정규 Q-Q: 정렬하고 같은 순위의 값을 짝짓는 그림

분위수는 분포에서 어느 정도 아래쪽에 위치하는지를 나타내는 경계값입니다. 예를 들어 중앙값은 아래쪽 절반의 경계입니다. **정규 Q-Q 플롯**은 자료를 작은 순서로 정렬한 값과, 정규분포에서 비슷한 순위에 대응하는 값을 짝지어 그린 그림입니다. Q 두 개는 두 분위수(quantile)를 가리킵니다.

E04 · 표의 한 행을 Q-Q 점 하나로 만들기

그림을 만드는 법을 배우기 위해 먼저 위 **보통잔차** 다섯 개를 씁니다. 정렬하면 -0.6, -0.2, 0, 0.2, 0.6입니다. R 기본 규칙으로 구한 대응 정규값은 약 -1.180, -0.497, 0, 0.497, 1.180입니다.

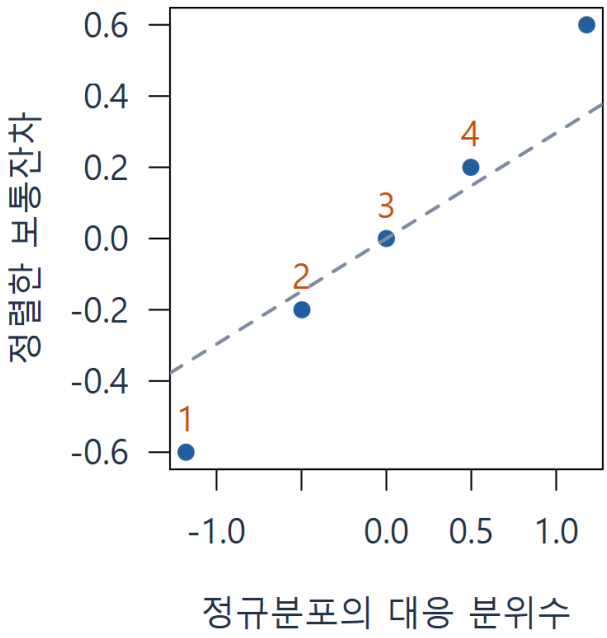
첫 점의 가로는 -1.180, 세로는 -0.6입니다. 두 번째 점은 (-0.497, -0.2)입니다. 가로축은 관측 번호, x 설명변수, 확률 자체가 아닙니다. 정규분포의 대응 **수치**입니다. 세로축에는 정렬한 잔차를 놓습니다.

① 작은 순서로 정렬

순위	잔차	확률위치	정규값
1	-0.60	0.119	-1.180
2	-0.20	0.310	-0.497
3	0.00	0.500	0.000
4	0.20	0.690	0.497
5	0.60	0.881	1.180

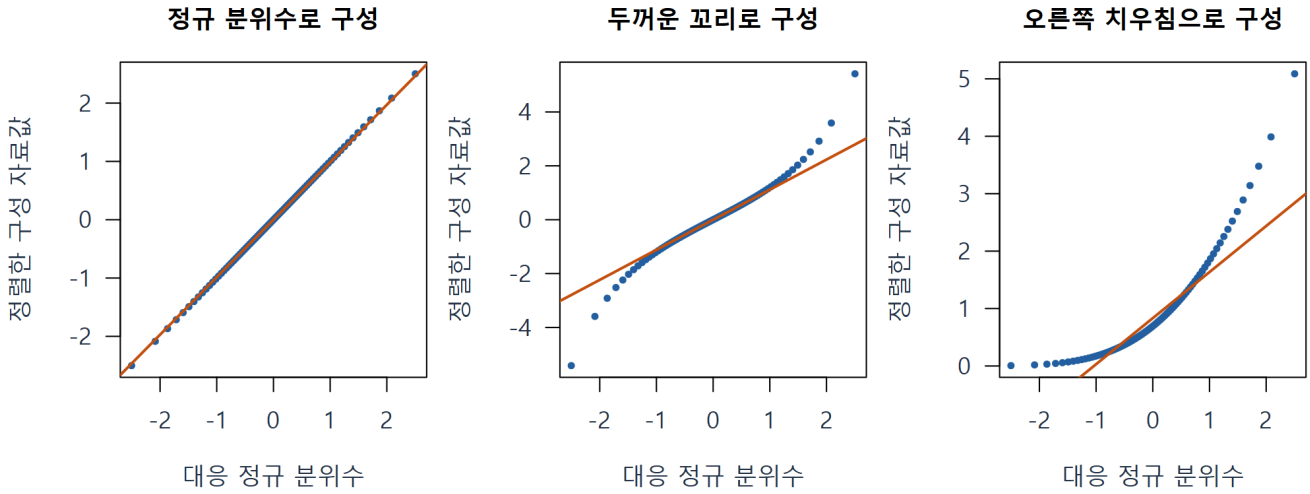
가로축은 확률이 아님
정규분포의 대응값

② 정규값과 잔차의 짝



회색 참고선은 원래 y~x의 회귀직선이 아닙니다. R의 `qqline()`은 기본적으로 첫째·셋째 사분위수의 대응점을 지나는 선을 그립니다. 작은 표본의 확률위치 근사 규칙에는 여러 방법이 있으며, 여기서는 `qnorm(ppoints(n))`으로 `qqnorm()`과 같은 좌표를 만듭니다. 출처: 추가 구성 자료 및 R 공식 `qqnorm·ppoints` 정의.

정규분포로 자료의 분포 모양을 대략 설명할 수 있으면 점들이 참고 직선 부근에 놓일 것으로 기대합니다. 꼬리에서 멀어지거나 한쪽으로 휘면 분포 모양을 더 살펴볼 단서입니다. 다섯 점만으로 정규성 여부를 확정하지 않습니다.

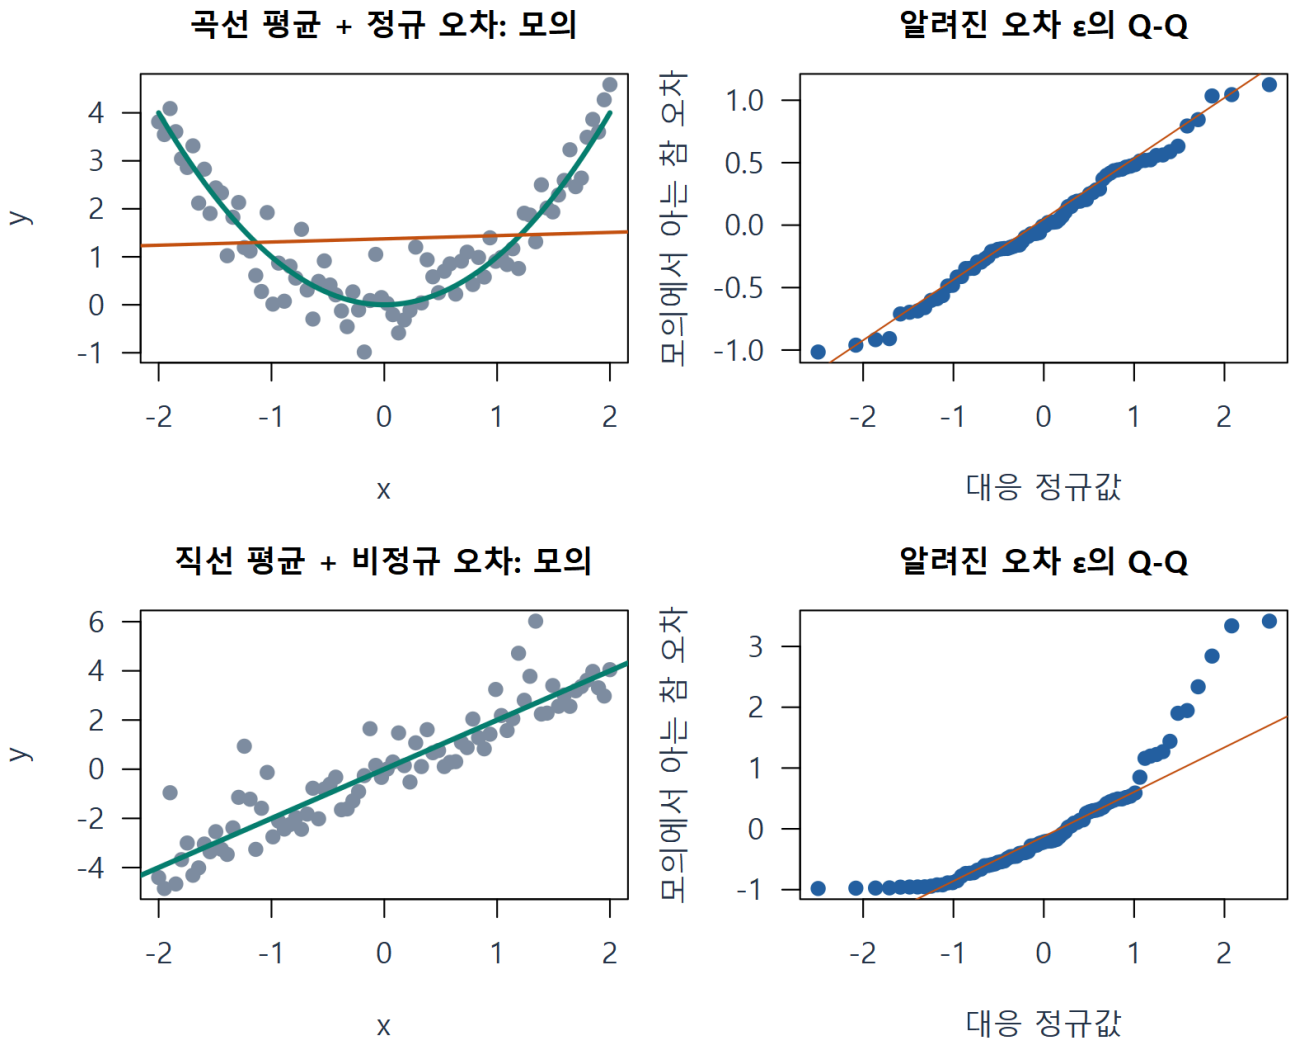


이 세 패널은 차이를 선명하게 보여 주려고 분포의 분위수로 구성한 설명용 자료입니다. 실제 표본이나 회귀잔차의 검정 결과가 아닙니다. 실제 진단에서는 적합한 모형의 내적 표준화잔차 등을 사용하며, 작은 표본의 표준화잔차가 정확한 정규 독립표본이라고 가정하지 않습니다.

확인 C04. Q-Q의 점 하나를 만들려면 어떤 두 숫자가 필요한가요? 원래 설명변수 x가 정규분포인지 보는 그림인가요?

7. 선형성과 정규성은 다른 질문

선형성은 **평균 관계의 형태**, 정규성은 **주어진 조건에서 평균 주위 오차의 분포 모양**에 관한 질문입니다. 직선 주위에서 오차가 한쪽으로 치우칠 수도 있고, 곡선 평균 주위의 오차가 정규분포일 수도 있습니다.



왼쪽 초록 선이 모의에서 정한 참 평균입니다. 위의 주황 직선은 곡선 관계를 놓칩니다. 오른쪽은 **모의에서 아는 참 오차 ε**의 Q-Q입니다. 실제 자료에서는 참 오차 대신 잔차를 보므로, 평균모형이 틀리면 잔차의 Q-Q도 달라질 수 있습니다. 먼저 평균 관계가 타당한지 살핀 뒤 분포 진단을 함께 읽습니다.

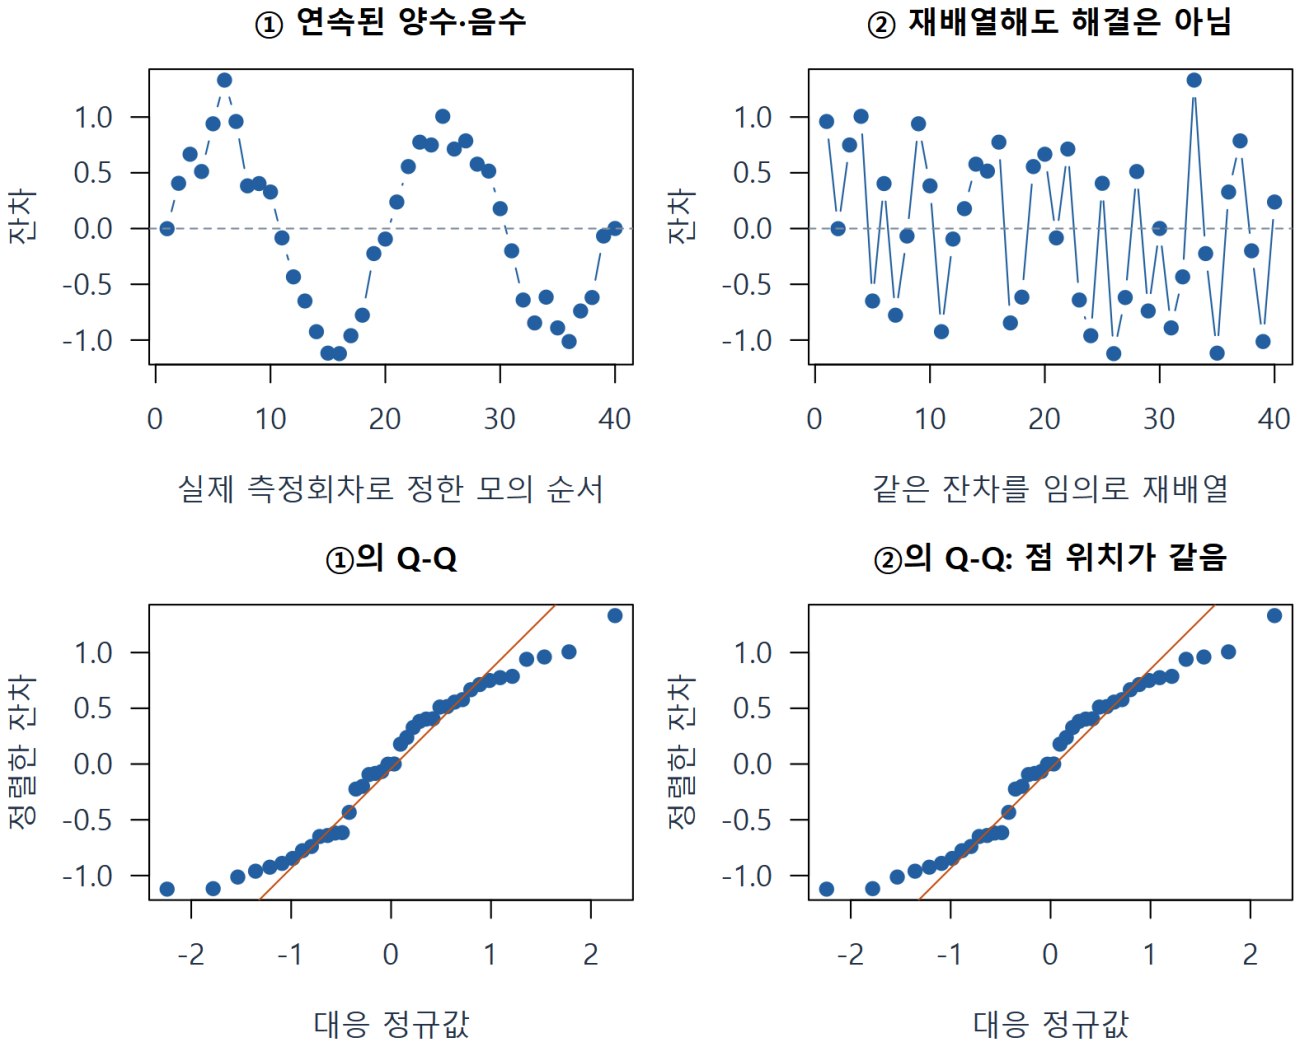
선형회귀의 '선형'은 지정한 설명변수에 대한 계수의 선형성을 뜻합니다. x^2를 설명변수에 넣은 다항회귀도 계수에 대해서는 선형모형일 수 있습니다. 여기서 직선과 곡선을 비교하는 것은 먼저 적합한 **y~x 모형의 평균 형태**를 점검하는 사례입니다. 정규성은 x나 y의 주변분포가 정규여야 한다는 요구가 아닙니다. 최소제곱 계수 계산 자체에 정규성이 필수인 것도 아닙니다.

8. 잔차–수집순서 플롯: 실제로 얻은 순서대로 놓기

수집순서는 자료를 실제로 얻은 순서입니다. 잔차–수집순서 플롯의 가로축에는 측정회차나 실제 시간을, 세로축에는 그 순서의 잔차를 놓습니다. 순서대로 양수·음수가 이어지거나 위치·산포가 변하는지 살핍니다.

E05 · 같은 잔차인데 순서 그림만 달라지는 이유

아래 추가 모의자료에서는 1~40을 실제 측정회차로 정했습니다. 1회차 잔차는 (1, 해당 잔차), 2회차 잔차는 (2, 해당 잔차)에 놓습니다. 왼쪽 위에는 양수와 음수가 덩어리로 이어지는 구조가 있습니다. 오른쪽 위는 **동일한 잔차 집합을 임의로 섞어 표시**했습니다.



아래 Q-Q 두 개의 점 위치는 같습니다. Q-Q를 만들 때 크기순으로 정렬해 순서 정보가 사라지기 때문입니다. 따라서 Q-Q가 괜찮아 보여도 순서 의존을 놓칠 수 있습니다. 순서를 섞는 것은 문제를 고치는 방법이 아닙니다.

부서 번호나 강 번호처럼 임의로 붙인 식별자를 시간으로 해석하지 않습니다. Scottish.Hills의 **Time은 경주 기록 시간이라는 반응변수**이며, 자료 수집순서를 뜻하지 않습니다. 순서 정보가 없다면 '시간 의존을 검토했다'고 보고하지 않습니다.

확인 C05. 잔차들을 다시 정렬해 시간순서 그림을 그려도 될까요? Q-Q가 같은 두 그림의 순서 구조는 왜 다를 수 있나요?

9. 그림을 고르는 작은 지도

확인할 질문	주로 보는 그림	점 하나의 좌표	관찰할 단서
평균 관계에 남은 구조가 있나	잔차–적합값, 잔차–설명변수	(적합값 또는 설명변수, 잔차)	곡선·집단별 치우침
산포가 일정한가	잔차–적합값 등	같은 좌표	부채꼴·집단별 다른 폭
오차 분포 모양이 정규에 가까운가	정규 Q-Q	(대응 정규 분위수, 정렬한 잔차)	꼬리·비대칭
순서 구조가 남아 있나	잔차–실제 수집순서	(실제 순서, 잔차)	연속 덩어리·추세·산포 변화

어떤 그림도 가정 전체를 증명하지 않습니다. '보인 패턴 → 가능한 설명 → 추가로 확인할 기록'을 구분해 씁니다. 예를 들어 곡선 패턴은 평균모형의 누락을 의심할 단서이지, 그 그림만으로 오차가 비정규라고 확정하는 근거는 아닙니다.

출처와 다음 연결

주교재『Chatterjee 예제를 통한 회귀분석 제6판: R 활용』§5.1–5.7, 인쇄188–205쪽. 기하학·분산 설명은 교재 정의를 풀어 썼고, 5행 표·점 이동·순서/오차 모의실험은 추가 교육용 구성입니다.

R: 회귀 삭제 진단 · R: 정규 Q-Q · R: 확률위치 · NIST: 수집순서 그림

이제 h가 높다는 것과 실제로 적합을 크게 바꾼다는 것을 구분합니다. B · 지레·영향력·P-R로 계속.

W10A B · 지레값·영향력·P-R를 한 단계씩

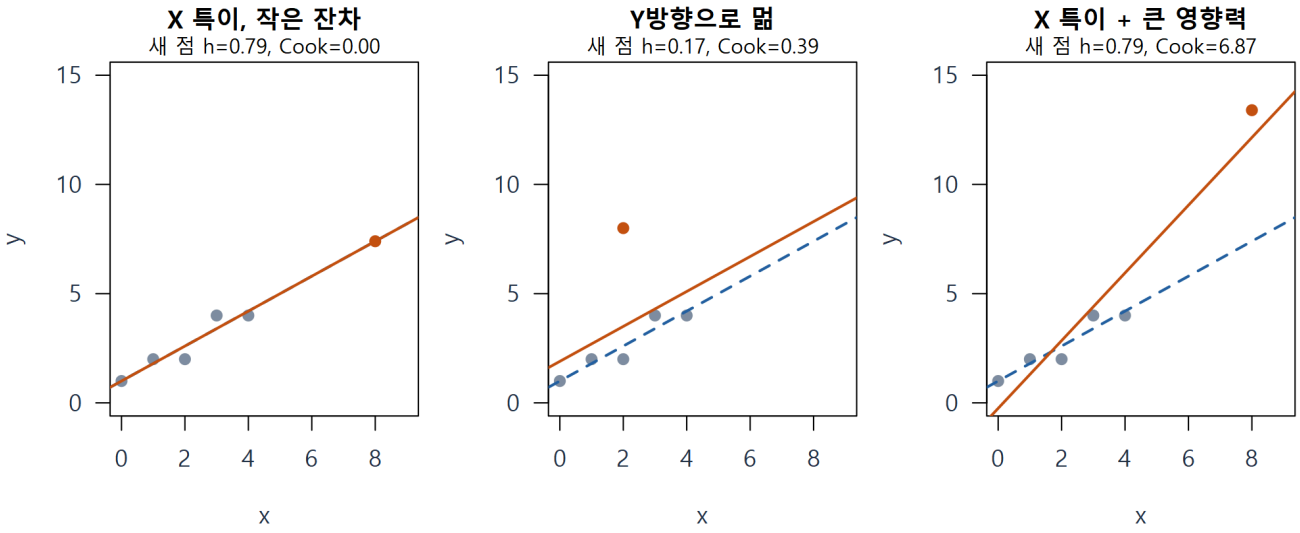
회귀분석의 이해 · 2026년 11월 2일

A의 잔차·h 설명을 먼저 읽습니다. 이 자료에서 h는 주어진 x 배치의 자기 예측 민감도, 잔차 e는 관측에서 전체 모형의 적합값을 뺀 값입니다. 둘을 안 뒤 '그 점을 빼면 적합 결과가 얼마나 달라지는가'를 살핍니다.

1. 서로 다른 세 질문부터 구별하기

질문	부르는 이름	확인하는 대상
설명변수 배치에서 다른 점들과 떨어져 있나	높은 지레점	X 공간의 특이성, h
적합한 평균에서 Y방향으로 멀리 있나	반응 방향의 특이값	잔차와 적절한 표준화
제외하고 다시 적합하면 결과가 크게 바뀌나	영향력 있는 관측	계수·예측 등의 실제 변화

'높은 지레값'은 잠재적으로 적합을 크게 바꿀 수 있는 위치를 말합니다. 실제로 바꾸었는지는 잔차와 삭제 재적합을 함께 봅니다. 특이값도 반드시 기록 오류는 아닙니다. 어떤 모형을 적합했는지에 따라 특이해 보이는 정도가 달라집니다.



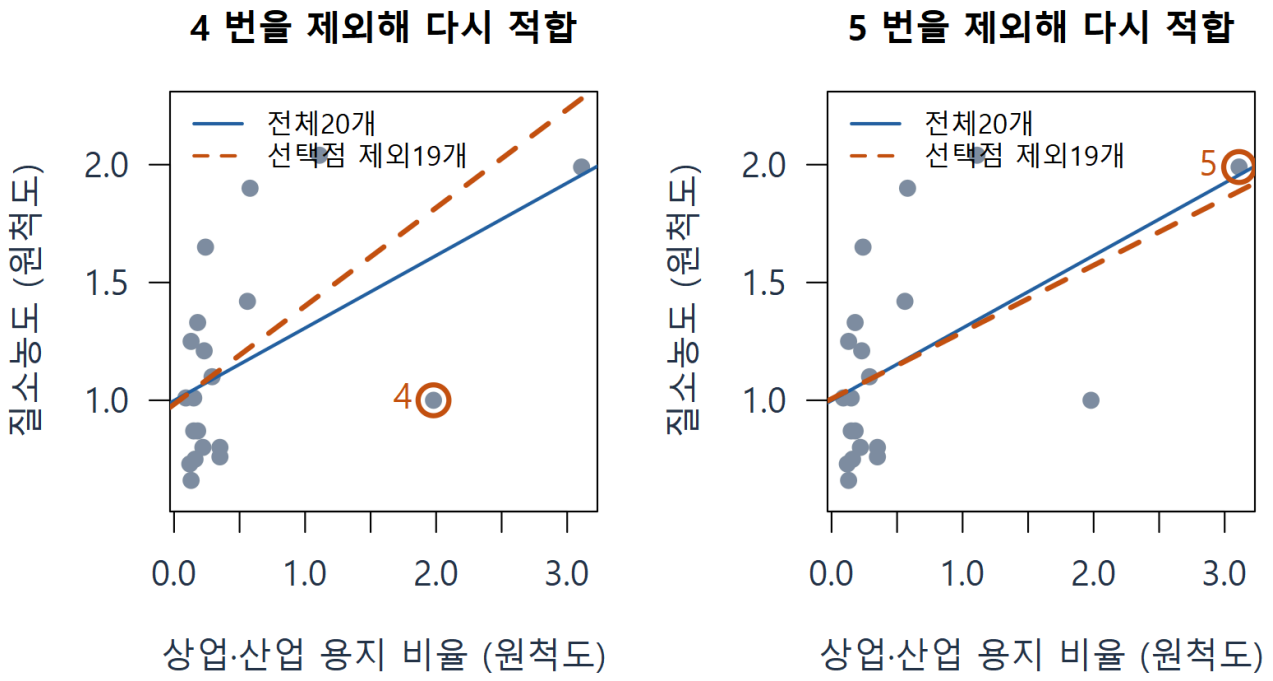
세 패널은 각각 원래 5행에 **여섯 번째 점을 따로 추가**한 교육용 예입니다. 파란 점선은 추가 전 직선, 주황 실선은 추가 후 직선입니다. 왼쪽 점은 h가 크지만 두 직선이 거의 겹칩니다. 오른쪽은 직선이 크게 바뀝니다. 그림의 6행 모형 수치를 앞의 5행 계산에 섞지 않습니다. 출처: 추가 구성 자료의 실제 OLS 적합.

확인 C06. h가 더 큰 점의 Cook 값이 반드시 더 클까요? 왼쪽과 오른쪽 패널에서 '위치'와 '실제로 바뀐 정도'를 나누어 설명하세요.

2. ‘제외 후 재적합’은 원자료 삭제가 아니라 민감도 비교

원자료는 그대로 보관합니다. 분석용 사본에서 i번을 빼고 다시 적합한 모형을 만들어 전체 모형과 비교합니다. 이때 다른 점의 잔차도 바뀔 수 있습니다. 어떤 점을 제외해 얻은 결론이 전체 자료의 결론과 다르면, 그 차이를 설명할 내용 근거가 필요합니다.

교재의 NYRivers는 강 20개입니다. 여기서 먼저 사용하는 모형은 **질소농도 Nitrogen ~ 상업·산업 용지 비율 ComIndl**, 계수 수 k=2인 단순모형입니다. 농도의 물리 단위는 이 검토 원문에 명시되어 있지 않아 원척도로 표시합니다. 임의로 mg/L 같은 새 단위를 붙이지 않습니다.



두 패널의 파란 실선은 같은 20개 전체 모형입니다. 주황 점선은 각각 4번 또는 5번을 제외한 19개 모형입니다. 큰 빈 원으로 제외한 관측의 **원래 위치를 계속 표시**했습니다. 5번은 x가 매우 크지만 이 단순모형의 적합선 부근에 있어, 4번 제외와는 다른 변화가 나타납니다. 출처: 주교재 §5.8–5.9, 저자 공식 NYRivers 자료를 재계산한 자체 그림.

3. Cook의 거리: 전체 예측이 얼마나 변했는가

한 점을 뺀 모형도 원래 모든 관측의 x 위치에서 예측할 수 있습니다. Cook의 거리는 그 **전체 예측 변화의 제곱합**을, 계수 수와 오차 규모로 나누어 비교하는 무단위 양입니다. 부호는 없고 0 이상입니다.

$$C_i = \frac{\sum_{j=1}^{n} (\hat{y}_j - \hat{y}_{j(i)})^2}{k s^2}.$$

여기서 $\hat{y}_j$는 전체 모형의 j번 예측, $\hat{y}_{j(i)}$는 i번을 빼고 적합한 모형의 **같은 j번 위치 예측**입니다. i는 제외할 점, j는 예측 변화를 합산할 모든 위치입니다. 분모의 s는 전체 자료의 오차 규모입니다.

E06 · 익숙한 5행 표의 4번 Cook 계산

다시 A의 5행 모형으로 돌아옵니다. $n = 5, k = 2, s^2 = 0.8/3$, 4번은 $e_4 = 0.6, h_4 = 0.3$입니다. 먼저 내적표준화잔차를 구하면 다음과 같습니다.

$$r_4 = \frac{0.6}{\sqrt{0.8/3}\sqrt{0.7}} \approx 1.388730.$$

OLS에서는 전체 삭제 재적합을 매번 하지 않고도 같은 Cook 값을 얻는 다음 식이 성립합니다.

$$C_4 = \frac{r_4^2}{k}\frac{h_4}{1-h_4} = \frac{1.388730^2}{2}\frac{0.3}{0.7} \approx 0.413265.$$

잔차가 평균모형에서 벗어난 정도와 그 위치의 지레 작용이 함께 들어갑니다. 같은 표의 1번은 h=0.6으로 더 크지만 잔차가 0이라 Cook도 0입니다. 계산이 맞는지는 실제 4번 제외 재적합 후 원래 다섯 위치의 예측 변화를 합산해 검산합니다.

확인 C07. Cook을 직접 정의로 계산할 때 변화량을 4번 한 위치에서만 보나요, 원래 모든 위치에서 보나요? 무엇으로 나누는지도 짚어 보세요.

4. DFFITS: 그 점 자기 위치의 예측 변화

DFFITS는 i번의 **자기 위치**에서 전체 예측과 i번 제외 모형의 예측이 얼마나 다른지 표준화합니다. 삭제 후 오차 규모 $s_{(i)}$를 쓰며, 예측 변화의 방향 때문에 양수와 음수가 가능합니다.

$$\mathrm{DFFITS}_i = \frac{\hat{y}_i - \hat{y}_{i(i)}}{s_{(i)}\sqrt{h_i}} = r_i^*\sqrt{\frac{h_i}{1-h_i}}.$$

위 식의 r_i^*는 A에서 배운 외적 표준화잔차입니다. Cook은 전체 예측 변화와 전체 s, DFFITS는 자기 예측 변화와 삭제 후 s를 사용합니다. 둘은 관련되지만 같은 숫자는 아닙니다.



왼쪽 막대들은 NY 4번을 제외했을 때 **각 원래 위치**의 예측 차이입니다. 가로는 시간순서가 아닙니다. 오른쪽은 그중 자기 4번 위치의 차이를 삭제 후 척도로 나누어 DFFITS 약 -1.1448로 읽습니다. 이 그림은 NY20행 모형이며, 앞 E06의 교육용 5행 모형과 다릅니다. 출처: 같은 공식 NY 자료의 실제 삭제 재적합.

5. 잠재성 P와 잔차 성분 R을 따로 이해하기

'잠재성'은 낯선 새 확률이 아닙니다. 지레값을 다음처럼 바꾸어, h가 1에 가까울 때 그 위치의 특이성을 더 크게 드러낸 척도입니다.

$$P_i = \frac{h_i}{1-h_i}.$$

h=0.2이면 P=0.25, h=0.6이면 P=1.5입니다. 1보다 클 수 있으므로 확률이 아닙니다. h가 커질수록 P도 커집니다.

다음으로 **정규화잔차** $d_i = e_i/\sqrt{\mathrm{SSE}}$를 정의합니다. 제곱 $d_i^2 = e_i^2/\mathrm{SSE}$는 전체 잔차제곱합 중 그 점이 차지하는 비중입니다. 이것은 내적 표준화잔차 r_i의 제곱과 다릅니다. Hadi의 잔차 성분은 다음과 같습니다.

$$R_i = \frac{k}{1-h_i}\,\frac{d_i^2}{1-d_i^2}, \qquad H_i = P_i + R_i.$$

Hadi의 H_i는 두 성분을 더한 지표입니다. P는 X 위치 쪽, R은 잔차 쪽 특이성을 드러냅니다. 식을 한꺼번에 외우기보다 **두 성분이 무엇을 크게 만드는가**부터 읽습니다. P와 R은 둘 다 0 이상이고, 제곱을 사용한 R에는 잔차의 원래 부호가 남지 않습니다.

6. P-R 플롯의 점 하나를 만들기

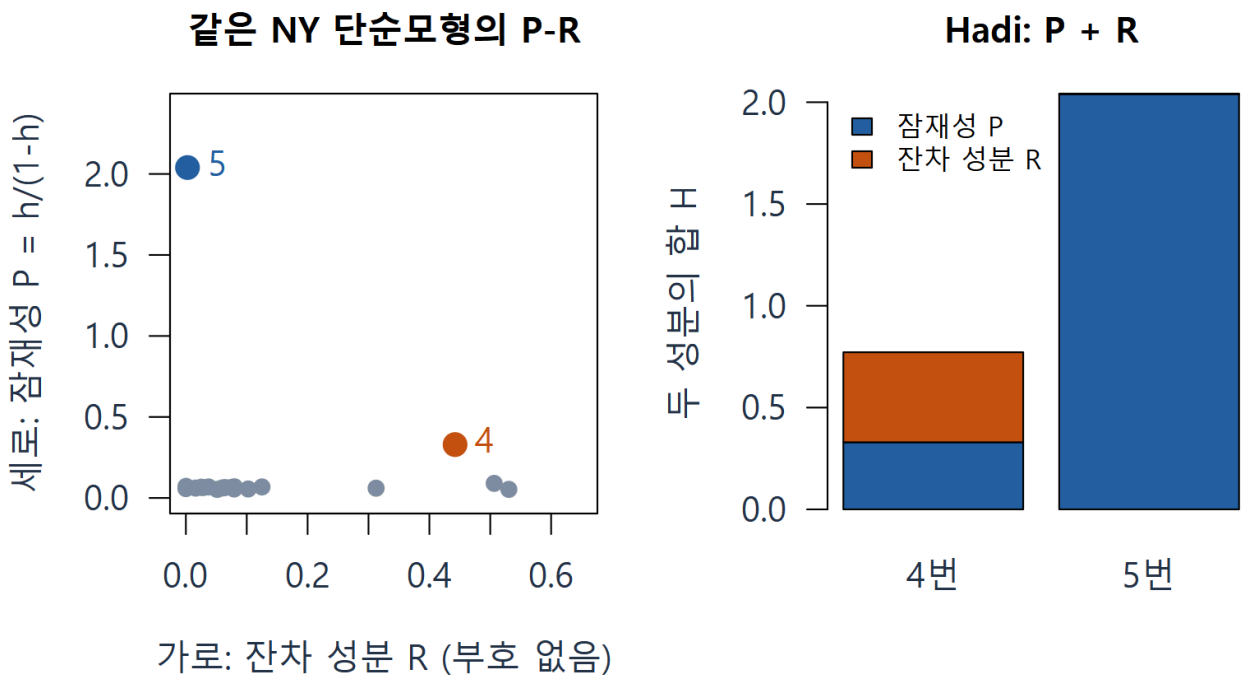
이 교재의 잠재성–잔차 플롯(P-R)은 **가로에 R, 세로에 P**를 놓습니다. R 기본 진단의 '가로 지레값, 세로 표준화잔차' 그림과 축이 다릅니다. R이라는 글자는 여기서 잔차 **성분**의 이름이며 R 프로그래밍 언어나 부호 있는 잔차 r과도 구분합니다.

E07 · NY 4번과 5번의 좌표를 만들고 읽기

이 예는 다시 $n=20, k=2$의 NY 단순모형입니다.

강 번호	h	내적 잔차 r	Cook	P	R	P-R 좌표 (가로, 세로)
4	0.247865	-1.847232	0.562255	0.329549	0.442189	(0.442189, 0.329549)
5	0.671010	0.155291	0.024593	2.039602	0.002681	(0.002681, 2.039602)

4번의 P는 $0.247865/(1-0.247865) \approx 0.329549$입니다. 그 점의 e^2/SSE를 R 식에 넣으면 약 0.442189입니다. 그래서 가로 0.442189, 세로 0.329549에 점을 찍습니다. 5번도 같은 방식으로 계산하지만, P가 크고 R이 매우 작아 위쪽 왼편에 놓입니다.



5번의 Hadi 값이 큰 것은 주로 **잠재성 P** 때문입니다. 5번의 Cook이 작은 것과 모순이 아닙니다. Cook은 이 모형의 실제 예측 변화, Hadi는 X/Y의 특이성을 함께 드러내는 더 넓은 관점을 가집니다. 한 숫자의 순위만으로 서로 다른 질문을 같은 결론으로 바꾸지 않습니다. 출처: 주교재 식5.24–5.25, 공식 자료 재계산. 표시값 반올림 전 수치로 검산했습니다.

확인 C08. P-R에서 위쪽에 있다는 것은 무엇이 큰가요? R 성분만 보고 관측이 예측보다 위인지 아래인지도 알 수 있나요?

7. 경계선·가면·수렁: 진단을 판결로 쓰지 않기

h의 평균은 k/n이며, 그 두 배인 2k/n을 조사 기준으로 쓰기도 합니다. NY 단순모형에서는 2×2/20=0.2입니다. Cook 1이나 DFFITS의 기준선 등도 자주 보지만, 이는 **추가 조사할 점을 찾는 경험적 신호**입니다. 표본 크기·모형·분석 목적을 함께 봅니다. 값 하나가 경계를 넘었다고 자동으로 제외하지 않습니다.

가면(masking)은 여러 특이 관측이 직선을 함께 끌어당겨 문제 관측이 잔차만으로 잘 드러나지 않는 상황입니다. 수렁(swamping)은 그렇게 끌려간 직선 때문에 정상적인 관측을 문제 관측으로 잘못 지목하는 상황입니다. 잔차가 작다고 안심하거나, 크다고 바로 오류로 판정하지 않는 이유입니다.

삭제하면 설명변수 배치가 계수 추정을 더 이상 지탱하지 못하는 경우도 있습니다. h=1, 삭제 후 계수의 유일성 상실, 잔차 자유도 부족, 삭제 오차규모 0 등에서는 어떤 진단이 정의되지 않거나 불안정할 수 있습니다. 이런 값을 임의로 0으로 채우지 않습니다.

확인 C09. 기준선을 넘은 관측을 발견했을 때, 제외하기 전에 확인할 내용 근거를 두 가지 쓰세요.

8. 같은 강 자료라도 모형을 함께 적기

앞의 표·그림은 `Nitrogen ~ ComIndl`입니다. 교재에는 Agr·Forest·Rsdntial·ComIndl 네 변수를 포함한 **k=5의 전체모형**도 있습니다. 같은 4번·5번이라도 모형이 달라지면 잔차, h, 계수의 t값, 영향 지표가 달라집니다. '강 4번은 언제나 영향점'이라는 말 대신 **어느 모형의 어떤 결과에 영향을 주는지**를 적습니다.

R에서는 `hatvalues(fit)`, `rstandard(fit)`, `rstudent(fit)`, `cooks.distance(fit)`, `dffits(fit)`를 사용합니다. fit은 앞서 `lm()`으로 적합한 모형 객체입니다. 함수는 어떤 자료와 식으로 얻은 fit인지 알아야 해석할 수 있습니다. 우리 실습의 공통 함수는 중간 성분을 한 표로 연결하며, 입력·반환 열·지원 모형은 고정 버전 API 설명에서 확인합니다.

출처와 다음 연결

주교재 §5.8–5.11, 인쇄205–219쪽; 저자 공식 NYRivers 자료 안내; R 회귀 삭제 진단. 교재 p215의 DFFITS 수치 표기와 계산식·R 코드의 불일치는 개념 카드의 검산 주석에서 구분합니다. 공식 정오표로 단정하지 않습니다.

다음은 다른 변수가 이미 있을 때 한 변수의 효과를 어떻게 그리는지, 특이 관측을 발견한 뒤 어떻게 분석을 이어 가는지입니다. C · 변수 효과와 관측 처리.

W10A C · 다른 변수를 고려하는 그림과 관측 처리

회귀분석의 이해 · 2026년 11월 2일

이 부분은 처음 배우는 내용으로 읽습니다. **잔차화**라는 말은 어떤 변수를 다른 변수로 예측한 뒤, 실제 값에서 그 예측을 빼는 계산을 뜻합니다. 자료 행을 실제로 없애거나 원인을 실험적으로 통제했다는 뜻이 아닙니다. A의 '관측 - 예측'을 두 번 사용하는 것이 출발점입니다.

1. 경주 자료의 한 행과 단위를 먼저 읽기

Scottish.Hills의 한 행은 스코틀랜드 언덕 경주 하나이며 총 35행입니다. Time은 경주 기록 **초**, Distance는 거리 **마일**, Climb은 총 고도 상승량 **피트**입니다. 교재의 '경사'라는 말이 각도나 경사 비율을 뜻하는 것이 아닙니다.

첫 경주는 시간 965초, 거리 2.5마일, 상승량 650피트입니다. 긴 거리의 경주가 고도 상승량도 큰 편이라면, 거리와 시간만 그린 산점도에서 보이는 관계에는 다른 변수와 함께 움직이는 부분도 포함됩니다. 거리의 조건부 관계를 읽으려면 고도 상승량을 함께 고려해야 합니다.

같은 35행의 다중회귀 적합식은 다음과 같습니다.

$$\widehat{\text{Time}} = -539.482907 + 373.072677\,\text{Distance} + 0.662888\,\text{Climb}.$$

거리 계수는 다른 설명변수를 모형에서 함께 고려했을 때의 기울기입니다. 단위는 초/마일입니다. 이 관찰 자료의 조건부 연관을 인과효과라고 단정하지 않습니다.

2. 첨가변수플롯: 두 잔차를 만들어 한 점으로 놓기

첨가변수플롯(added-variable plot, 편회귀플롯)은 관심 변수의 다중회귀 계수를 그림으로 읽는 방법입니다. 관심 변수가 Distance라면, **같은 다른 변수 Climb과 절편**을 두 보조회귀에 사용합니다. 보조회귀는 좌표를 만들기 위한 작은 회귀입니다.

단계	적합할 작은 회귀	관측에서 뺄 값	남는 값
① 시간 쪽	Time ~ Climb	상승량으로 예측한 시간	시간 잔차 r_Y
② 거리 쪽	Distance ~ Climb	상승량으로 예측한 거리	거리 잔차 r_X
③ 좌표 만들기	새 보조회귀가 아님	각 경주의 두 잔차를 연결	가로 r_X, 세로 r_Y

시간만 잔차화하고 거리는 원래 값으로 두는 그림이 아닙니다. 같은 관측행, 같은 다른 변수 집합, 같은 절편 조건을 사용해야 합니다.

E08 · 첫 경주의 첨가변수 좌표

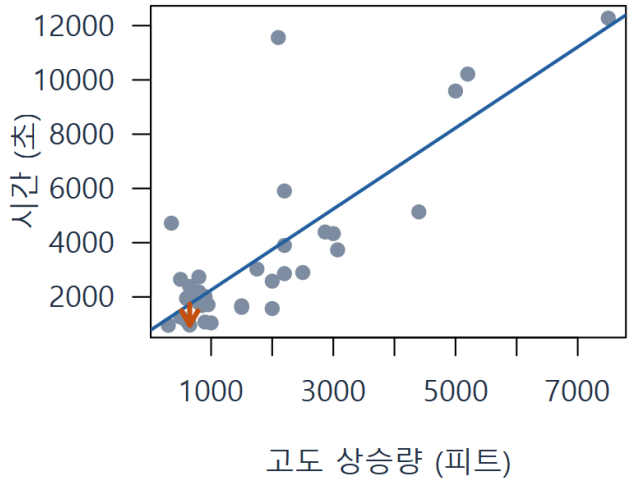
첫 경주의 Climb=650피트를 ①의 보조회귀에 넣으면 시간 예측은 약 1732.543초입니다. 시간 잔차는 $965 - 1732.543 = -767.543$초입니다. 같은 650피트를 ②에 넣으면 거리 예측은 약 4.935094마일입니다. 거리 잔차는 $2.5 - 4.935094 = -2.435094$마일입니다.

따라서 이 경주의 첨가변수 점은 다음 좌표입니다.

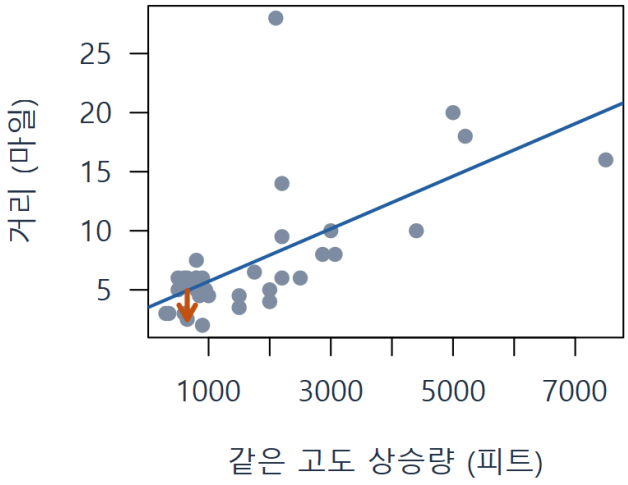
$$(r_X, r_Y) = (-2.435094 \text{ 마일}, -767.542917 \text{ 초}).$$

음수 거리는 실제 거리가 음수라는 말이 아닙니다. **그 상승량에서 보조회귀가 예측한 거리보다 짧다**는 뜻입니다. 시간 쪽도 같은 방식으로 읽습니다.

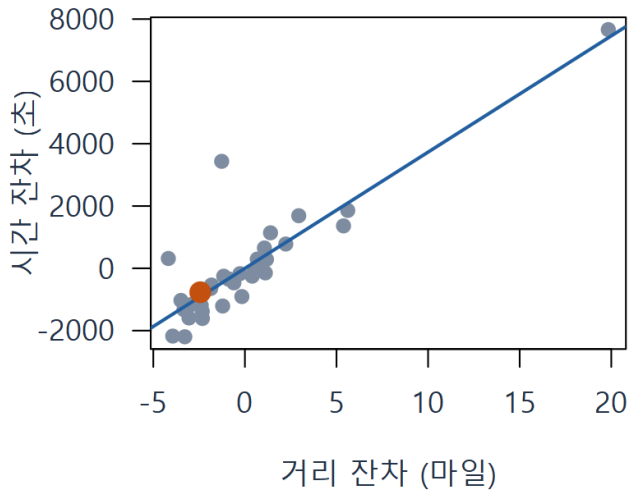
① 시간 ~ 고도 상승량



② 거리 ~ 고도 상승량



③ 두 잔차를 좌표로 옮김



첫 경주의 좌표

가로 -2.435 마일

세로 -767.543 초

기울기는 모든 점으로 계산

전체 기울기 373.073 초/마일

위 두 그림의 주황 화살표는 첫 경주의 각 보조회귀 잔차입니다. 아래 왼쪽은 모든 경주의 두 잔차를 좌표로 놓은 결과입니다. 출처: 주교재 §5.13의 공식 Hills 자료와 자체 단계별 그림.

두 잔차 좌표 전체에 최소제곱 직선을 적합한 기울기는 약 373.072677초/마일로, 앞 다중회귀의 Distance 계수와 같습니다. **첫 한 점의 세로/가로 비율**이 그 계수라는 뜻은 아닙니다. 점에는 여전히 잔차가 있기 때문입니다. 전체 기울기는 모든 점으로 구합니다.

$$b_{\text{Distance}} = \frac{\sum_i r_{Xi} r_{Yi}}{\sum_i r_{Xi}^2}.$$

이 식의 분자는 두 잔차가 함께 움직인 정도를 더한 값, 분모는 남은 거리 변동의 제곱합입니다. 행렬을 이용한 증명은 선택 보충으로 둡니다.

확인 C10. 첨가변수플롯에서 가로축도 잔차여야 하는 이유는 무엇인가요? 첫 경주의 음수 거리 잔차가 실제 음수 거리가 아닌 이유도 설명하세요.

3. 성분잔차플롯: 원래 x축을 유지하기

성분은 여기서 관심 변수의 적합값 기여분 $b_j x_j$입니다. 성분잔차플롯(component-plus-residual plot, 편잔차플롯)은 전체 다중모형의 잔차 e에 그 기여분을 다시 더합니다.

$$\text{가로} = x_j, \qquad \text{세로} = e + b_j x_j.$$

첨가변수플롯과 달리 **가로는 원래 설명변수**입니다. 관심 변수와 반응 사이에 남은 곡선 같은 형태를 살피는 데 도움을 줍니다. 세로의 성분잔차는 원래 y 관측값 자체가 아닙니다.

E09 · 첫 경주의 성분잔차를 한 행 계산하기

전체 모형에 거리 2.5, 상승량 650을 넣으면 시간 예측은 약 824.075979초입니다. 잔차는 $965 - 824.075979 = 140.924021$초입니다. 거리 성분을 다시 더하면 다음과 같습니다.

$$e_1 + b_{\text{Distance}} x_1 = 140.924021 + 373.072677 \times 2.5 \approx 1073.605713 \text{ 초}.$$

이 점은 가로 2.5마일, 세로 1073.605713초입니다. 앞 E08의 점 (-2.435094, -767.542917)과 다릅니다. 같은 경주·같은 전체모형을 **다른 목적으로 좌표 변환**한 것입니다.

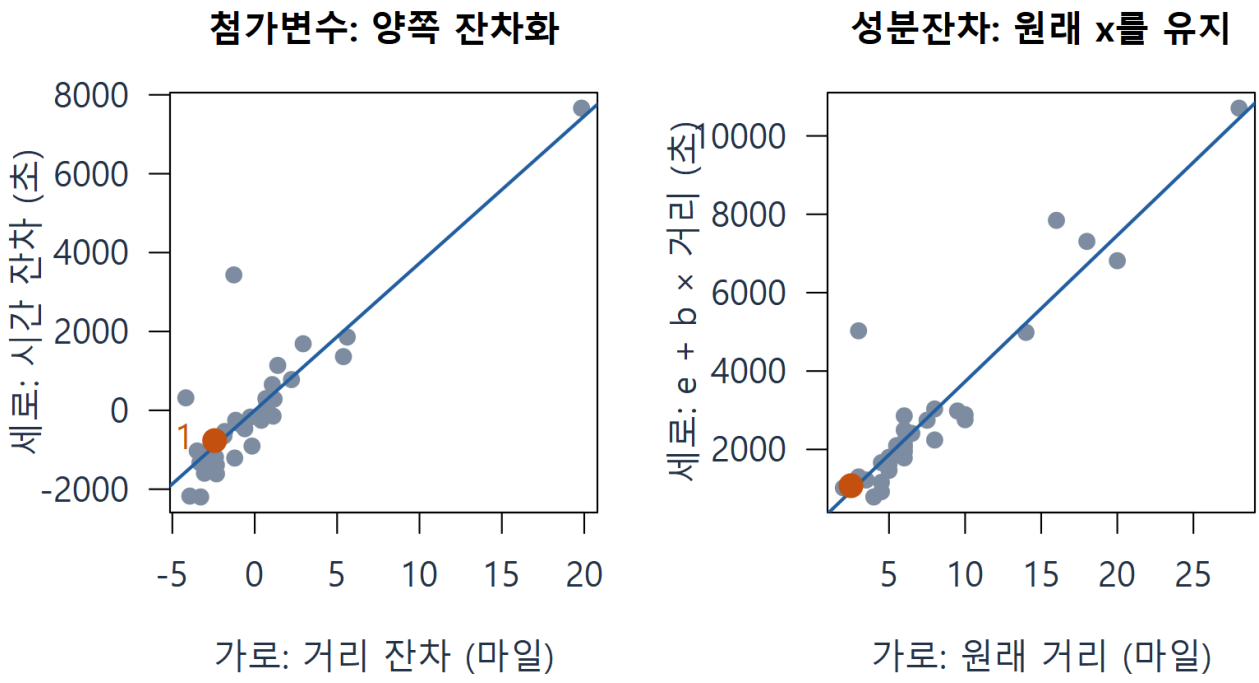


그림	가로	세로	먼저 읽을 질문
원 산점도	원래 거리	원래 시간	주변 관계가 어떻게 보이나
첨가변수	다른 변수로 설명되지 않은 거리 부분	같은 다른 변수로 설명되지 않은 시간 부분	조건부 기울기와 이를 좌우하는 점은 무엇인가
성분잔차	원래 거리	전체 잔차 + 거리 성분	관심 변수에 곡선 형태가 남아 있나

확인 C11. 두 그림의 점 번호 1은 같은 관측인데 왜 좌표가 다른가요? 각 가로축을 정확히 말해 보세요.

4. 새 변수를 넣을 때 따로 물을 두 질문

첫째는 **새 변수의 계수가 0과 구별되는가**입니다. 일반 OLS 출력의 계수 t값은 추정 계수를 그 표준오차로 나눈 값입니다. 다른 변수들이 모형에 있을 때 새 변수의 추가적인 선형 연관에 관한 질문이며, 가정과 함께 읽습니다.

둘째는 **새 변수를 넣으면 기존 변수의 계수가 얼마나 달라지는가**입니다. 새 변수의 유의확률만 읽어서는 이 변화가 보이지 않을 수 있습니다. 계수 변화량 자체를 새 변수의 t검정 결과와 같은 검정이라고 부르지 않습니다.

질문 1: 새 변수의 계수	질문 2: 기존 계수의 변화
고도 상승량 계수 .6629 초/피트	거리만: 약 499.825 초/마일
계수 / 표준오차 = t 약 5.387	고도 포함: 약 373.073 초/마일
두 질문을 같은 것으로 읽지 않음	두 질문을 같은 것으로 읽지 않음

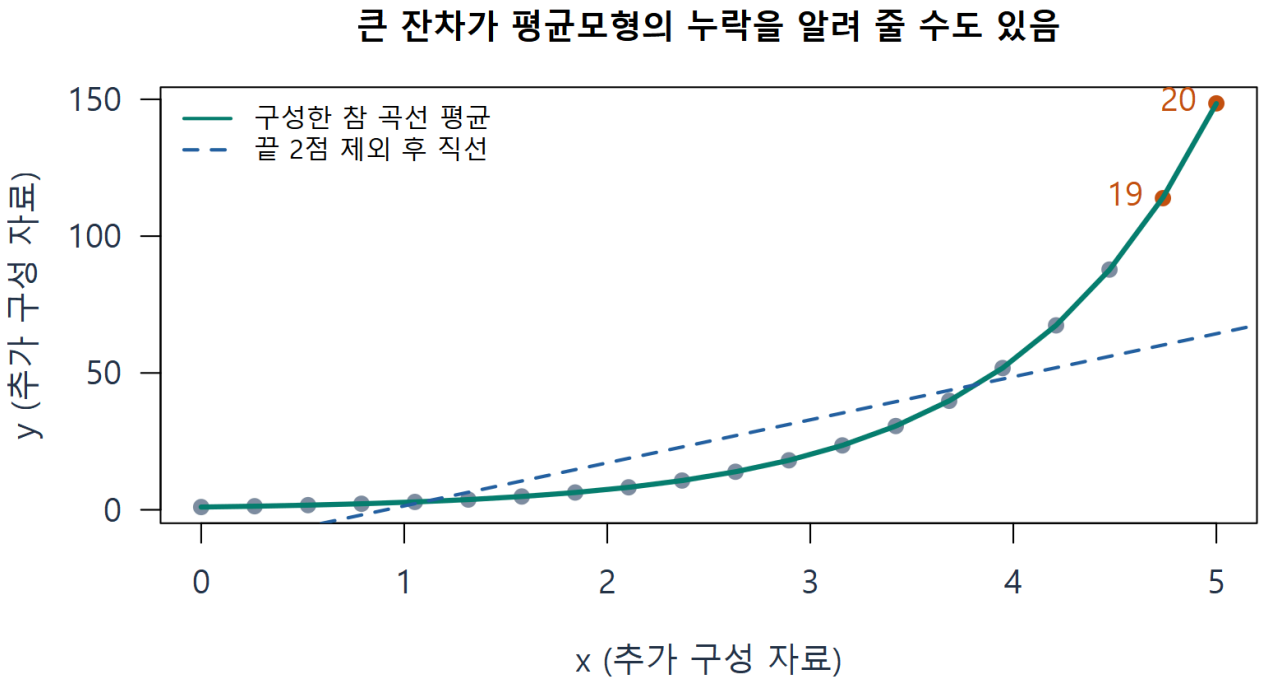
이 Hills 자료에서는 거리를 혼자 넣은 기울기가 약 499.825초/마일이고, 상승량을 함께 넣으면 약 373.073초/마일입니다. 새 상승량 계수의 t값은 약 5.387입니다. 두 질문 모두 필요합니다. 전후 계수 변화만으로 인과적 교란이나 공선성을 확정하지는 않습니다.

교재 §5.14는 '새 계수의 유의성'과 '기존 계수의 큰 변화' 유무를 조합한 네 상황을 비교합니다. 각 경우의 자세한 읽기는 개념 카드에 있습니다. 실제 변수 선택은 분석 목적·가정·자료 지지·계수 안정성도 함께 고려합니다.

확인 C12. '새 계수가 유의하다'와 '기존 거리 계수가 달라졌다'는 같은 질문인가요? 위 두 숫자 묶음을 각각 어느 질문에 연결할지 설명하세요.

5. 특이 관측을 발견한 뒤의 순서

먼저 자료 기록과 분석 맥락을 확인합니다. 입력·단위 오류가 확인되면 원본과 수정 근거를 보존합니다. 실제로 관측된 드문 사례라면 단순히 불편하다는 이유로 없애지 않습니다. 평균모형에서 중요한 곡선·집단·상호작용을 빠뜨렸을 수도 있습니다.



이 그림은 교재 그림5.9의 **문제의식을 새 자료로 재현**한 것으로 원교재 자료와 같지 않습니다. 초록 곡선은 구성한 참 평균, 파란 점선은 마지막 두 점을 제외한 직선입니다. 뒤의 큰 점은 곡선 관계를 알려 주는 정보일 수 있습니다. 이를 삭제하면 평균형태를 잘못 정한 문제를 놓칠 수 있습니다.

실무 기록은 '관측한 현상 → 가능한 원인 → 확인한 사실 → 선택한 처리 → 전체/민감도 비교' 순서로 남깁니다. 제외 분석은 원자료 유지 상태에서 따로 비교하고, 제외 이유와 결과 변화를 함께 보고합니다.

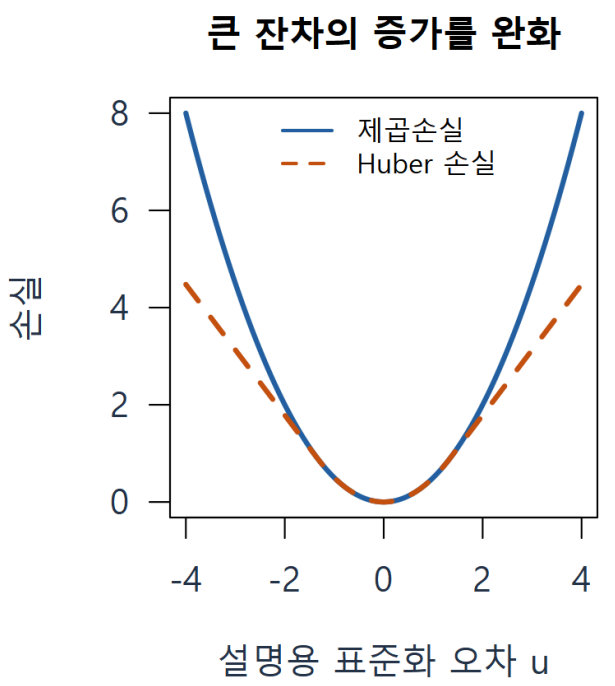
확인 C13. 큰 잔차가 발견되면 기록 오류 확인, 평균모형 재검토, 삭제 민감도 비교 중 무엇을 어떤 근거로 진행할지 설명하세요. 큰 잔차 자체가 삭제 이유가 되나요?

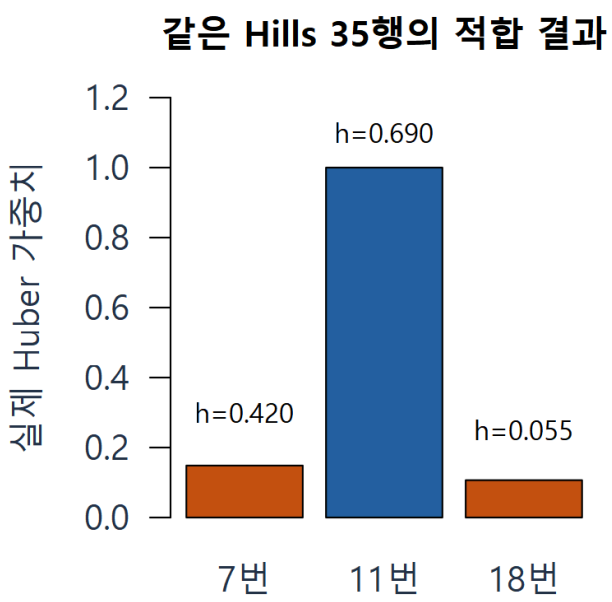
6. 로버스트 회귀: 큰 잔차의 작용을 완화하는 도입

최소제곱은 잔차를 제곱해 더합니다. 절댓값이 1에서 4로 커지면 제곱은 1에서 16으로 커져 큰 잔차의 작용이 빠르게 커집니다. **로버스트(강건) 회귀**는 일부 큰 잔차가 전체 적합을 지나치게 좌우하는 문제를 줄이려는 접근입니다. 교재 §5.15는 이 아이디어를 도입하며 전체 알고리즘은 뒤 장에서 다룹니다.

E10 · Huber의 직관과 가중치 한 번 읽기

추가 시연인 Huber M 적합은 작은 잔차 부근에서는 제곱손실처럼 반응하지만 큰 잔차에서는 손실 증가를 완화합니다. 반복해서 적합하며 잔차의 상대적 크기에 따라 가중치가 달라집니다. 설명용으로 표준화 잔차 u와 기준 1.345를 쓰면 가중치는 $\min(1, 1.345/|u|)$입니다. u=0.5이면 1, u=2이면 약 0.6725입니다. 실제 u의 규모 추정도 로버스트 적합 과정에 들어갑니다.





왼쪽은 손실의 원리를 보여 주는 추가 도식입니다. 오른쪽은 **같은 Hills35행을 유지한** `MASS::rlm()` Huber 적합 결과입니다. 7번 가중치는 약 0.1485, 18번은 약 0.1066으로 작지만, h가 약 0.690인 11번은 가중치 1입니다. 잔차 기반 Huber가 모든 높은 지레점을 자동으로 처리하는 것은 아닙니다.

가중치는 관측이 맞을 확률이 아닙니다. 작은 가중치를 받았다고 오류가 확정되는 것도 아닙니다. OLS와 로버스트의 계수·예측·가중치 변화를 비교하고 자료 맥락을 확인합니다. R `rlm`의 잔차 자유도는 일반 `lm`의 규모 추론을 잘못 적용하지 않도록 NA로 설정됩니다. 일반 OLS t/F 출력과 같은 방식으로 해석하지 않습니다.

확인 C14. 'h가 큰 점은 Huber에서 항상 작은 가중치를 받는다'고 말할 수 있나요? 11번 경주가 보여 주는 한계를 설명하세요.

출처와 다음 연결

주교재 §5.12–5.15, 인쇄220–228쪽. 공식 Hills는 초·마일·피트 단위를 유지했습니다. R의 내장 `MASS::hills`는 분 단위이고 일부 값에도 차이가 있어 이 자료를 조용히 대체하지 않았습니다. 잔차화는 선형 조정이며 인과 통제 실험이 아닙니다. Huber의 구체적 손실·가중치 시연은 교재 도입을 보완한 추가 설명입니다.

R car: 첨가변수플롯 · R car: 성분잔차플롯 · MASS: 로버스트 적합

이제 집단별 잔차 구조를 이용해 범주형 변수와 상호작용을 배웁니다. D · 급여 자료의 범주형 예측변수.

W10A D · 범주형 예측변수와 상호작용을 급여로 이해하기

회귀분석의 이해 · 2026년 11월 2일 · 주교재 §6.1–6.3

앞의 진단은 모형을 비판하는 데서 끝나지 않습니다. 집단별로 잔차가 한쪽으로 남으면 평균모형에 어떤 구조가 빠졌는지 생각할 수 있습니다. 이번에는 **범주형 예측변수**와 **상호작용**을 넣어 이 질문을 이어 갑니다. 반응변수는 계속 연속형 급여이며, 이진 반응 회귀를 배우는 범위가 아닙니다.

1. 숫자로 적힌 범주 이름은 수량과 다르다 (§6.1)

범주형 또는 질적 변수는 집단의 이름을 나타냅니다. 학력코드 1·2·3이 있다 해도 3이 1의 세 배인 학력이나, 각 단계 사이의 같은 거리라는 뜻은 아닙니다. 코드를 그대로 수치형 회귀에 넣으면 의도하지 않은 등간격 효과를 가정하게 됩니다.

교재의 Salary Survey는 직원 46명의 익명 수치 자료입니다. 각 열은 다음 뜻입니다.

열	뜻	값·단위
S	연급여, 반응변수	달러/년
X	경력, 수치형 예측변수	년
E	교육수준 범주	1 고졸, 2 학사, 3 대학원
M	관리직 여부 범주	0 비관리직, 1 관리직

이 자료에서 읽는 집단 차이는 관찰 자료의 조건부 연관입니다. 학력을 바꾸거나 승진시키면 특정인의 급여가 그만큼 바뀐다는 인과효과로 단정하지 않습니다.

2. 더미변수: ‘해당하면 1, 아니면 0’ (§6.2)

지시변수 또는 더미변수는 특정 범주에 속하는지를 0/1로 표시한 열입니다. E1은 고졸일 때 1, E2는 학사일 때 1로 만듭니다. 대학원은 두 값이 모두 0인 **기준범주**로 둡니다. 기준범주는 비교의 출발점이지 우열이나 좋은 집단을 뜻하지 않습니다.

교육수준	E1	E2	이 행의 의미
고졸	1	0	고졸 차이를 더함
학사	0	1	학사 차이를 더함
대학원	0	0	기준범주 값에서 시작

왜 세 집단인데 두 열만 쓸까요? 절편의 1열과 고졸·학사·대학원 세 지시열을 모두 넣으면, 세 지시열의 합이 항상 절편의 1열입니다. 같은 정보를 중복해서 넣어 계수를 유일하게 정할 수 없게 됩니다. 이를 흔히 **더미변수 함정**이라고 부릅니다. 절편을 두고 한 범주를 기준으로 빼면 이 중복을 피할 수 있습니다.

범주 이름을 0/1 열로 표현하기

E	M	절편	E1	E2	E3	E1×M	E2×M
1	0	1	1	0	0	0	0
1	1	1	1	0	0	1	0
2	0	1	0	1	0	0	0
2	1	1	0	1	0	0	1
3	0	1	0	0	1	0	0
3	1	1	0	0	1	0	0

E1 + E2 + E3 = 절편의 1열 → 모두 넣으면 중복

E3 열은 중복을 설명하기 위해 그림에 표시했습니다. **절편·E1·E2와 함께 E3까지 적합한다는 뜻은 아닙니다.** 오른쪽 곱 열은 뒤에서 상호작용을 만들 때 씁니다. 출처: 교재 범주 정의로 구성한 자체 부호화 표.

확인 C15. E=3인 관측의 E1과 E2가 모두 0이라고 해서 교육수준 정보가 없어진 것인가요? 절편과 세 더미를 모두 넣으면 무엇이 중복되나요?

3. 가법모형: 각 효과를 더하되 차이는 일정하게

가법은 각 항의 효과를 더한다는 뜻입니다. 교재 식6.1은 경력·교육수준·관리직 효과를 다음과 같이 더합니다.

급여 계수의 첨자는 **대응하는 예측항의 이름**으로 통일합니다. b_X는 경력 X, b_{E1}과 b_{E2}는 학력 더미, b_M은 관리직, b_{E1M}과 b_{E2M}은 두 곱항의 계수입니다. 보충 카드·질문 해설도 같은 표기를 씁니다.

교재 기호와 비교하면 경력의 β_1은 b_X, 학력의 γ_1, γ_2는 b_{E1}, b_{E2}, 관리직의 δ_1은 b_M, 상호작용의 α_1, α_2는 b_{E1M}, b_{E2M}에 대응합니다. 절편은 b_0입니다. 급여 자료의 X열은 경력(년)이며, 여러 설명 항을 모은 설계행렬 $\mathbf{X}$와 구별합니다.

$$\widehat{S} = b_0 + b_X X + b_{E1} E1 + b_{E2} E2 + b_M M.$$

각 계수의 뜻을 먼저 구분합니다. b_0는 경력 0인 기준범주 대학원·비관리직의 모형값, b_X은 경력 1년의 평균 차이입니다. b_{E1}과 b_{E2}는 같은 경력·관리직 여부에서 기준 학력과의 차이입니다. b_M는 같은 경력·학력에서 관리직과 비관리직의 차이입니다. 경력 0은 이 자료의 실제 관측 범위 밖이므로 절편을 관측된 직원 급여라고 말하지 않습니다.

같은 46행으로 적합하면 교재 표6.2와 다음 수치가 재현됩니다.

$$\widehat{S} = 11031.807892 + 546.184019 X - 2996.210262 E1 + 147.824948 E2 + 6883.531006 M.$$

E11 · 경력 5년·고졸·관리직의 급여 예측

먼저 범주를 0/1로 바꿉니다. 고졸이므로 E1=1, E2=0이고, 관리직이므로 M=1입니다. 경력은 X=5입니다.

$$\begin{aligned}\widehat{S} &= 11031.807892 + 546.184019 \times 5 \\ &\quad -2996.210262 \times 1 + 147.824948 \times 0 + 6883.531006 \times 1 \\ &\approx 17650.048730 \text{ 달러/년}.\end{aligned}$$

같은 조건의 비관리직은 마지막 관리직 항만 빠집니다. 따라서 이 모형에서 관리직 격차는 6883.531006달러입니다. 학력이 고졸·학사·대학원 중 무엇이든 이 격차가 같도록 정한 모형입니다. 이 제약이 자료와 맞는지 잔차로 살펴봅니다.

여기서 실제 원래 예측변수는 경력·학력·관리직 세 가지이지만, 추정하는 계수는 절편·경력·학력 더미 둘·관리직의 **5개**입니다. 범주형 변수가 들어오면 '원래 변수 수 + 1'로 계수 수를 세면 안 됩니다. k는 실제 모형행렬의 계수 수이며, 완전계수 모형에서는 그 rank입니다.

4. 상호작용: 한 차이가 다른 조건에 따라 달라짐 (§6.3)

'관리직과 비관리직 차이가 학력마다 다를 수 있다'는 가정을 표현하려면 E1×M과 E2×M을 추가합니다. 곱이 낯설어도 0/1 스위치로 읽으면 됩니다. E1×M은 고졸이면서 관리직일 때만 1입니다. E2×M은 학사이면서 관리직일 때만 1입니다.

$$\widehat{S} = b_0 + b_X X + b_{E1} E1 + b_{E2} E2 + b_M M + b_{E1M} E1M + b_{E2M} E2M.$$

이번 식의 상호작용은 **교육수준 × 관리직**입니다. 경력 X와의 곱이 없으므로, 교육수준·관리직 집단별 경력 기울기를 다르게 만드는 식은 아닙니다. 계수는 7개이고, 46행의 잔차 자유도는 46-7=39입니다.

같은 46명을 유지한 교재 표6.3의 적합값은 다음과 같습니다. 가법모형을 적합할 때와 표본을 바꾸지 않았습니다.

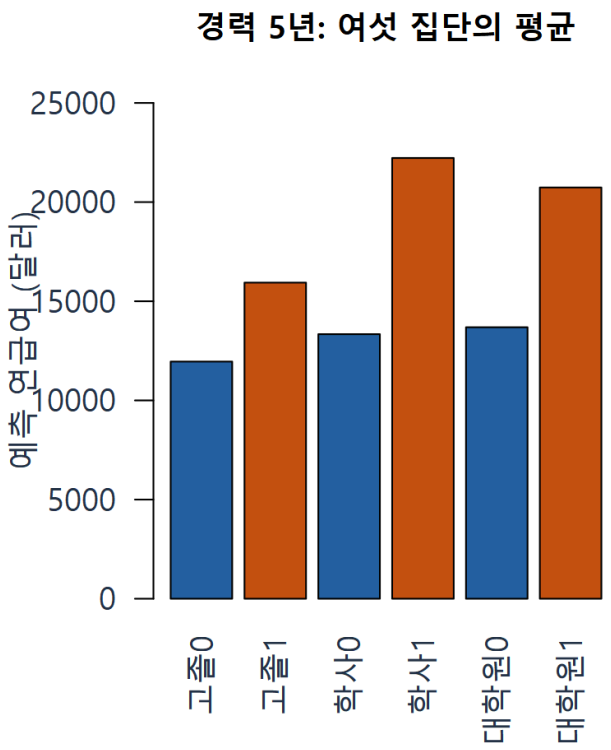
$$\begin{aligned}\widehat{S} &= 11203.433772 + 496.987011X \\ &\quad - 1730.748323E1 - 349.077692E2 + 7047.412024M \\ &\quad - 3066.035125E1M + 1836.487946E2M.\end{aligned}$$

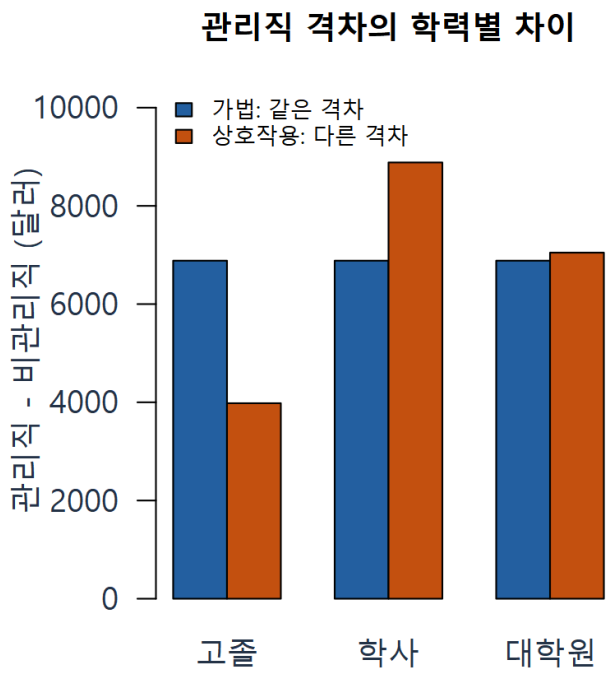
E12 · 관리직 격차를 세 번 계산하기

먼저 경력과 학력을 같게 두고 M만 0에서 1로 바꿉니다. 두 예측을 빼면 경력과 학력의 공통 항이 사라집니다.

학력	관리직 - 비관리직의 식	격차 (달러/년)
대학원: E1=0,E2=0	b_M	7047.412024
고졸: E1=1,E2=0	$b_M + b_{E1M}$	3981.376900
학사: E1=0,E2=1	$b_M + b_{E2M}$	8883.899970

고졸의 경우 $7047.412024 - 3066.035125 = 3981.376900$입니다. 학사의 $b_{E2M} = 1836.487946$은 학사 관리직 격차 자체가 아니라 **기준범주 관리직 격차에 더해지는 차이**입니다. 그래서 총 격차는 약 8883.900달러입니다. 이 계산은 집단 차이를 읽는 대수적 비교이며 별도의 인과 연구설계를 뜻하지 않습니다.





왼쪽의 0/1은 비관리직/관리직을 뜻합니다. 오른쪽 파란 막대는 가법모형의 같은 격차, 주황 막대는 상호작용 모형의 학력별 격차입니다. 경력은 모두 5년으로 같습니다. 출처: 공식 Salary.Survey46행 재계산.

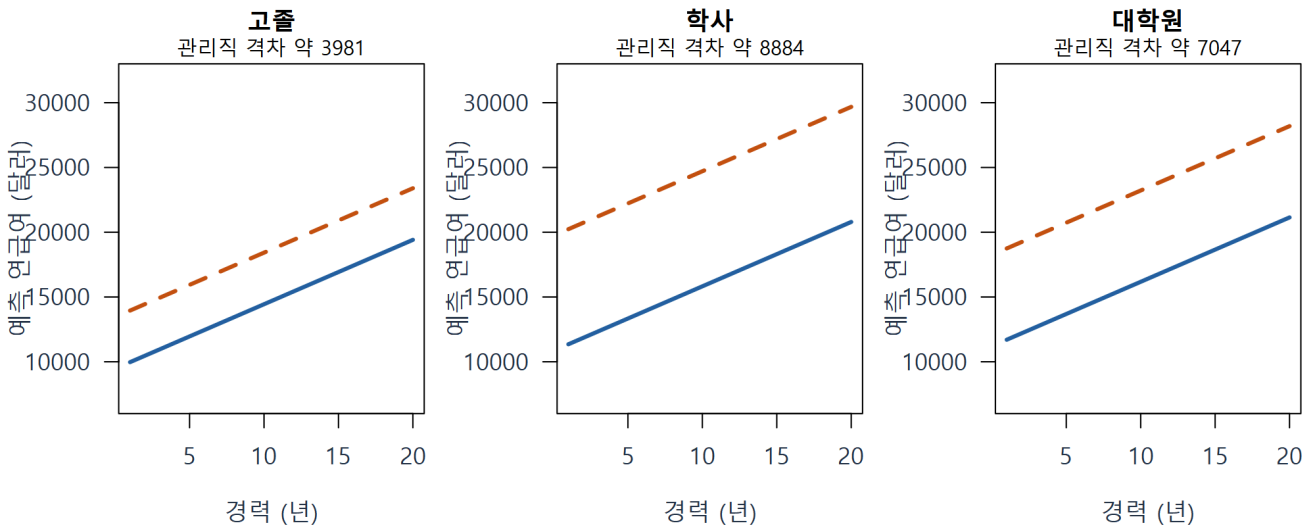
경력 5년의 집단	비관리직 예측	관리직 예측
고졸	11957.621	15938.997
학사	13339.291	22223.191
대학원	13688.369	20735.781

위 표는 상호작용 모형의 **집단 평균 예측**입니다. 앞 E11의 17650.049는 가법모형 값이므로 서로 다른 모형의 숫자를 한 계산에 섞지 않습니다.

확인 C16. 학사 관리직 격차를 구할 때 1836.488만 읽으면 왜 틀리나요? 기준범주 격차와 추가 차이를 각각 짚으세요.

5. 상호작용인데 경력 직선들이 평행한 이유

이번 모형에는 X×M이나 X×학력 항이 없습니다. 따라서 어떤 집단이든 경력이 1년 달라질 때 예측의 기울기는 496.987011달러/년으로 같습니다. 학력별 관리직과 비관리직의 **세로 간격**은 다르지만 경력에 따른 기울기는 공통입니다.

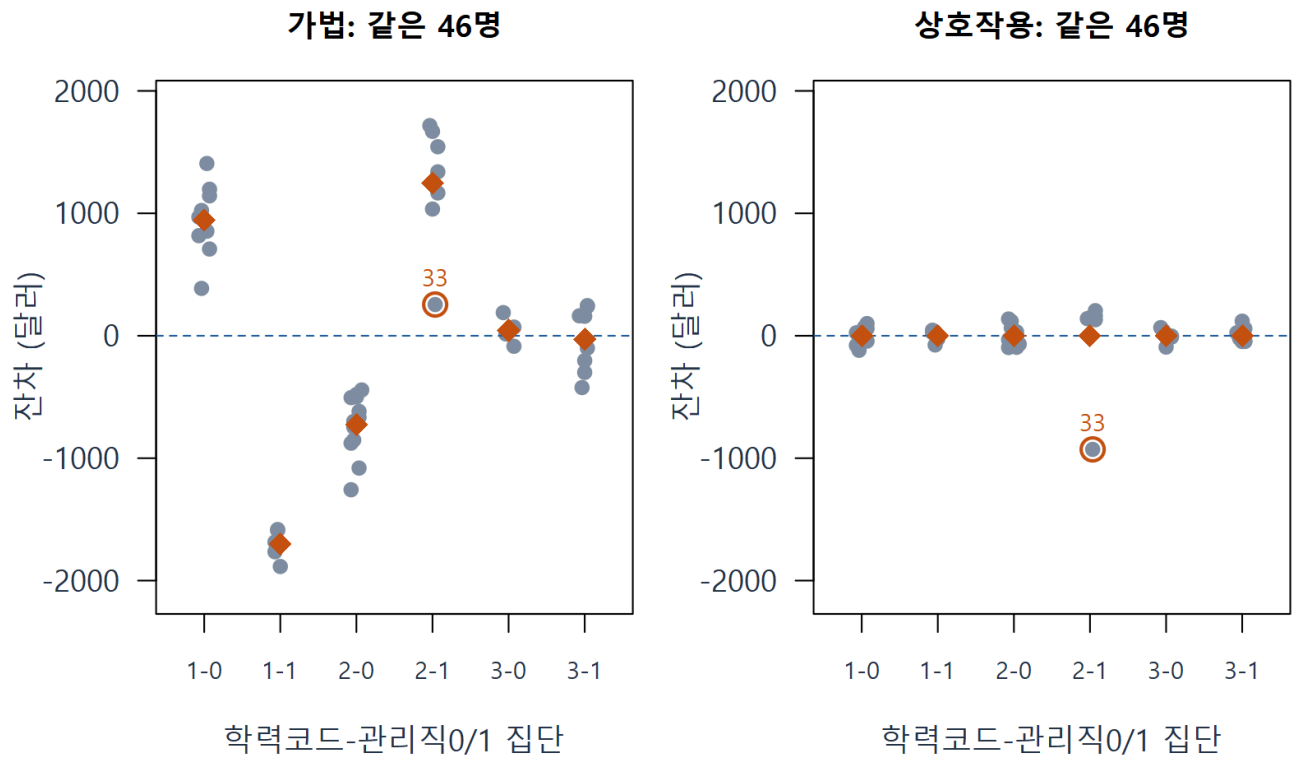


각 패널에서 파란 실선은 비관리직, 주황 점선은 관리직입니다. 세 패널은 같은 축 척도입니다. 상호작용이라는 말만 보고 모든 직선이 교차하거나 기울기가 달라져야 한다고 생각하지 않습니다. **어떤 변수끼리 곱했는지** 식으로 확인합니다.

확인 C17. 이번 상호작용 모형에서 경력이 5년에서 6년으로 바뀌면 여섯 집단의 예측은 각각 얼마나 달라지나요? 관리직 격차도 경력에 따라 달라지나요?

6. 잔차로 연결하기: 모형을 바꾼 뒤에도 다시 확인

가법모형에서 학력×관리직 집단별 잔차가 한쪽으로 치우치면, 같은 관리직 격차라는 제약이 충분하지 않을 가능성을 생각할 수 있습니다. 아래는 같은 46명의 두 모형 잔차를 **같은 세로 척도**에 놓은 그림입니다.



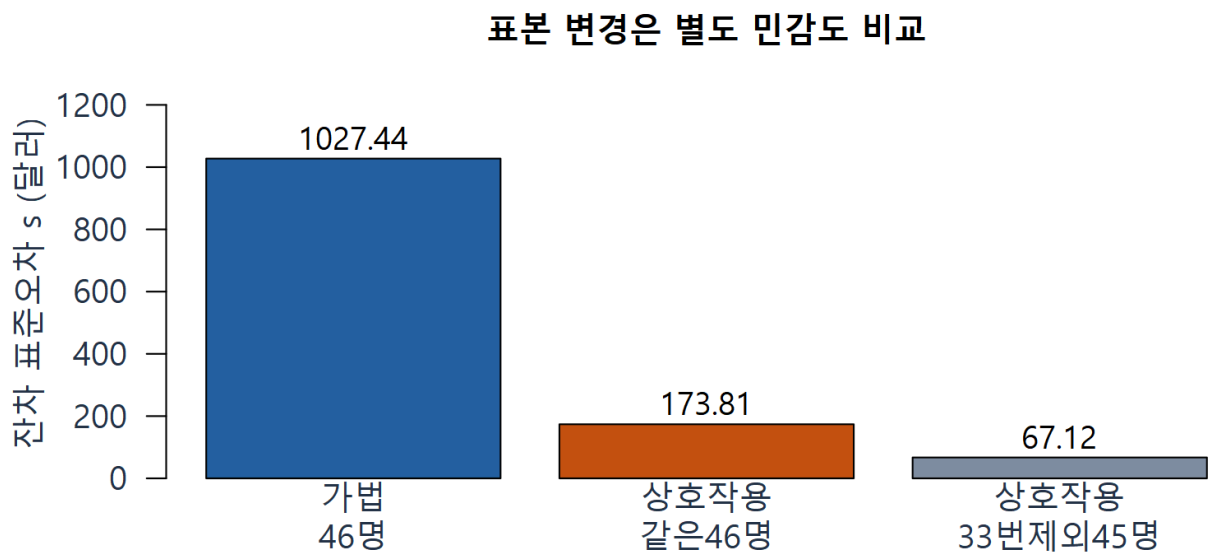
가로의 1-0은 고졸·비관리직, 1-1은 고졸·관리직처럼 읽습니다. 주황 마름모는 집단별 평균 잔차입니다. 오른쪽 집단 평균이 0에 가깝다는 사실만으로 좋은 모형이 입증되지는 않습니다. 여섯 집단의 절편을 표현하는 이번 OLS 모형에서는 집단별 잔차합 0이 적합 계산의 성질로 생깁니다. **집단 안의 곡선·산포·순서 구조와 개별 관측**도 다시 살펴야 합니다.

확인 C18. 상호작용을 넣은 뒤 집단 평균 잔차가 0이면 모든 가정이 만족됐다고 말할 수 있나요? 적합 계산으로 생기는 성질과 추가 진단을 구별하세요.

7. 교재의 33번 관측: 표본 변경은 별도 민감도 분석

교재는 33번을 따로 살펴본 뒤 제외한 분석도 보여 줍니다. 우리 원자료 46행은 보존합니다. 33번의 실제 S=23780, X=10, E=2, M=1입니다. 같은 관측도 가법모형 잔차는 약 +254.996달러, 상호작용 모형 잔차는 약 -928.126달러로 달라집니다. 특이성은 모형과 연결되어 있다는 앞 내용을 다시 확인합니다.

분석	사용 관측	k	잔차 자유도	잔차 표준오차 s
가법	전체 46	5	41	1027.437
상호작용	같은 46	7	39	173.809
상호작용·33번 제외 민감도	45	7	38	67.119



앞 두 줄은 표본을 같게 두고 모형을 비교했습니다. 마지막 줄은 표본도 달라졌으므로 별도 민감도 비교입니다. s가 작아졌다는 이유만으로 33번을 오류로 확정하거나 제외를 자동 결정하지 않습니다. 교재 표6.4–6.5와 비교할 때도 45행 분석임을 먼저 적습니다.

45행 모형의 경력 계수는 약 498.418이고 95% 신뢰구간은 약 [494.062, 502.774]입니다. 이는 모형 가정 아래 **공통 평균 경력 기울기**의 구간입니다. 특정 직원의 내년 급여 변화가 반드시 이 범위에 든다는 뜻은 아닙니다. 교재 표6.5의 경력0 집단 평균과 그 신뢰구간은 개념 카드에서 별도로 읽습니다.

8. R로 표현하고, 기준범주를 바꾸어 검산하기

R에서 범주를 `factor()`로 표시하고 기준수준을 명시합니다. `S ~ X + Education + M`은 가법모형, `S ~ X + Education * M`은 Education·M·Education:M을 포함한 이번 상호작용 모형입니다. 별표가 모든 변수끼리 곱한다는 뜻은 아닙니다. 경력 X는 이 곱에 포함되지 않습니다.

기준범주를 바꾸면 절편과 차이 계수의 숫자는 바뀔 수 있습니다. 하지만 같은 모형공간과 같은 자료를 표현했다면 **각 관측의 적합값과 여섯 집단 예측은 같습니다.** 모형이 바뀐 것과 표현 기준이 바뀐 것을 구분하는 검산입니다.

확인 C19. 대학원 대신 고졸을 기준으로 바꾸면 기존 직원의 적합 급여까지 바뀌어야 하나요? 계수와 예측을 나누어 답하세요.

9. 이해를 확인하고 실습으로 옮기기

설치 없는 온라인 R에서 먼저 실행 전 예상값을 적습니다. 점 이동 코드에서는 같은 x의 자기 예측과 잔차 변화량을 비교합니다. 급여 코드에서는 가법/상호작용을 바꾸고 세 관리직 격차를 비교합니다. 마지막에는 누적 앱 편집기의 `W10A_L06` 출력 필드 한 곳을 수정해 입력–함수–결과를 연결합니다.

출구 X01. 큰 h, 큰 잔차, 큰 영향력을 서로 다른 말로 한 문장씩 설명하세요.

출구 X02. Q-Q와 수집순서 플롯의 축을 각각 쓰고, 어느 그림이 순서 구조를 놓칠 수 있는지 설명하세요.

출구 X03. 학력×관리직 모형에서 학사 관리직 격차와 공통 경력 기울기가 어떤 계수 조합인지 설명하세요.

출처

주교재『Chatterjee 예제를 통한 회귀분석 제6판: R 활용』§6.1–6.3, 인쇄242–253쪽의 §6.4 시작 전. 표6.2–6.4는 저자 공식 Salary Survey46행과 명시한45행 민감도로 재현했습니다. 설명과 그림은 자체 작성이며 교재 원본 전체 파일은 배포하지 않습니다.

R: 모형행렬과 더미·상호작용 · R: 기준수준 변경 · 반복 계산 워크북 · 개념 카드와 선택 수학 보충